Tecnológico de Costa Rica

Escuela de Ingeniería en Computadores
(Computer Engineering School)

Programa de Licenciatura en Ingeniería en Computadores
(Licentiate Degree Program in Computer Engineering)



Desarrollo de una Plataforma de Localización y Mapeo Simultaneo (SLAM) Híbrida en Tiempo Real Mediante Fusión de Visión, GPS y Aprendizaje por Refuerzo para Navegación en Entornos Viales

(Development of a Real-Time Hybrid SLAM Platform through Vision, GPS, and Reinforcement Learning Fusion for Road Environment Navigation)

Informe de Trabajo de Graduación para optar por el título de Ingeniero en Computadores con grado académico de Licenciatura

(Report of Graduation Work in fulfillment of the requirements for the degree of Licentiate in Computer Engineering)

NAHEEM JOHNSON SOLÍS

Cartago, junio de 2026
(Cartago, June, 2026)

Declaro que el presente Proyecto de Graduación ha sido realizado enteramente por mi persona, utilizando y aplicando literatura referente al tema e introduciendo conocimientos propios.

En los casos en que he utilizado bibliografía he procedido a indicar las fuentes mediante las respectivas citas bibliográficas. En consecuencia, asumo la responsabilidad total por el trabajo de graduación realizado y por el contenido del correspondiente informe final.

NAHEEM JOHNSON SOLÍS

Cartago, 11 de noviembre de 2026

Céd: 118210613

Instituto Tecnológico de Costa Rica
Área Académica de Ingeniería en Computadores
Proyecto de Graduación
Tribunal Evaluador

Proyecto de Graduación defendido ante el presente Tribunal Evaluador como requisito para optar por el título de Ingeniero en Computadores con el grado académico de Licenciatura, del Instituto Tecnológico de Costa Rica.

Miembros del Tribunal

Profesora Lector	Profesor Lector

Dr.Eng. Jeferson González Gómez
Profesor Asesor

Los miembros de este Tribunal dan fe de que el presente trabajo de graduación ha sido aprobado y cumple con las normas establecidas por el Área Académica de Ingeniería en Computadores.

Cartago, noviembre de 2026

Instituto Tecnológico de Costa Rica
Área Académica de Ingeniería en Computadores
Proyecto de Graduación
Tribunal Evaluador
Acta de Evaluación

Proyecto de Graduación defendido ante el presente Tribunal Evaluador como requisito para optar por el título de Ingeniero en Computadores con el grado académico de Licenciatura, del Instituto Tecnológico de Costa Rica.

Estudiante: *NAHEEM JOHNSON SOLÍS*

Nombre del Proyecto: *Desarrollo de una Plataforma de Localización y Mapeo Simultaneo (SLAM) Híbrida en Tiempo Real Mediante Fusión de Visión, GPS y Aprendizaje por Refuerzo para Navegación en Entornos Viales*

Miembros del Tribunal

_____ _____

Profesora Lector Profesor Lector

_____

Dr.Eng. Jeferson González Gómez
Profesor Asesor

Los miembros de este Tribunal dan fe de que el presente trabajo de graduación ha sido aprobado y cumple con las normas establecidas por el Área Académica de Ingeniería en Computadores.

Nota final del Proyecto de Graduación: _____

Cartago, noviembre de 2026

Resumen

Palabras clave: PALABRAS CLAVE

Abstract

Keywords:

DEDICATORIA

Agradecimientos

NAHEEM JOHNSON SOLÍS

Cartago, 30 de octubre de 2026

Índice general

Índice de figuras iv

Índice de tablas v

1 Introducción 1
- 1.1 Antecedentes del proyecto . . . 2
  - 1.1.1 Descripción de la organización . . . 2
  - 1.1.2 Descripción del área de conocimiento del proyecto . . . 3
  - 1.1.3 Trabajos similares encontrados . . . 4
- 1.2 Planteamiento del problema . . . 6
  - 1.2.1 Contexto del problema . . . 6
  - 1.2.2 Justificación del problema . . . 7
  - 1.2.3 Enunciado del problema . . . 9
- 1.3 Objetivos del proyecto . . . 9
  - 1.3.1 Objetivo general . . . 9
  - 1.3.2 Objetivos específicos . . . 9
- 1.4 Alcances, entregables y limitaciones del proyecto . . . 10
  - 1.4.1 Alcances . . . 10
  - 1.4.2 Entregables . . . 11
  - 1.4.3 Limitaciones del proyecto . . . 11

2 Marco teórico 13
- 2.1 Introducción . . . 13
- 2.2 Mapa conceptual . . . 14
- 2.3 Localización y mapeo simultáneos . . . 15
  - 2.3.1 Representación probabilística . . . 15
  - 2.3.2 Arquitectura: procesamiento frontal y posterior . . . 16
- 2.4 SLAM visual monocular . . . 17
  - 2.4.1 Modelo de cámara estenopeica . . . 17
  - 2.4.2 Detección y descripción de características ORB . . . 18
  - 2.4.3 Geometría epipolar y estimación de la pose relativa . . . 19
  - 2.4.4 Estimación robusta mediante RANSAC . . . 20
  - 2.4.5 Triangulación . . . 21
  - 2.4.6 Deriva y ambigüedad de escala . . . 22

2.4.7 Escala métrica a partir de profundidad monocular . . . 23
2.5 Posicionamiento satelital . . . 23
2.5.1 Principio de operación . . . 23
2.5.2 Fuentes de error y receptores de dispositivos móviles . . . 24
2.5.3 Conversión a coordenadas métricas . . . 25
2.6 Sensores inerciales . . . 25
2.7 Fusión de sensores . . . 26
2.7.1 Complementariedad entre las fuentes . . . 26
2.7.2 Filtro de Kalman . . . 27
2.7.3 Filtro de Kalman extendido . . . 28
2.7.4 Papel de las covarianzas de ruido . . . 29
2.7.5 Filtrado adaptativo . . . 30
2.8 Aprendizaje por refuerzo . . . 31
2.8.1 Procesos de decisión de Markov . . . 31
2.8.2 Métodos basados en valor: Q-learning . . . 32
2.8.3 Ajuste adaptativo de la fusión mediante aprendizaje por refuerzo . . . 33
2.9 Operación en tiempo real . . . 35
2.10 Métricas de evaluación de trayectorias . . . 37

3 Marco metodológico 40
3.1 Introducción . . . 40
3.2 Tipo de trabajo y estrategia elegida . . . 40
3.3 Secuencia del proceso . . . 41
3.3.1 Fase 1: análisis y definición de requerimientos . . . 42
3.3.2 Fase 2: diseño e implementación de la plataforma . . . 43
3.3.3 Fase 3: validación experimental . . . 45
3.3.4 Fase 4: análisis de resultados y documentación . . . 46
3.4 Herramientas y recursos . . . 46
3.5 Actores participantes . . . 48
3.6 Desglose del marco metodológico . . . 48

4 Descripción del trabajo realizado 50
4.1 Descripción del proceso de solución . . . 50
4.1.1 Requerimientos de la plataforma . . . 50
4.1.2 Arquitectura de la plataforma . . . 52
4.1.3 Estimación de la escala métrica . . . 54
4.1.4 Corrección de la odometría visual . . . 55
4.1.5 Filtro de fusión . . . 56
4.1.6 Mecanismo de aprendizaje por refuerzo . . . 59
4.2 Análisis de los resultados obtenidos . . . 61
4.2.1 Comportamiento en tiempo real . . . 62
4.2.2 Prueba de campo . . . 63
4.2.3 Precisión de la localización . . . 64

4.2.4 Aporte del aprendizaje por refuerzo 65
4.2.5 Limitaciones de la solución 67

5 Conclusiones **68**
5.1 Recomendaciones 68

Bibliografía **69**

A APENDICE A **72**

B APENDICE B **73**

C APENDICE C **74**

Índice de figuras

Fig. 1 Mapa conceptual del marco teórico 14
Fig. 2 Arquitectura de un sistema SLAM 16
Fig. 3 Modelo de cámara estenopeica 18
Fig. 4 Geometría epipolar entre dos vistas 20
Fig. 5 Operación del filtro con frecuencias distintas 29
Fig. 6 Ciclo de interacción entre el agente y el entorno 31
Fig. 7 Descarte de cuadros y procesamiento asíncrono 36
Fig. 8 Diferencia entre ATE y RPE 38

Fig. 9 Secuencia del proceso seguido 42

Fig. 10 Arquitectura de la plataforma 53
Fig. 11 Percentil 90 del error a 30 s por sesión de prueba 66

Índice de tablas

Tabla 1 Comparación de los trabajos similares con el presente proyecto . . . 5
Tabla 2 Entregables asociados a cada objetivo específico 11

Tabla 3 Características complementarias de las fuentes de información 27

Tabla 4 Herramientas y recursos del proyecto 47
Tabla 5 Desglose del marco metodológico por objetivo específico 49

Tabla 6 Requerimientos propuestos para la plataforma 52
Tabla 7 Mediciones y niveles de ruido del filtro 57
Tabla 8 Error al volver el GPS según la variante del filtro 58
Tabla 9 Señales del estado de la política y sus niveles 60
Tabla 10 Grabaciones empleadas 62
Tabla 11 Comportamiento temporal en vivo, con el teléfono conectado por cable 62
Tabla 12 Desempeño en vivo durante la prueba de campo 63
Tabla 13 Separación final en el modo exclusivamente visual 64
Tabla 14 Percentil 95 del error con el GPS degradado 65
Tabla 15 Error al volver el GPS con la política de la primera iteración 65

Capítulo 1

Introducción

La localización y navegación de agentes móviles representan uno de los principales retos en los campos de la robótica móvil, los sistemas autónomos y las tecnologías de transporte inteligente. Para desplazarse de manera segura y fiable, un agente debe determinar su propia ubicación y, simultáneamente, generar una representación del entorno que le permita desenvolverse en él de forma efectiva.

Los sistemas de Localización y Mapeo Simultáneo (SLAM, del inglés *Simultaneous Localization and Mapping*) responden justamente a ese requerimiento: posibilitan calcular la trayectoria seguida por el agente y construir un mapa de su entorno empleando los datos proporcionados por sus sensores, sin necesidad de contar con una infraestructura externa instalada de antemano [2].

Si bien estas metodologías han mostrado un progreso notable, su rendimiento disminuye cuando se enfrentan a escenarios viales cambiantes. Factores como las variaciones lumínicas, los elementos en movimiento, las obstrucciones momentáneas y la desaparición de rasgos visuales generan errores acumulativos que afectan gradualmente la precisión en el cálculo de la trayectoria y la fidelidad del mapa, aunque para mitigar esta desviación se suele recurrir a coordenadas absolutas de sistemas de posicionamiento global (GPS) que también incorporan su propio margen de incertidumbre. Ante este desafío, el presente Trabajo Final de Graduación propone el desarrollo de un sistema SLAM híbrido de ejecución en tiempo real que integra la información visual de una cámara monocular, los registros GPS de dispositivos móviles y una estrategia de aprendizaje por refuerzo encargada de calibrar de manera dinámica el peso de cada fuente informativa durante el trayecto.

En este capítulo se presenta el contexto general del proyecto. En primer lugar, se exponen sus antecedentes, abarcando la descripción de la organización en la que se lleva a cabo, las áreas de conocimiento vinculadas y los estudios previos relacionados con la problemática que se busca atender. A continuación, se desarrolla el planteamiento del problema, desde la descripción de su contexto y justificación hasta la formulación concreta del mismo. Por último, se establecen los objetivos del proyecto y se especifican sus alcances, los

entregables previstos y las limitaciones identificadas.

1.1 Antecedentes del proyecto

El presente apartado ubica el proyecto dentro de su marco contextual. En primer lugar, se presenta la entidad donde este se lleva a cabo; seguidamente, se determinan las ramas de conocimiento de la Ingeniería en Computadores con las que se relaciona el trabajo y, por último, se examinan investigaciones anteriores que tratan problemáticas análogas, con el fin de delimitar aquellos elementos en los que este proyecto se sustenta y aquellos en los que se distingue respecto a la literatura existente.

1.1.1 Descripción de la organización

Esta sección tiene como fin presentar un panorama general del contexto y los antecedentes del proyecto en desarrollo. Para ello, se abordan elementos clave de la institución anfitriona, el Instituto Tecnológico de Costa Rica, tales como sus orígenes, localización geográfica, enfoque institucional y estructura organizativa.

El Instituto Tecnológico de Costa Rica (TEC) es una institución autónoma de educación superior universitaria de alcance nacional, establecida mediante la Ley No. 4.777 el 10 de junio de 1971. Su misión consiste en impulsar el desarrollo integral del país mediante la formación de profesionales, la investigación y la extensión en los campos de la tecnología y las ciencias relacionadas, procurando mantener un papel destacado en los ámbitos científico, tecnológico y técnico. El TEC tiene su sede principal en Cartago, Costa Rica, y ha contribuido significativamente al desarrollo educativo y tecnológico de la nación [25].

La fundación del TEC se promovió bajo la administración del presidente de la República, José Figueres Ferrer, contando con el respaldo del presidente de la Asamblea Legislativa, Daniel Oduber Quirós, así como de la comunidad cartaginesa. La población de Cartago optó por la iniciativa de crear el TEC por encima de otras alternativas, tales como un programa de desarrollo agropecuario y una carretera hacia San José. El acto de suscripción de la Ley de Creación del Tecnológico de Costa Rica constituyó un acontecimiento cívico de relevancia, el cual se conmemoró con desfiles en la vieja metrópoli [25].

Dentro de su esquema organizativo, el TEC dispone de diversas instancias fundamentales: la Asamblea Institucional como máxima autoridad, el Consejo Institucional en su rol de órgano directivo superior, la Rectoría como la máxima jerarquía ejecutiva, y un conjunto de cuatro Vicerrectorías orientadas a ejecutar políticas particulares [25].

En particular, el proyecto se lleva a cabo en la Escuela de Ingeniería en Computadores del TEC, localizada igualmente en Cartago. Esta disciplina integra las Ciencias de la Computación y la Ingeniería Electrónica, y comprende el diseño, la construcción, la implementación y el mantenimiento de componentes de sistemas computacionales, tanto en

hardware como en *software* [24]. La Escuela fomenta el desarrollo de soluciones mediante la aplicación de conocimientos en áreas como el desarrollo de software, la inteligencia artificial, los sistemas empotrados y la arquitectura de computadores. Asimismo, participa activamente en iniciativas de investigación orientadas al desarrollo de sistemas computacionales y dispositivos controlados por computador. El proyecto se enmarca en este contexto académico y forma parte de los requisitos para obtener el grado de Licenciatura en Ingeniería en Computadores. Esta modalidad permite a los estudiantes aplicar e integrar los conocimientos adquiridos durante su formación mediante la ejecución de proyectos de investigación, innovación o desarrollo tecnológico [10].

1.1.2 Descripción del área de conocimiento del proyecto

Las directrices de la Escuela de Ingeniería en Computadores definen las áreas de conocimiento dentro de las cuales debe encuadrarse un Trabajo Final de Graduación de la carrera [10]. El proyecto actual se sitúa en tres de dichas áreas, y cada una de ellas se vincula con un componente diferente de la plataforma planteada.

Inteligencia artificial y aprendizaje de máquina. La función encargada de determinar el nivel de confianza para cada sensor no se define mediante un conjunto de normas preestablecidas, sino a través de una política optimizada por medio de aprendizaje por refuerzo. Durante la navegación, el agente analiza métricas del estado del sistema, genera un peso para cada fuente de datos y refina su comportamiento basándose en una señal de recompensa vinculada a la precisión de la estimación obtenida [22]. Este enfoque de resolución, donde el criterio de elección surge de la experiencia empírica en vez de ser impuesto por el diseñador, caracteriza a esta disciplina.

Reconocimiento y procesamiento de imágenes. El movimiento del agente se calcula mediante el análisis de la secuencia de imágenes capturadas por la cámara. Para ello, es necesario identificar puntos característicos en cada cuadro, generar descriptores que permitan identificarlos en imágenes posteriores y encontrar correspondencias entre cuadros consecutivos. Para realizar este proceso, la plataforma utiliza características ORB [17]. Con base en las correspondencias identificadas, se estima el desplazamiento relativo de la cámara, por lo que la precisión de la localización está directamente relacionada con la calidad del procesamiento de la información visual.

Aplicaciones de alta complejidad algorítmica. La estimación de la trayectoria no se limita a una serie de cálculos directos. Comprende geometría de múltiples vistas para recuperar el movimiento a partir de correspondencias entre imágenes, la conservación de un grafo de poses que acumula las relaciones entre cuadros clave, y la fusión de mediciones heterogéneas, expresadas en sistemas de referencia y con frecuencias de actualización distintas, en una estimación única y coherente. Por consiguiente, el diseño de la solución requiere razonar sobre el costo computacional de cada componente y sobre la manera en que el error se propaga a lo largo del recorrido.

A estas tres áreas se añade un eje transversal que condiciona todo el diseño: la ejecución

en tiempo real. El sistema tiene que generar su estimación mientras el vehículo está en marcha, lo que establece un límite de tiempo estricto por cada fotograma y exige que el análisis visual, la integración de los datos GPS y la decisión del modelo de aprendizaje por refuerzo se procesen dentro de ese margen. Dicha limitación no representa un campo de estudio autónomo dentro de la clasificación de la Escuela, pero determina las elecciones implementadas en cada uno de los apartados anteriores.

1.1.3 Trabajos similares encontrados

La integración del SLAM visual con sistemas de posicionamiento global, así como el uso del aprendizaje por refuerzo para determinar cómo combinar ambas fuentes de información, son enfoques que se han estudiado previamente en la literatura. En las siguientes secciones se examinan tres trabajos relacionados con el problema propuesto, destacando sus similitudes y las diferencias más relevantes en cada caso.

Fusión multisensorial adaptativa mediante actor-crítico. Jia et al. plantean *Lvio-Fusion*, un sistema SLAM que combina cámara estéreo, LiDAR, unidad inercial y GPS por medio de optimización de grafos, e incluye un agente entrenado con el método actor-crítico que ajusta de manera dinámica el peso otorgado a cada sensor conforme al entorno en el que se desplaza el vehículo; los autores lo evalúan en escenarios de tráfico urbano y reportan mejoras frente a esquemas de ponderación fija [11]. Se trata del trabajo conceptualmente más afín al presente proyecto, pues comparte la noción de concebir la asignación de confianza entre sensores como una decisión aprendida en lugar de un parámetro fijo. La distinción radica en los recursos que cada solución demanda: *Lvio-Fusion* se apoya en sensores de nivel profesional, en los cuales el LiDAR aporta mediciones de distancia absolutas y la unidad inercial sostiene la estimación cuando la información visual se deteriora, mientras que este proyecto parte de una cámara monocular y un receptor GPS de dispositivo móvil, de manera que el agente debe decidir entre dos fuentes que, por separado, resultan débiles.

Ponderación entre algoritmos de localización mediante aprendizaje profundo por refuerzo. Wong et al. integran la detección de anomalías en los residuos de estimación junto con un agente optimizado mediante *Proximal Policy Optimization* para balancear el peso de dos métodos de posicionamiento simultáneos —uno apoyado en LiDAR y otro en SLAM visual—, validando su enfoque en escenarios internos simulados en Gazebo [29]. Aunque comparten similitudes en cuanto al mecanismo, las discrepancias con este proyecto son profundas: los espacios interiores simulados carecen de los retos que justifican esta investigación, tales como las variaciones lumínicas al aire libre o la pérdida de calidad en la señal de satélite; asimismo, mientras que Wong et al. evalúan dos estimaciones relativas entre sí, este trabajo requiere fusionar una estimación relativa de alta precisión local pero vulnerable a la deriva con una referencia absoluta afectada por ruido.

Fusión de sensores de teléfono móvil para navegación vehicular. Chiang et al.

combinan datos de GNSS, la unidad de medición inercial y la cámara de un teléfono móvil mediante un esquema de acoplamiento débil que emplea un filtro de Kalman extendido y SLAM monocular para el procesamiento visual. En pruebas realizadas con un vehículo terrestre en un entorno urbano, los autores reportan una mejora del 43,0 % en la estimación de la posición en comparación con una solución que utiliza únicamente GNSS [3]. Este estudio presenta una estrecha relación con el proyecto, tanto por su contexto de aplicación como por los sensores utilizados, ya que evidencia que la información obtenida de un teléfono móvil puede contribuir a mejorar la localización vehicular. Sin embargo, se distingue por incorporar la unidad inercial como elemento principal de la integración, mientras que este proyecto emplea únicamente el giroscopio del teléfono para medir el cambio de rumbo. Además, su método de fusión se basa en un modelo de incertidumbre establecido previamente, cuya configuración permanece fija, frente al enfoque de este proyecto, que busca reemplazar esa configuración por una política adaptativa.

Aporte del presente proyecto. La Tabla 1 sintetiza dichas diferencias. Los estudios examinados abordan por separado las piezas del problema: la fusión adaptativa mediante aprendizaje por refuerzo se ha investigado con conjuntos de sensores extensos o en entornos simulados, mientras que la fusión con sensores de dispositivo móvil en carretera se ha estudiado con métodos de parámetros fijos y con respaldo inercial. Este proyecto se ocupa de la intersección de ambas líneas: una estrategia de fusión adaptativa fundamentada en aprendizaje por refuerzo, que opera únicamente con los sensores de un dispositivo móvil (cámara monocular, GPS y giroscopio), sin integración inercial completa, y que opera en tiempo real durante recorridos viales reales, en lugar de limitarse a datos previamente grabados o simulados.

Tabla 1: Comparación de los trabajos similares con el presente proyecto

Trabajo	**Sensores**	**Estrategia de fusión**	**Validación**
Jia et al. [11]	Cámara estéreo, LiDAR, IMU, GPS	Adaptativa, actor-crítico	Escenas urbanas y conjuntos de datos públicos
Wong et al. [29]	LiDAR 2D, cámara RGB-D, encoders	Adaptativa, *Proximal Policy Optimization*	Entornos interiores simulados
Chiang et al. [3]	GNSS, IMU y cámara de teléfono móvil	Filtro de Kalman extendido, parámetros fijos	Vehículo terrestre en zona urbana
Presente proyecto	Cámara monocular, GPS y giroscopio de dispositivo móvil	Adaptativa, aprendizaje por refuerzo	Recorridos viales controlados, en tiempo real

1.2 Planteamiento del problema

En esta sección se define la problemática que motiva el proyecto. Para ello, primero se detalla el entorno tecnológico en el que se manifiesta este inconveniente, a continuación se fundamenta su importancia y, por último, se formula de manera específica la incógnita que la investigación pretende responder.

1.2.1 Contexto del problema

La determinación precisa de la ubicación de un agente móvil en el entorno donde se desplaza representa uno de los principales desafíos de la robótica móvil y los sistemas autónomos. Esta capacidad es esencial en aplicaciones como los vehículos autónomos, los robots de exploración, los sistemas avanzados de asistencia al conductor y las plataformas inteligentes de monitoreo, ya que los errores en la estimación de la posición pueden repercutir considerablemente en el funcionamiento del sistema e incluso poner en riesgo la seguridad de la operación.

Con el fin de atender esta problemática, a lo largo de las últimas décadas se han concebido diversas técnicas orientadas a la localización y a la construcción de mapas del entorno. Dentro de ellas, los sistemas de Localización y Mapeo Simultáneo (SLAM) se han afianzado como una de las alternativas más empleadas, gracias a su aptitud para estimar de manera simultánea la trayectoria de un agente y producir una representación del entorno a partir de los datos que proveen los sensores [2].

Específicamente, las metodologías fundamentadas en visión por computador han cobrado notable importancia gracias a la accesibilidad de dispositivos económicos y al avance en los métodos de análisis visual. No obstante, al implementar estos sistemas en entornos viales cotidianos, se enfrentan a inconvenientes como variaciones lumínicas, elementos en movimiento, obstrucciones momentáneas y desaparición de rasgos visuales, lo cual genera desviaciones acumulativas que disminuyen de forma continua la exactitud del posicionamiento. A este panorama se suma un obstáculo característico de los arreglos monoculares: al calcular el desplazamiento mediante una única cámara, la escala del trayecto carece de una determinación absoluta, haciendo que dicho error de escala también se propague y acumule a lo largo de la ruta [15].

De manera complementaria, los sistemas de posicionamiento global (GPS) ofrecen referencias absolutas de ubicación que contribuyen a mitigar parte de la deriva acumulada en los métodos de SLAM visual. Sin embargo, estas mediciones están sujetas a errores provocados por el ruido de la señal, las interferencias y las fluctuaciones en la precisión según las condiciones del entorno [8]. En particular, los receptores incorporados en dispositivos móviles de consumo presentan limitaciones más pronunciadas, debido a que ofrecen una precisión inferior a la de los equipos de grado topográfico y actualizan sus mediciones con menor frecuencia que la captura de imágenes de una cámara.

Frente a este panorama, se plantea la necesidad de concebir mecanismos de fusión sensorial que sean capaces de explotar las ventajas de cada tecnología y subsanar sus carencias particulares. Asimismo, se incrementa la exigencia de validar este tipo de soluciones bajo condiciones de operación en tiempo real, de modo que puedan emplearse en escenarios de navegación más próximos a aplicaciones reales.

1.2.2 Justificación del problema

El posicionamiento exacto constituye un elemento esencial para cualquier sistema que requiera desplazamiento autónomo o asistencia a la conducción. Con el auge de las aplicaciones vinculadas a la movilidad inteligente, la robótica móvil y la navegación autónoma, se acentúa la necesidad de disponer de mecanismos capaces de preservar estimaciones de ubicación estables a pesar de las alteraciones del entorno durante la ruta. Asimismo, abordar esta problemática mediante sensores económicos y de alta accesibilidad —tales como la cámara y el módulo GPS integrados en un teléfono inteligente— cobra relevancia al disminuir las barreras de entrada para la experimentación con estos sistemas en ámbitos académicos e investigativos.

Este problema no puede solucionarse de manera óptima mediante el uso de un único sensor, debido a que las dos fuentes de información disponibles presentan limitaciones diferentes que pueden complementarse entre sí. El SLAM visual permite estimar el movimiento con una buena precisión a nivel local, pero no dispone de una referencia absoluta de posición y tiende a acumular errores conforme avanza el recorrido, especialmente cuando la escena presenta poca textura o cuando los objetos en movimiento dificultan el seguimiento de características. Por su parte, el GPS proporciona una referencia absoluta de ubicación que no acumula deriva en función de la distancia recorrida, aunque sus mediciones pueden presentar ruido, menor resolución espacial y pérdidas de señal. Estas diferencias justifican el uso de la fusión sensorial como una estrategia para obtener estimaciones de posición más precisas que las que se conseguirían utilizando cada fuente de información de forma independiente [8].

El inconveniente radica en que la manera de combinar ambas fuentes no resulta sencilla. Los esquemas de fusión habituales tienden a otorgar a cada sensor un nivel de confianza definido mediante parámetros fijos o reglas previamente establecidas, lo que presume implícitamente que las condiciones de operación permanecen estables. Tal suposición no se satisface en un recorrido vial: la confiabilidad de la cámara y la del GPS cambian de manera independiente y en cuestión de segundos, en función de la iluminación, la textura de la escena, el tráfico circundante y la visibilidad del cielo. Un esquema de parámetros fijos debe, por lo tanto, optar por un punto intermedio que resulta conservador cuando las condiciones son favorables e insuficiente cuando son desfavorables.

Las estrategias de aprendizaje por refuerzo brindan una opción para resolver dicha restricción, debido a que posibilitan el entrenamiento de una política que determina, en función del estado observado, el peso correspondiente a cada fuente de datos en cada

momento [22]. Investigaciones recientes en el campo han demostrado que balancear las aportaciones de diversos sensores con agentes optimizados por refuerzo eleva la exactitud del posicionamiento frente a esquemas de ponderación estática [11, 29], validando así la idoneidad de la metodología seleccionada en esta iniciativa.

No obstante, la utilidad práctica de una estrategia de fusión de este tipo está condicionada a su capacidad para operar a la velocidad requerida durante la navegación. Un sistema de localización resulta útil para apoyar o dirigir el desplazamiento únicamente si genera estimaciones mientras el agente continúa en movimiento. Esto exige que el procesamiento de las imágenes, la integración de las mediciones GPS y las decisiones tomadas por el agente de aprendizaje por refuerzo se realicen dentro de un intervalo de tiempo limitado para cada cuadro. Esta condición no queda reflejada al evaluar el sistema de manera diferida sobre datos registrados previamente, puesto que, en ese escenario, el tiempo de procesamiento no impone restricciones sobre el comportamiento observado. Por consiguiente, evaluar el sistema en condiciones de funcionamiento continuo permite obtener información sobre su desempeño que no es posible determinar únicamente mediante el análisis diferido.

Evidencia de la situación. Como antecedente de este proyecto se dispone de una plataforma experimental previa que combina un módulo de SLAM visual monocular fundamentado en características ORB con un esquema de fusión de datos GPS, en el que un agente de aprendizaje por refuerzo modifica la ponderación otorgada a cada fuente a partir de indicadores de confianza visual y de confianza del GPS. Dicha plataforma funciona de manera diferida sobre secuencias de un conjunto de datos vehicular público, utilizando mediciones GPS a las que se incorpora ruido de forma controlada para aproximar el comportamiento de un receptor de dispositivo móvil, y presenta sus resultados mediante las métricas *Absolute Trajectory Error* (ATE) y *Relative Pose Error* (RPE) en contraste con el SLAM visual sin fusión. Los resultados alcanzados evidencian que el enfoque disminuye el error de trayectoria respecto a la estimación puramente visual, lo que ratifica el potencial de la estrategia de fusión adaptativa.

Aun así, este sistema exhibe dos deficiencias fundamentales que configuran el núcleo del problema de investigación. Por un lado, nunca se ha implementado bajo exigencias de tiempo real, por lo que no hay constancia de que su enfoque de integración mantenga la efectividad ante un margen de cómputo estrictamente limitado por fotograma. Por otro lado, su validación previa se ha limitado a conjuntos de datos almacenados y ruido satelital artificial, lo que impide conocer su comportamiento frente a trayectorias y mediciones reales capturadas directamente en carretera mediante un dispositivo móvil. Superar ambas deficiencias implica rediseñar la arquitectura para el funcionamiento continuo, aplicar las optimizaciones correspondientes y someter el sistema a una validación experimental en recorridos viales controlados.

Por último, abordar esta problemática aporta beneficios que van más allá del escenario específico analizado. Como resultado, el proyecto proporciona una plataforma experi-

mental modular basada en sensores de uso común, que estará disponible para la Escuela de Ingeniería en Computadores como punto de partida para futuras investigaciones en localización inteligente, percepción del entorno y fusión sensorial. Asimismo, ofrece documentación sobre los efectos de incorporar aprendizaje por refuerzo al proceso de fusión de información en condiciones de funcionamiento en tiempo real.

1.2.3 Enunciado del problema

La plataforma experimental existente evidencia que una estrategia de fusión adaptativa fundamentada en aprendizaje por refuerzo disminuye el error de localización de un sistema SLAM visual monocular, aunque lo hace trabajando sobre datos previamente grabados, por lo que su desempeño bajo las restricciones de cómputo que implica operar en tiempo real, y con datos capturados directamente en carretera, sigue sin establecerse. Partiendo de esta circunstancia, el problema que atiende el presente proyecto se plantea del siguiente modo: ¿Cómo diseñar e implementar una plataforma SLAM híbrida en tiempo real basada en visión computacional, datos GPS y aprendizaje por refuerzo, que permita reducir los errores de localización presentes en sistemas SLAM tradicionales durante recorridos controlados en carretera?

1.3 Objetivos del proyecto

A partir de la problemática planteada en el apartado previo, se establecen las metas que guían la ejecución del proyecto. El objetivo general define la meta final que se busca alcanzar, en tanto que los propósitos específicos fragmentan dicho logro en cuatro fases comprobables por separado.

1.3.1 Objetivo general

Desarrollar una plataforma SLAM híbrida capaz de operar en tiempo real mediante la combinación de visión computacional, datos GPS y aprendizaje por refuerzo, con el propósito de incrementar la precisión y estabilidad de la localización durante recorridos viales controlados.

1.3.2 Objetivos específicos

- Sintetizar un listado de requerimientos funcionales, computacionales y temporales para la operación en tiempo real de un sistema SLAM híbrido basado en visión y GPS, a partir de la revisión de literatura científica y documentación técnica del área, validado mediante criterio de experto.

- Diseñar una plataforma SLAM híbrida que combine procesamiento visual y datos GPS para la localización en tiempo real.
- Desarrollar un mecanismo de aprendizaje por refuerzo que permita optimizar de forma adaptativa el proceso de fusión sensorial.
- Valorar experimentalmente el desempeño del sistema por medio de métricas de precisión, estabilidad y rendimiento computacional.

1.4 Alcances, entregables y limitaciones del proyecto

En este apartado se delimitan los compromisos asumidos por el proyecto. Primeramente se define su cobertura, especificando tanto los aspectos incluidos como aquellos excluidos de forma intencional; a continuación se enlistan los productos asociados a cada meta específica; y por último se exponen las restricciones que condicionan los hallazgos logrados.

1.4.1 Alcances

El proyecto comprende el diseño y desarrollo de una plataforma SLAM híbrida operativa en tiempo real, que utiliza información visual capturada mediante una cámara monocular, datos GPS y mediciones del giroscopio provenientes de un dispositivo móvil. Este alcance contempla la implementación de los módulos responsables de capturar imágenes, procesar la información visual, estimar la escala métrica mediante un modelo preentrenado de profundidad monocular, obtener y filtrar las mediciones GPS y del giroscopio, sincronizar temporalmente las fuentes de datos e integrar la información recopilada para generar una estimación unificada de la posición.

El proyecto comprende asimismo el desarrollo y la integración del mecanismo de aprendizaje por refuerzo encargado de la fusión adaptativa, lo cual abarca la definición del estado que percibe el agente, la acción mediante la cual modifica la ponderación de las mediciones en el filtro de fusión, su entrenamiento y la optimización requerida para que dicha decisión se adopte dentro del presupuesto de tiempo disponible por cada cuadro de video.

Por último, el alcance contempla la comprobación experimental del sistema a través de trayectos controlados en vías públicas y el cotejo de su rendimiento frente a un método fundamentado exclusivamente en SLAM visual. Dicha evaluación se efectúa sobre indicadores de exactitud en el posicionamiento, desviación acumulada de la trayectoria, firmeza de la estimación, tasa de actualización y consumo de recursos de cómputo.

El proyecto no contempla la fabricación de un vehículo autónomo ni la incorporación de la plataforma en uno existente. Asimismo, se excluye el desarrollo de funciones para la planificación de trayectorias y el control del vehículo, dado que el trabajo se centra exclusivamente en la estimación de la posición y la generación de un mapa del entorno.

De igual manera, no se incluye la evaluación del sistema en escenarios de operación no controlados ni su implementación como un producto destinado a entornos de producción. El resultado esperado consiste en una plataforma experimental, respaldada por evidencia que permita analizar el impacto de la estrategia de fusión propuesta.

1.4.2 Entregables

La Tabla 2 muestra los entregables correspondientes a cada objetivo específico del proyecto.

Tabla 2: Entregables asociados a cada objetivo específico

Objetivo	**Entregables**
OE1	Documento de requerimientos funcionales, computacionales y temporales de la plataforma. Definición de las métricas de evaluación que se emplearán en la validación experimental.
OE2	Documento de arquitectura del sistema, con la descripción de sus módulos y de las interfaces entre ellos. Plataforma SLAM híbrida funcional, capaz de operar con información visual y datos GPS.
OE3	Módulo de aprendizaje por refuerzo funcional e integrado a la plataforma. Configuración de entrenamiento del agente, incluyendo la definición del estado observado y de la señal de recompensa utilizada.
OE4	Resultados experimentales obtenidos de los recorridos controlados en carretera. Informe de evaluación con el análisis comparativo frente al enfoque basado únicamente en SLAM visual.

Por otra parte, la iniciativa comprende entre sus entregables este documento de Trabajo Final de Graduación, junto con el material requerido para su exposición y defensa ante la comisión evaluadora.

1.4.3 Limitaciones del proyecto

La plataforma emplea exclusivamente los sensores de un dispositivo móvil para obtener la información necesaria: una cámara monocular, un receptor GPS y el giroscopio. Esta elección permite mantener el costo del sistema dentro del rango de un dispositivo móvil convencional; sin embargo, supone que la estimación carece de una referencia métrica directa para determinar la escala, que se obtiene de un modelo de profundidad aprendido.

En particular, de la unidad de medición inercial (IMU) solo se utiliza el giroscopio, para medir el cambio de rumbo; el acelerómetro se emplea únicamente para estimar la vertical y no para estimar la posición ni la velocidad. La ausencia de una integración inercial

completa restringe la aptitud del sistema para mantener la estimación a lo largo de intervalos en los que la información visual y la satelital se degradan de manera prolongada: el sistema conserva el rumbo, pero no dispone de una medición independiente de la distancia recorrida, situación que en otros trabajos se resuelve justamente por medio de la integración inercial.

Tampoco se utiliza ROS (*Robot Operating System*) como framework de integración. Los bloques interactúan a través de un diseño personalizado, lo cual facilita la implementación y la gestión de la sincronización temporal del software, aunque disminuye la viabilidad de aprovechar directamente módulos ya existentes en dicho ecosistema.

Por último, las pruebas del sistema se circunscriben a recorridos controlados, cuyas rutas y condiciones de ejecución se establecen previamente. En consecuencia, los resultados reflejan el desempeño de la plataforma en dichos escenarios y no pueden generalizarse a cualquier entorno vial, especialmente a aquellos con una mayor densidad de tráfico o condiciones ambientales considerablemente diferentes.

Capítulo 2

Marco teórico

2.1 Introducción

El problema formulado en el capítulo previo conjuga elementos procedentes de ámbitos diversos. La estimación del movimiento a partir de imágenes corresponde a la visión computacional; la medición del giro del vehículo, a los sensores inerciales; la obtención de una referencia absoluta de posición proviene de la navegación por satélite; la forma de combinar estas fuentes compete a la fusión de sensores; y el mecanismo que ajusta dicha combinación se sustenta en el aprendizaje por refuerzo. A ello se añade la restricción de operar en tiempo real, la cual condiciona las decisiones de diseño en todos los componentes mencionados.

Este apartado agrupa las bases teóricas de dichos componentes. Cada noción se expone mediante su respectivo planteamiento matemático, los algoritmos que la concretan y, de ser útil para su entendimiento, un esquema ilustrativo del flujo de información. El principio de selección se basó en la utilidad: se incorpora exclusivamente aquello que posteriormente se utiliza para respaldar una opción de diseño, examinar un resultado empírico o entender una restricción del sistema.

En la Sección 2.2 se expone el mapa conceptual del capítulo, cuyos nodos se corresponden directamente con las secciones que lo conforman. Las Secciones 2.3 y 2.4 explican los fundamentos de la localización y el mapeo simultáneos, así como su aplicación mediante visión monocular. Por su parte, las Secciones 2.5 y 2.6 describen los sistemas de posicionamiento satelital y los sensores inerciales, mientras que la Sección 2.7 aborda la integración de estas fuentes de información mediante el filtro de Kalman. A su vez, la Sección 2.8 examina el aprendizaje por refuerzo como una herramienta para adaptar el proceso de fusión. Finalmente, las Secciones 2.9 y 2.10 presentan los aspectos relacionados con la ejecución en tiempo real y las métricas empleadas para evaluar las trayectorias estimadas.

A lo largo del capítulo, los escalares se escriben en cursiva, los vectores en negrita minúscula y las matrices en negrita mayúscula. El superíndice $\top$ señala transposición, $\mathbf{I}$ la matriz identidad y $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ una distribución normal con media $\boldsymbol{\mu}$ y covarianza $\boldsymbol{\Sigma}$.

2.2 Mapa conceptual

La Fig. 1 ilustra los conceptos abordados en este capítulo y los vínculos existentes entre ellos. Cada nodo representa un apartado y cada flecha se encuentra etiquetada con la conexión que enlaza a ambos temas.

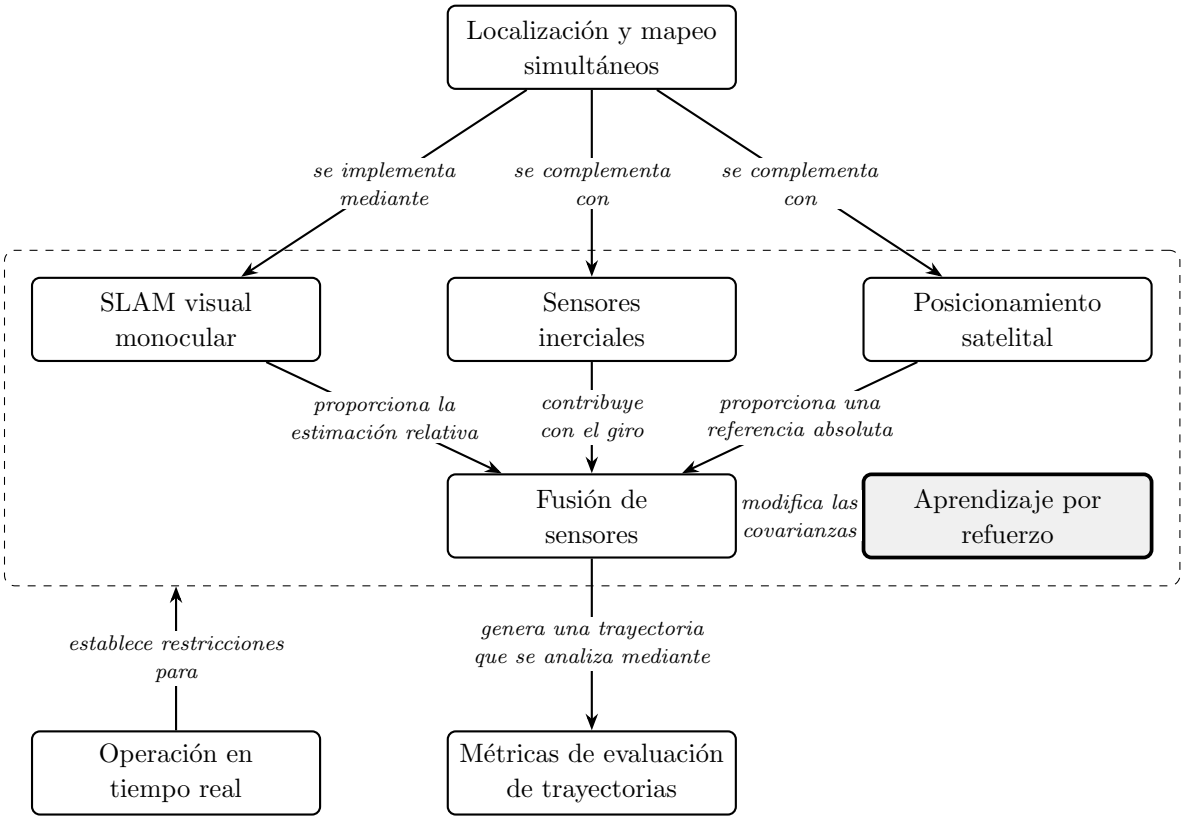


Fig. 1: Mapa conceptual del marco teórico. Cada nodo corresponde a una sección del capítulo. Fuente: elaboración propia.

El mapa se estructura en torno a la noción de localización y mapeo simultáneos, la cual ocupa la sección superior. El presente trabajo la aborda a través de su modalidad visual monocular y la complementa con los sensores inerciales del teléfono y con el posicionamiento satelital. La fuente visual y la satelital poseen una naturaleza contrapuesta: la primera genera una estimación relativa, precisa a corto plazo pero propensa a la deriva, y la segunda una referencia absoluta, exenta de deriva pero ruidosa. Los sensores inerciales suministran el giro del vehículo, el cual miden sin depender de la escena ni de la señal satelital. Las tres fuentes confluyen en la fusión de sensores, donde se integran en una estimación única. El aprendizaje por refuerzo se vincula con la fusión mediante las covarianzas de ruido del filtro, que constituye el punto en el que este trabajo propone intervenir, y por ello se resalta con trazo grueso. La trayectoria obtenida se evalúa con las métricas de la sección inferior. Por último, la operación en tiempo real no se representa como una etapa adicional, sino como una condición que incide sobre todo el procesamiento delimitado por la línea discontinua.

2.3 Localización y mapeo simultáneos

La localización y el mapeo simultáneos, abreviados como SLAM, consisten en calcular de manera conjunta la ruta de un agente móvil y un plano del escenario recorrido, basándose exclusivamente en las lecturas de los dispositivos que transporta [2]. El término *simultáneos* denota la dependencia mutua entre ambos cálculos: situar un objeto del entorno requiere conocer el punto de observación, al tiempo que determinar la posición del vehículo demanda un mapa de referencia. Por este motivo, ninguno de los dos parámetros puede resolverse de forma anticipada, sino que ambos se abordan como variables conjuntas de un mismo problema de estimación.

2.3.1 Representación probabilística

Debido a que las mediciones están sujetas a incertidumbre, el problema de SLAM se formula desde un enfoque probabilístico [26]. Se representa mediante $\mathbf{x}_t$ la pose del agente en el instante t, que comprende su posición y orientación; mediante $\mathbf{m}$, el mapa del entorno; mediante $\mathbf{u}_t$, la información relativa al movimiento entre los instantes $t-1$ y t; y mediante $\mathbf{z}_t$, las observaciones obtenidas en el instante t. La interacción entre estas variables se establece a través de dos modelos probabilísticos. El modelo de movimiento $p(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{u}_t)$ describe la evolución de la pose del agente, mientras que el modelo de observación $p(\mathbf{z}_t \mid \mathbf{x}_t, \mathbf{m})$ representa las mediciones que se esperan obtener cuando el agente se encuentra en una pose determinada dentro de un mapa conocido [26].

Con estos elementos se identifican dos maneras de formular la estimación. La formulación completa persigue la distribución conjunta de la trayectoria entera y el mapa,

$$p(\mathbf{x}_{1:t}, \mathbf{m} \mid \mathbf{z}_{1:t}, \mathbf{u}_{1:t}), \tag{2.1}$$

en tanto que la formulación en línea persigue solamente la pose actual y el mapa, y se alcanza marginalizando las poses previas [26]:

$$p(\mathbf{x}_t, \mathbf{m} \mid \mathbf{z}_{1:t}, \mathbf{u}_{1:t}) = \int \cdots \int p(\mathbf{x}_{1:t}, \mathbf{m} \mid \mathbf{z}_{1:t}, \mathbf{u}_{1:t})\, d\mathbf{x}_1 \cdots d\mathbf{x}_{t-1}. \tag{2.2}$$

La formulación completa posibilita corregir poses anteriores cuando arriba información nueva, mientras que la formulación en línea es la que resuelven los filtros recursivos, como el filtro de Kalman de la Sección 2.7.

En la práctica, la estimación suele plantearse como la búsqueda del valor más probable de las variables, conocido como estimador de máximo a posteriori. Si se agrupan todas las variables por estimar en $\mathcal{X}$ y todas las mediciones en $\mathcal{Z} = \{\mathbf{z}_k\}$, donde cada observación depende únicamente de un subconjunto $\mathcal{X}_k$ de las variables, se tiene que [2]

$$\mathcal{X}^* = \arg\max_{\mathcal{X}} \; p(\mathcal{X}) \prod_k p(\mathbf{z}_k \mid \mathcal{X}_k). \tag{2.3}$$

Cuando cada lectura se modela como $\mathbf{z}_k = h_k(\mathcal{X}_k) + \boldsymbol{\epsilon}_k$, con ruido gaussiano $\boldsymbol{\epsilon}_k \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Omega}_k^{-1})$, y la distribución a priori se contempla como una medición adicional, aplicar el logaritmo negativo a la Ecuación (2.3) deriva en un problema de mínimos cuadrados no lineales [2]:

$$\mathcal{X}^* = \arg\min_{\mathcal{X}} \sum_k \|h_k(\mathcal{X}_k) - \mathbf{z}_k\|^2_{\boldsymbol{\Omega}_k}, \qquad \|\mathbf{e}\|^2_{\boldsymbol{\Omega}} = \mathbf{e}^\top \boldsymbol{\Omega}\, \mathbf{e}, \tag{2.4}$$

en donde h_k representa la función encargada de predecir la medición a partir de los estados y $\boldsymbol{\Omega}_k$ corresponde a la matriz de información, equivalente a la inversa de la covarianza del error. Esta formulación resulta fundamental para el resto del apartado, ya que evidencia que el impacto de cada observación sobre el resultado final está gobernado por su respectiva matriz de información: a mayor incertidumbre asociada a una lectura, menor será su ponderación en la solución.

2.3.2 Arquitectura: procesamiento frontal y posterior

Los sistemas SLAM se estructuran en dos componentes que desempeñan funciones diferenciadas, como se muestra en la Fig. 2 [2]. El procesamiento frontal (*front-end*) convierte las mediciones originales de los sensores en restricciones expresadas según la Ecuación (2.4). Para ello, identifica características relevantes en las mediciones, determina cuáles observaciones pertenecen a un mismo elemento del entorno y genera una estimación inicial. Por su parte, el procesamiento posterior (*back-end*) utiliza las restricciones obtenidas para calcular una solución global que se ajuste de la mejor manera posible a todas ellas, distribuyendo los errores entre las distintas restricciones en lugar de permitir que se acumulen.

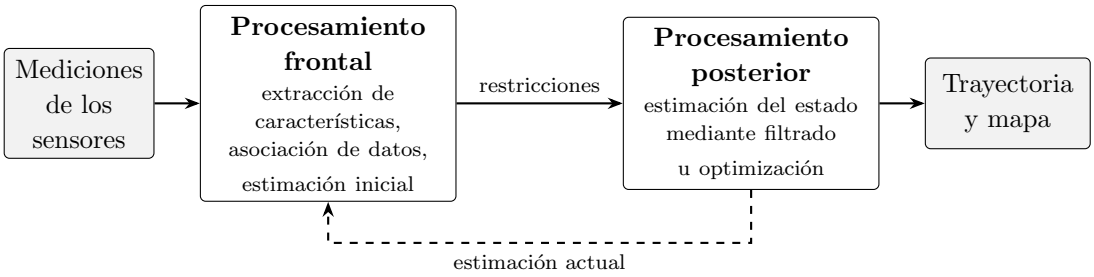


Fig. 2: Arquitectura de un sistema SLAM. La línea discontinua indica que el procesamiento frontal utiliza la estimación vigente para asociar nuevas observaciones. Fuente: elaboración propia con base en [2].

El procesamiento frontal varía según el tipo de sensor y constituye el punto donde se generan la mayor parte de los errores cuando las condiciones de observación se deterioran. El procesamiento posterior, por su parte, trabaja sobre relaciones geométricas abstractas y resulta en gran medida independiente del sensor.

El tratamiento posterior contempla dos perspectivas [2]. La primera aborda la expresión completa de la Ecuación (2.1) a través de la optimización: las poses de un grupo selecto

de cuadros representativos, llamados cuadros clave, se estructuran en un grafo cuyas aristas representan restricciones entre pares de poses, resolviendo la Ecuación (2.4) de manera iterativa en toda la red [7]. Esta alternativa posibilita la corrección de poses anteriores al recibir datos novedosos, como ocurre al identificar un sitio previamente recorrido, aunque su carga computacional se incrementa conforme se acumulan más poses. La segunda resuelve la modalidad secuencial de la Ecuación (2.2) mediante filtrado: en cada paso temporal actualiza exclusivamente la estimación actual junto con su respectiva incertidumbre, manteniendo un costo computacional acotado por cuadro. La iteración anterior del sistema estructuraba las poses en un grafo de cuadros clave provisto de una fase opcional de optimización; por su parte, la plataforma en tiempo real propuesta en este estudio adopta el método de filtrado a través del mecanismo descrito en la Sección 2.7.

2.4 SLAM visual monocular

Cuando el sistema utiliza una única cámara como sensor principal, se conoce como SLAM visual monocular. Esta configuración es de interés debido a que las cámaras son dispositivos económicos, livianos y de bajo consumo energético, capaces de proporcionar más información por medición que otros tipos de sensores [18]. El procesamiento frontal comprende una secuencia de operaciones: identificar y describir puntos característicos en cada imagen, establecer correspondencias entre distintas imágenes, calcular el desplazamiento relativo de la cámara y reconstruir las coordenadas tridimensionales de dichos puntos. Si el sistema únicamente enlaza los movimientos calculados entre cuadros consecutivos, sin generar ni aprovechar un mapa del entorno, esta técnica se denomina odometría visual [18]. Este enfoque corresponde al utilizado por la plataforma desarrollada en este trabajo, que calcula el movimiento entre cuadros y emplea la triangulación para comprobar cada pose estimada y determinar la escala. En esta sección se explica cada una de estas etapas, se analizan las dos limitaciones características de los sistemas monoculares y, finalmente, se describe el procedimiento empleado por la plataforma para obtener una escala métrica.

2.4.1 Modelo de cámara estenopeica

El vínculo entre un punto del espacio y su imagen se describe por medio del modelo de cámara estenopeica, ilustrado en la Fig. 3 [9]. Un punto con coordenadas homogéneas $\tilde{\mathbf{X}} = [X, Y, Z, 1]^\top$ en el sistema del mundo se proyecta sobre el píxel $\tilde{\mathbf{y}} = [u, v, 1]^\top$ de acuerdo con

$$Z_c\,\tilde{\mathbf{y}} = \mathbf{K}\,[\,\mathbf{R} \mid \mathbf{t}\,]\,\tilde{\mathbf{X}}, \qquad \mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}, \tag{2.5}$$

en donde $\mathbf{R}$ y $\mathbf{t}$ son la rotación y la traslación que trasladan el punto al sistema de la cámara, Z_c es su profundidad en dicho sistema, y $\mathbf{K}$ es la matriz de parámetros intrínsecos, compuesta por las distancias focales f_x, f_y y el punto principal (c_x, c_y), ambos expresa-

dos en píxeles [9]. Las coordenadas normalizadas $\bar{\mathbf{y}} = \mathbf{K}^{-1}\tilde{\mathbf{y}}$ suprimen el efecto de los parámetros intrínsecos y son las que se utilizan en la geometría de dos vistas. El modelo no toma en cuenta la distorsión que provocan las lentes reales, la cual desplaza la imagen de los puntos alejados del centro [9]; en este trabajo se emplea sin términos de distorsión.

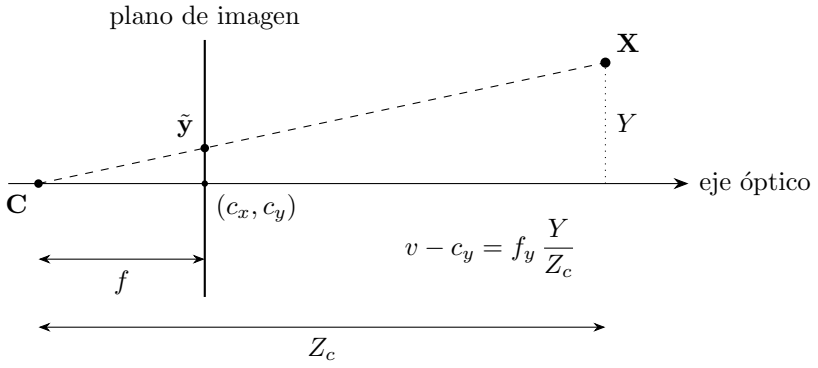


Fig. 3: Modelo de cámara estenopeica en vista lateral. La coordenada de la imagen depende del cociente Y/Z_c, por lo que la profundidad se pierde en la proyección. Fuente: elaboración propia con base en [9].

La Fig. 3 evidencia una consecuencia que se retoma en la Sección 2.4.6: la posición dentro de la imagen está determinada por el cociente entre la coordenada transversal y la profundidad, de suerte que un objeto con el doble de dimensiones y ubicado al doble de distancia genera exactamente la misma proyección visual.

2.4.2 Detección y descripción de características ORB

Operar con un conjunto acotado de puntos característicos, en vez de la imagen completa, disminuye el volumen de datos que el sistema debe procesar, lo cual se vuelve imprescindible cuando existe una restricción de tiempo. La plataforma utiliza características ORB, que conjugan un detector de esquinas con un descriptor binario y añaden a ambos la información de orientación requerida para que la descripción no varíe cuando la cámara rota [17].

Detección. El detector FAST [16] clasifica un píxel como una esquina potencial si, dentro de una circunferencia de dieciséis elementos circundantes, existe un arco de píxeles consecutivos cuya intensidad excede a la del punto central por encima de un umbral, o bien es inferior a esta en una diferencia mayor a dicho valor; por su parte, ORB implementa la variante FAST-9 y ordena los candidatos según el criterio de esquina de Harris con el objeto de preservar los más estables [17]. Con el fin de tolerar modificaciones en la escala, la identificación se repite en cada nivel de una pirámide conformada por versiones a menor resolución de la imagen.

Orientación. La orientación de cada punto se determina a partir del centroide de intensidad del parche I que lo rodea. Los momentos calculados sobre el parche y el ángulo

correspondiente se definen como [17]

$$m_{pq} = \sum_{u,v} u^p \, v^q \, I(u,v), \qquad \beta = \operatorname{atan2}(m_{01},\, m_{10}), \tag{2.6}$$

donde β representa el ángulo del vector que conecta el centro del parche con su centroide de intensidad.

Descripción. El descriptor se conforma mediante pruebas binarias que contrastan la intensidad de pares de píxeles del parche suavizado:

$$\tau(I;\mathbf{a},\mathbf{b}) = \begin{cases} 1 & \text{si } I(\mathbf{a}) < I(\mathbf{b}), \\ 0 & \text{en otro caso,} \end{cases} \qquad f_n(I) = \sum_{i=1}^{n} 2^{\,i-1} \, \tau(I;\mathbf{a}_i,\mathbf{b}_i), \tag{2.7}$$

con $n = 256$ pares $(\mathbf{a}_i, \mathbf{b}_i)$ cuyas posiciones se rotan conforme a β antes de ser evaluadas [17]. El resultado consiste en una cadena de 256 bits.

Emparejamiento. Dos descriptores binarios $\mathbf{d}_a$ y $\mathbf{d}_b$ se contrastan a través de la distancia de Hamming,

$$d_H(\mathbf{d}_a, \mathbf{d}_b) = \sum_{i=1}^{n} d_a^{(i)} \oplus d_b^{(i)}, \tag{2.8}$$

donde $\oplus$ representa la operación lógica de disyunción exclusiva. Dicho cálculo se simplifica al conteo de bits sobre el resultado de una instrucción lógica, la cual es ejecutada directamente por el procesador, constituyendo el motivo principal por el que ORB resulta una alternativa frecuente en arquitecturas expuestas a limitaciones temporales.

Para cada descriptor de la primera imagen, se identifican los dos descriptores más próximos de la segunda imagen, cuyas distancias cumplen $d_H^{(1)} \leq d_H^{(2)}$. La correspondencia se considera válida únicamente cuando se satisface la siguiente condición:

$$d_H^{(1)} < \zeta \, d_H^{(2)}, \qquad 0 < \zeta < 1, \tag{2.9}$$

Este procedimiento, denominado prueba de razón, permite filtrar correspondencias ambiguas [13]. En particular, elimina aquellos puntos para los que el mejor candidato presenta una distancia similar a la del segundo, algo frecuente en regiones con patrones visuales repetitivos.

2.4.3 Geometría epipolar y estimación de la pose relativa

Tras emparejar los puntos de dos imágenes, la relación geométrica entre ambas vistas posibilita recuperar el movimiento de la cámara. Tal como se aprecia en la Fig. 4, los dos centros de cámara y el punto observado determinan un plano, denominado plano epipolar, que intersecta a cada plano de imagen en una recta; el punto observado en una imagen ha de localizarse, en la otra, sobre dicha recta [9].

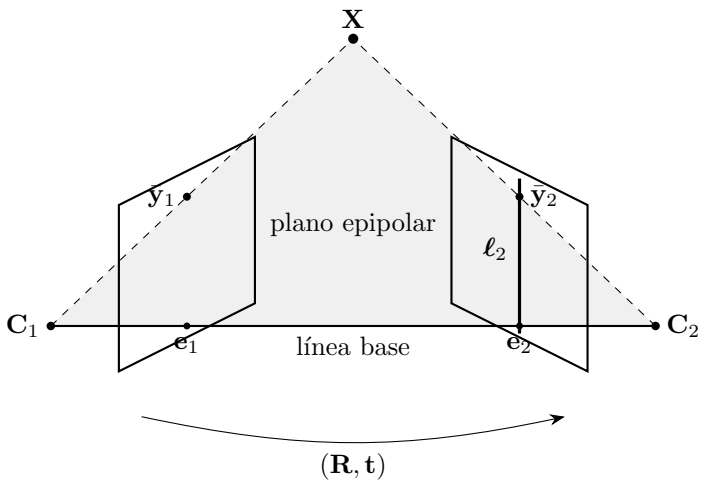


Fig. 4: Geometría epipolar entre dos vistas. El punto $\bar{\mathbf{y}}_2$ correspondiente a $\bar{\mathbf{y}}_1$ debe encontrarse sobre la recta epipolar $\boldsymbol{\ell}_2$; $\mathbf{e}_1$ y $\mathbf{e}_2$ son los epipolos. Fuente: elaboración propia con base en [9].

Dicha condición se formula de manera algebraica por medio de la matriz esencial $\mathbf{E}$, la cual vincula las coordenadas normalizadas de un mismo punto en ambas vistas [9]:

$$\bar{\mathbf{y}}_2^{\top}\,\mathbf{E}\,\bar{\mathbf{y}}_1 = 0, \qquad \mathbf{E} = [\mathbf{t}]_{\times}\,\mathbf{R}, \qquad [\mathbf{t}]_{\times} = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ -t_y & t_x & 0 \end{bmatrix}, \tag{2.10}$$

en donde $\mathbf{R}$ y $\mathbf{t}$ corresponden a la orientación y al desplazamiento relativos entre ambas cámaras. Cada correspondencia suministra una ecuación lineal respecto a los componentes de $\mathbf{E}$, de tal manera que la matriz es factible de estimarse a partir de un conjunto reducido de asociaciones. Posteriormente, esta se procesa mediante una descomposición en valores singulares, $\mathbf{E} = \mathbf{U}\,\mathrm{diag}(1, 1, 0)\mathbf{V}^{\top}$, lo cual genera cuatro posibles pares $(\mathbf{R}, \mathbf{t})$; siendo el válido aquel único caso donde los puntos tridimensionales recuperados se sitúan frente a ambas cámaras [9]. Puesto que la Ecuación (2.10) se satisface de igual manera al multiplicar $\mathbf{t}$ por un factor escalar arbitrario, el desplazamiento solo puede determinarse en cuanto a su dirección, por lo que se normaliza fijando $\|\mathbf{t}\| = 1$.

2.4.4 Estimación robusta mediante RANSAC

El proceso de emparejamiento genera inevitablemente correspondencias erróneas, debido a patrones visuales repetitivos, objetos en movimiento entre capturas o variaciones en las condiciones de iluminación. Si se aplicara un ajuste por mínimos cuadrados utilizando todas las correspondencias, los valores atípicos podrían distorsionar significativamente la estimación. Para reducir este efecto, el método RANSAC estima el modelo de manera iterativa a partir de subconjuntos mínimos seleccionados aleatoriamente y conserva aquel que presenta concordancia con el mayor número de correspondencias, tal como se describe en el Algoritmo 1 [4].

Algoritmo 1 RANSAC aplicado a la estimación de la matriz esencial. Fuente: elaboración propia con base en [4, 9].

Entrada: correspondencias $\mathcal{C}$, tamaño de muestra mínima $n_{\min}$, umbral de error δ, número de iteraciones N_{it}
Salida: matriz esencial $\mathbf{E}^*$ y conjunto de correspondencias consistentes $\mathcal{I}^*$

$\mathcal{I}^* \leftarrow \emptyset$
para $i = 1, \ldots, N_{\text{it}}$ **hacer**
  seleccionar al azar $\mathcal{M} \subset \mathcal{C}$ con $|\mathcal{M}| = n_{\min}$
  estimar $\mathbf{E}_i$ a partir de $\mathcal{M}$ mediante la Ecuación (2.10)
  $\mathcal{I}_i \leftarrow \{\, c \in \mathcal{C} \;:\; \text{err}(c, \mathbf{E}_i) < \delta \,\}$
  si $|\mathcal{I}_i| > |\mathcal{I}^*|$ **entonces**
    $\mathcal{I}^* \leftarrow \mathcal{I}_i$
  fin si
fin para
reestimar $\mathbf{E}^*$ con todas las correspondencias de $\mathcal{I}^*$
devolver $\mathbf{E}^*$, $\mathcal{I}^*$

La cantidad de iteraciones requerida para que, con probabilidad p, al menos una muestra carezca de valores atípicos depende de la proporción η de correspondencias correctas y del tamaño de la muestra [9]:

$$N_{\text{it}} = \left\lceil \frac{\log(1-p)}{\log(1-\eta^{\,n_{\min}})} \right\rceil . \tag{2.11}$$

La Ecuación (2.11) evidencia que el costo de RANSAC se incrementa con rapidez a medida que se reduce la proporción de correspondencias correctas, lo cual sucede justamente en escenas degradadas. Asimismo, el tamaño de $\mathcal{I}^*$ constituye un indicador directo de la calidad de la estimación en ese instante.

2.4.5 Triangulación

Una vez determinado el desplazamiento relativo, las coordenadas tridimensionales de cada elemento se obtienen mediante el proceso de triangulación. Si $\mathbf{M}_1 = \mathbf{K}[\,\mathbf{I} \mid \mathbf{0}\,]$ y $\mathbf{M}_2 = \mathbf{K}[\,\mathbf{R} \mid \mathbf{t}\,]$ representan las matrices de proyección correspondientes a ambas perspectivas, el punto $\tilde{\mathbf{X}}$ ha de cumplir que $\tilde{\mathbf{y}}_1 \times (\mathbf{M}_1\tilde{\mathbf{X}}) = \mathbf{0}$ y $\tilde{\mathbf{y}}_2 \times (\mathbf{M}_2\tilde{\mathbf{X}}) = \mathbf{0}$. Dichas restricciones configuran un sistema de ecuaciones lineales homogéneas $\mathbf{A}\tilde{\mathbf{X}} = \mathbf{0}$, cuya resolución se alcanza calculando el vector singular correspondiente al valor singular mínimo de $\mathbf{A}$ [9].

Un punto reconstruido mediante triangulación se considera válido únicamente cuando se encuentra delante de ambas cámaras, lo que implica que su profundidad Z_c debe ser positiva en las dos vistas. Este mismo principio permite seleccionar, entre las cuatro soluciones obtenidas al descomponer $\mathbf{E}$, el par $(\mathbf{R}, \mathbf{t})$ que representa el movimiento correcto [9]. La exactitud de la triangulación también está condicionada por el paralaje, definido como el

ángulo formado por los dos rayos que convergen en el punto. Si la línea base es pequeña en comparación con la distancia al punto observado, los rayos presentan direcciones casi paralelas, por lo que incluso una pequeña imprecisión en la imagen puede generar un error considerable en la profundidad estimada [9]. Por este motivo, la triangulación entre cuadros consecutivos puede resultar poco fiable en un vehículo, ya que este recorre una distancia reducida entre capturas mientras observa puntos ubicados a decenas de metros. En consecuencia, resulta conveniente utilizar imágenes separadas por un intervalo mayor. El número de puntos que cumplen estas condiciones permite evaluar si la geometría de la escena ofrece información suficiente para estimar el movimiento de manera confiable. Estos criterios son los que aplica la estimación de escala de la Sección 2.4.7, que triangula entre cuadros separados y descarta los puntos con poco paralaje.

2.4.6 Deriva y ambigüedad de escala

La configuración monocular tiene dos limitaciones que resultan determinantes para este proyecto.

Deriva. La pose de la cámara se consigue componiendo los movimientos relativos calculados entre cuadros consecutivos. Si $\mathbf{T}_k = \left[\begin{smallmatrix} \mathbf{R}_k & \mathbf{t}_k \\ \mathbf{0}^\top & 1 \end{smallmatrix}\right]$ denota la pose en el cuadro k y $\mathbf{T}_{k-1,k}$ el movimiento estimado entre los cuadros $k-1$ y k, entonces [18]

$$\mathbf{T}_k = \mathbf{T}_{k-1}\,\mathbf{T}_{k-1,k} = \mathbf{T}_0 \prod_{i=1}^{k} \mathbf{T}_{i-1,i}. \tag{2.12}$$

Cada factor del producto alberga un error de estimación, y la composición hace que dichos errores se propaguen sin ser corregidos. Incluso si cada paso resulta preciso, la trayectoria estimada se aleja de manera progresiva de la real a medida que crece la distancia recorrida.

Ambigüedad de escala. Si un determinado grupo de poses y puntos tridimensionales $\{\mathbf{R}_k, \mathbf{t}_k, \mathbf{X}_j\}$ resulta consistente con todas las vistas capturadas, de igual manera lo es el conjunto $\{\mathbf{R}_k, s\,\mathbf{t}_k, s\,\mathbf{X}_j\}$ para cualquier parámetro $s > 0$, dado que la proyección descrita en la Ecuación (2.5) divide entre la profundidad y dicho factor se anula. Por consiguiente, la trayectoria obtenida mediante visión monocular queda determinada salvo por un coeficiente de escala desconocido, el cual puede además experimentar variaciones graduales a lo largo del trayecto [15, 18]. Establecer dicho valor de escala demanda información ausente en la geometría de las imágenes, tales como lecturas de distancia proporcionadas por un sensor alternativo o información previa acerca del escenario.

Estas dos limitaciones se vuelven más pronunciadas en entornos viales. Las variaciones de iluminación, las superficies con escasa textura y la presencia de objetos en movimiento disminuyen la proporción η de correspondencias válidas, lo que afecta a cada factor de la Ecuación (2.12) y favorece una acumulación más rápida del error.

2.4.7 Escala métrica a partir de profundidad monocular

Una manera de conseguir esa información sin acudir a otro sensor consiste en utilizar una red neuronal entrenada para estimar la profundidad de cada píxel a partir de una única imagen. Tales modelos aprenden la relación entre la apariencia y la profundidad a partir de grandes conjuntos de imágenes, y algunas de sus variantes se ajustan con datos que incorporan la profundidad real, de manera que su salida se expresa en metros [30]. Su estimación resulta menos precisa que una medición directa, pero no se deriva de la geometría entre vistas y, por consiguiente, no comparte la ambigüedad descrita en la Sección 2.4.6.

El sistema integra ambas fuentes de estimación de profundidad. Al considerar dos cuadros separados por un intervalo Δt_b que garantice la presencia de paralaje, la triangulación basada en una traslación unitaria $\|\mathbf{t}\| = 1$ genera profundidades Z_j^{VO} expresadas en unidades de la propia línea base, al tiempo que el modelo predice para esos mismos puntos valores de profundidad Z_j^{m} medidos en metros. Por consiguiente, la relación entre ambos valores corresponde a la longitud de la línea base expresada en metros, la cual se calcula empleando la mediana de los puntos disponibles:

$$\hat{b} = \mathrm{mediana}_j \left(\frac{Z_j^{\mathrm{m}}}{Z_j^{\mathrm{VO}}} \right), \qquad v^{\mathrm{cam}} = \frac{\hat{b}}{\Delta t_b}, \tag{2.13}$$

donde v^{cam} representa la rapidez del vehículo estimada a partir de la cámara. A diferencia de la media aritmética, el uso de la mediana mitiga el impacto de aquellos puntos cuya profundidad se encuentra erróneamente calculada, tales como los correspondientes a elementos en movimiento dentro de la escena. Dicha escala se deriva exclusivamente de la información visual, previniendo así la dependencia estricta de la estimación respecto al GPS: ante una degradación de la señal satelital, la fuente visual mantiene su propia métrica de distancia. No obstante, su margen de error fluctúa según las características del entorno, motivo por el cual el mecanismo de filtrado descrito en la Sección 2.7 incorpora un factor de corrección de escala guiado por las lecturas del sistema satelital.

2.5 Posicionamiento satelital

2.5.1 Principio de operación

Un sistema global de navegación por satélite está formado por una constelación de satélites que emiten señales con información sobre el instante de transmisión y los datos necesarios para determinar su posición. El receptor calcula el tiempo que tarda cada señal en llegar y lo transforma en una distancia aparente conocida como pseudodistancia. Para un satélite i, cuya posición $\mathbf{r}^{(i)}$ es conocida, la pseudodistancia observada se expresa mediante el siguiente modelo [8]

$$\rho^{(i)} = \left\| \mathbf{r}^{(i)} - \mathbf{r} \right\| + c\,\delta t_r + \varepsilon^{(i)}, \tag{2.14}$$

donde $\mathbf{r}$ representa la posición del receptor, c corresponde a la velocidad de la luz, δt_r denota el desfase del reloj del receptor y $\varepsilon^{(i)}$ comprende los demás errores presentes en la medición. El modelo contiene cuatro incógnitas: las tres coordenadas de $\mathbf{r}$ y el desfase temporal δt_r. Por tanto, se necesitan al menos cuatro satélites para resolver el sistema.

El receptor resuelve dicho sistema de manera iterativa, linealizando la Ecuación (2.14) en torno a una posición aproximada y aplicando mínimos cuadrados [8]. Aparte de la posición, calcula la velocidad a partir del desplazamiento Doppler de la frecuencia de las señales recibidas, el cual es proporcional a la velocidad relativa entre el receptor y cada satélite [8]. Dicha velocidad no se consigue derivando posiciones sucesivas, por lo que no hereda de forma directa su error.

2.5.2 Fuentes de error y receptores de dispositivos móviles

El componente $\varepsilon^{(i)}$ presente en la Ecuación (2.14) agrupa los errores remanentes de órbita y oscilador del satélite, el desfasaje temporal ocasionado por la ionosfera y la troposfera, el fenómeno de multitrayecto derivado de rebotes en superficies próximas y el ruido propio del receptor [8]. Asimismo, la exactitud posicional está supeditada a la disposición espacial de los satélites en línea de visión: si dichos satélites se concentran en una zona acotada del firmamento, la estructura matemática se vuelve mal condicionada, provocando la amplificación de los errores de pseudodistancia en el resultado final, un fenómeno cuantificado mediante el índice de dilución de la precisión [8].

Esta fuente de información presenta dos características que la diferencian de la estimación visual. En primer lugar, su error es acotado, ya que no aumenta conforme se incrementa la distancia recorrida, pues cada posición se calcula sin depender de las estimaciones anteriores. En segundo lugar, el error puede alcanzar una magnitud considerable en un momento determinado y conservar una correlación durante varios segundos mientras continúen las condiciones que lo generan.

Los receptores incorporados en teléfonos móviles funcionan bajo el mismo principio que los equipos geodésicos, aunque con limitaciones de costo, tamaño y consumo. Sus antenas utilizan polarización lineal en vez de circular, lo que las hace más propensas al multitrayecto, y la relación entre portadora y ruido de sus observaciones es aproximadamente diez decibelios inferior a la de una antena geodésica [31]. En consecuencia, las soluciones basadas solamente en código alcanzan exactitudes de tres a cinco metros en condiciones favorables, las cuales superan los diez metros en entornos con multitrayecto severo [31]. A esto se añade una asimetría temporal: el receptor proporciona una o pocas soluciones por segundo, en tanto que la cámara genera varias decenas de imágenes en ese mismo intervalo. En tal contexto el GPS no puede considerarse como una referencia verdadera, sino como una segunda estimación con su propio error, cuya confiabilidad fluctúa a lo largo del recorrido.

2.5.3 Conversión a coordenadas métricas

El receptor proporciona coordenadas geodésicas (latitud, longitud y altitud) referidas al elipsoide del marco de referencia WGS 84, en tanto que la estimación visual se formula en un sistema cartesiano local con unidades métricas. Su integración requiere transformar ambas fuentes a un marco de referencia común. Para el análisis en una superficie bidimensional, el procedimiento convencional consiste en emplear la proyección Universal Transversa de Mercator (UTM), la cual segmenta la superficie terrestre en husos de seis grados de longitud y proyecta cada uno de manera independiente, limitando así la distorsión geométrica en cada sección [19]. Sus expresiones analíticas corresponden a desarrollos en serie que se omiten en este documento. Dado que un trayecto que atraviesa la frontera entre dos husos generaría coordenadas en sistemas diferentes, todas las mediciones de una ruta se proyectan en el huso correspondiente al punto de partida, expresándose como componentes de desplazamiento al este y al norte respecto a dicho origen. Esta consideración resulta especialmente relevante en el caso de Costa Rica, cuyo territorio es atravesado por el meridiano de 84° de longitud oeste, el cual marca la frontera entre los husos 16 y 17. Es importante destacar que esta transformación unifica las unidades y el marco de referencia de la observación satelital, mas no alinea ambas fuentes por sí sola: la trayectoria visual se origina en un punto y una orientación arbitrarios, y su escala, aunque se encuentre expresada en metros, conserva el sesgo asociado al modelo de profundidad descrito en la Sección 2.4.7.

2.6 Sensores inerciales

Los teléfonos móviles incorporan sensores inerciales de bajo costo, fabricados con tecnología microelectromecánica. Los dos que interesan en este trabajo son el acelerómetro, que mide la fuerza específica sobre el dispositivo y, por tanto, también la reacción a la gravedad, y el giroscopio, que mide la velocidad angular, ambos sobre los tres ejes del dispositivo [8]. La orientación se obtiene integrando la velocidad angular en el tiempo [8]. En un vehículo terrestre interesa sobre todo el cambio de rumbo, que corresponde a la rotación alrededor de la vertical, y para calcularlo basta la componente de la velocidad angular en esa dirección.

La vertical no se conoce de antemano, dado que el teléfono puede montarse con cualquier inclinación. Una manera sencilla de estimarla se vale de que la gravedad es constante, mientras que las aceleraciones propias del vehículo cambian de signo y se compensan con el tiempo; un filtro paso bajo de primer orden sobre la medición $\mathbf{f}_j$ del acelerómetro preserva la primera y atenúa las segundas:

$$\mathbf{g}_j = \mathbf{g}_{j-1} + \frac{\Delta t_j}{\tau_\mathrm{g}} \left(\mathbf{f}_j - \mathbf{g}_{j-1} \right), \qquad \hat{\mathbf{n}}_j = \frac{\mathbf{g}_j}{\|\mathbf{g}_j\|}, \tag{2.15}$$

donde Δt_j es el tiempo transcurrido entre las muestras $j-1$ y j, y τ_g la constante de tiempo del filtro, del orden de decenas de segundos. Con la vertical $\hat{\mathbf{n}}_j$, el giro acumulado

entre dos cuadros se consigue integrando la componente vertical de las mediciones $\boldsymbol{\omega}_j$ del giroscopio mediante la regla del trapecio,

$$\Delta\psi = \sum_j \tfrac{1}{2} \left(\boldsymbol{\omega}_{j-1} + \boldsymbol{\omega}_j\right)^\top \hat{\mathbf{n}}_j \, \Delta t_j, \tag{2.16}$$

en donde la suma abarca las muestras comprendidas entre ambos cuadros.

El giroscopio registra la velocidad angular con alta precisión en lapsos breves y con absoluta independencia de la escena visual; sin embargo, su lectura incorpora un sesgo de variación lenta que, al integrarse según se indica en la Ecuación (2.16), se traduce en un error de orientación acumulativo que se incrementa con el tiempo [8]. Por su parte, el acelerómetro se descarta como fuente para la estimación directa de la posición: dicho cálculo demandaría una doble integración de la señal tras compensar el efecto de la gravedad, lo cual, al emplear dispositivos de bajo costo, genera un error proporcional al cuadrado del tiempo que supera rápidamente al del GPS [8]. En consecuencia, para el desarrollo de este trabajo se establece una estrategia complementaria donde el giroscopio suministra la variación de rumbo entre cuadros consecutivos, la cámara aporta la estimación de rapidez y el sistema GPS interviene para corregir ambas magnitudes, conforme se detalla en el apartado subsiguiente.

2.7 Fusión de sensores

2.7.1 Complementariedad entre las fuentes

Al comparar las tres fuentes de información, se observa que cada una presenta limitaciones diferentes, lo que permite aprovechar sus fortalezas al combinarlas. La Tabla 3 sintetiza estas diferencias.

Tabla 3: Características complementarias de las fuentes de información

Característica	**Cámara**	**Giroscopio**	**GPS de dispositivo móvil**
Magnitud que aporta	Movimiento relativo y rapidez	Cambio de rumbo	Posición, velocidad Doppler y rumbo entre soluciones
Naturaleza de la estimación	Relativa, respecto a un origen arbitrario	Relativa, respecto al rumbo inicial	Absoluta, respecto a un marco global
Comportamiento del error	Crece con la distancia, Ec. (2.12)	Crece con el tiempo por el sesgo, Ec. (2.16)	Acotado, no crece con el recorrido
Precisión instantánea	Alta entre cuadros consecutivos	Alta en intervalos cortos	Del orden de metros
Frecuencia de actualización	Decenas de cuadros por segundo	Decenas de muestras por segundo	Una o pocas soluciones por segundo
Escala	Aproximada, a partir del modelo de profundidad	No aplica	Métrica por construcción
Condiciones que la degradan	Poca textura, cambios de iluminación, objetos en movimiento	Variación del sesgo durante intervalos largos sin corrección	Obstrucción del cielo, multitrayecto, geometría desfavorable

La última fila constituye la que justifica el enfoque de este trabajo. Las condiciones que degradan una fuente resultan en buena medida independientes de las que degradan las otras: un túnel de vegetación densa obstruye la señal satelital a la vez que enriquece la textura visual, y una carretera abierta brinda buena visibilidad de los satélites junto con una escena pobre en características. El giroscopio, por su parte, no depende de la escena ni del cielo, de modo que sostiene el rumbo en ambos casos durante intervalos cortos.

2.7.2 Filtro de Kalman

El filtro de Kalman es la realización clásica de la estimación recursiva para sistemas lineales con ruido gaussiano [12]. El sistema se describe mediante un modelo de estado y un modelo de medición:

$$\begin{aligned} \mathbf{x}_k &= \mathbf{F}_k\,\mathbf{x}_{k-1} + \mathbf{B}_k\,\mathbf{u}_k + \mathbf{w}_k, \quad & \mathbf{w}_k &\sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k), \\ \mathbf{z}_k &= \mathbf{H}_k\,\mathbf{x}_k + \mathbf{v}_k, & \mathbf{v}_k &\sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k), \end{aligned} \tag{2.17}$$

donde $\mathbf{x}_k$ es el estado, $\mathbf{u}_k$ la entrada, $\mathbf{z}_k$ la medición, $\mathbf{F}_k$ la matriz de transición, $\mathbf{H}_k$ la matriz de observación, y $\mathbf{Q}_k$ y $\mathbf{R}_k$ las covarianzas del ruido de proceso y del ruido de medición, respectivamente [8].

El filtro conserva una estimación del estado $\hat{\mathbf{x}}_k$ junto con su covarianza $\mathbf{P}_k$, las cuales se actualizan mediante dos etapas. Durante la predicción, el estado se proyecta a partir del modelo del sistema, mientras que la incertidumbre aumenta:

$$\hat{\mathbf{x}}_k^- = \mathbf{F}_k\,\hat{\mathbf{x}}_{k-1} + \mathbf{B}_k\,\mathbf{u}_k, \qquad \mathbf{P}_k^- = \mathbf{F}_k\,\mathbf{P}_{k-1}\,\mathbf{F}_k^\top + \mathbf{Q}_k. \tag{2.18}$$

En la etapa de corrección, se contrasta la medición con el valor predicho y se ajusta la estimación según la ganancia de Kalman [8]:

$$\begin{aligned} \boldsymbol{\nu}_k &= \mathbf{z}_k - \mathbf{H}_k\,\hat{\mathbf{x}}_k^-, \quad \mathbf{S}_k = \mathbf{H}_k\,\mathbf{P}_k^-\,\mathbf{H}_k^\top + \mathbf{R}_k, \\ \mathbf{K}_k &= \mathbf{P}_k^-\,\mathbf{H}_k^\top\,\mathbf{S}_k^{-1}, \quad \hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{K}_k\,\boldsymbol{\nu}_k, \\ &\qquad\qquad \mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k\,\mathbf{H}_k)\,\mathbf{P}_k^-. \end{aligned} \tag{2.19}$$

El término $\boldsymbol{\nu}_k$ recibe el nombre de innovación, mientras que $\mathbf{S}_k$ representa su covarianza teórica. Por su parte, la ganancia $\mathbf{K}_k$ establece el grado en que la estimación se ajusta hacia la medición, en función de la incertidumbre asociada a la predicción y a la propia medición.

2.7.3 Filtro de Kalman extendido

Cuando el modelo de movimiento o el de medición no son lineales, como sucede al incluir rotaciones, se recurre al filtro de Kalman extendido [8]. El modelo pasa a ser $\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k) + \mathbf{w}_k$ y $\mathbf{z}_k = h(\mathbf{x}_k) + \mathbf{v}_k$. La predicción del estado y de la medición emplean las funciones no lineales, $\hat{\mathbf{x}}_k^- = f(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_k)$ y $\boldsymbol{\nu}_k = \mathbf{z}_k - h(\hat{\mathbf{x}}_k^-)$, en tanto que la propagación de la covarianza y el cálculo de la ganancia utilizan las Ecuaciones (2.18) y (2.19) con los jacobianos evaluados en la estimación vigente:

$$\mathbf{F}_k = \left.\frac{\partial f}{\partial \mathbf{x}}\right|_{\hat{\mathbf{x}}_{k-1},\,\mathbf{u}_k}, \qquad \mathbf{H}_k = \left.\frac{\partial h}{\partial \mathbf{x}}\right|_{\hat{\mathbf{x}}_k^-}. \tag{2.20}$$

Para la localización de un vehículo terrestre resulta suficiente considerar un estado planar,

$$\mathbf{x} = [\,x,\ y,\ \theta,\ \kappa,\ v\,]^\top, \tag{2.21}$$

integrado por la posición (x, y) en el plano definido en la Sección 2.5, el rumbo θ, un parámetro κ que ajusta la escala del modelo de profundidad de la Sección 2.4.7 y la rapidez v. En cada cuadro, la etapa de predicción incorpora la variación de rumbo $\Delta\psi_k$ medida por el giroscopio según la Ecuación (2.16), o bien la estimada por la cámara cuando no se dispone de muestras del giroscopio, bajo la premisa de que el vehículo avanza en la dirección de su propio rumbo:

$$\theta_k = \theta_{k-1} + \Delta\psi_k, \qquad \begin{bmatrix} x_k \\ y_k \end{bmatrix} = \begin{bmatrix} x_{k-1} \\ y_{k-1} \end{bmatrix} + v_{k-1}\,\Delta t_k \begin{bmatrix} \cos\!\left(\theta_{k-1} + \frac{1}{2}\Delta\psi_k\right) \\ \sin\!\left(\theta_{k-1} + \frac{1}{2}\Delta\psi_k\right) \end{bmatrix}, \tag{2.22}$$

donde Δt_k denota el intervalo temporal transcurrido desde el cuadro anterior y el rumbo intermedio aproxima la trayectoria curvilínea desarrollada durante dicho lapso. A su vez,

el factor de escala κ y la rapidez v se propagan sin modificaciones directas, de modo que su incertidumbre se incrementa a través de la matriz de covarianza del ruido de proceso $\mathbf{Q}_k$.

Las actualizaciones se reciben a diferentes frecuencias, tal como se ilustra en la Fig. 5. Cada vez que se dispone de una solución del GPS, se actualizan la posición mediante $h(\mathbf{x}) = [x, y]^\top$; la rapidez, utilizando la velocidad Doppler y $h(\mathbf{x}) = v$; y el rumbo, a partir de la dirección del segmento que conecta dos soluciones consecutivas, siempre que su longitud concuerde con la distancia que predice la velocidad Doppler. De forma periódica, la rapidez estimada por la cámara mediante la Ecuación (2.13) se utiliza para corregir el estado con $h(\mathbf{x}) = v/\kappa$, de manera que el GPS, al proporcionar el valor de v, también permite estimar κ; si la cámara identifica que el vehículo permanece detenido, se emplea directamente la medición $v = 0$. En los cuadros donde no se realiza ninguna corrección, se conserva la predicción mediante $\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^-$ y $\mathbf{P}_k = \mathbf{P}_k^-$. Tanto la Ecuación (2.22) como la medición v/κ presentan una relación no lineal con el estado, por lo que resulta apropiado utilizar el filtro extendido. Dado que el GPS se integra mediante sus estimaciones de posición y velocidad previamente calculadas, en lugar de utilizar las pseudodistancias originales, este enfoque se clasifica como acoplamiento débil [8].

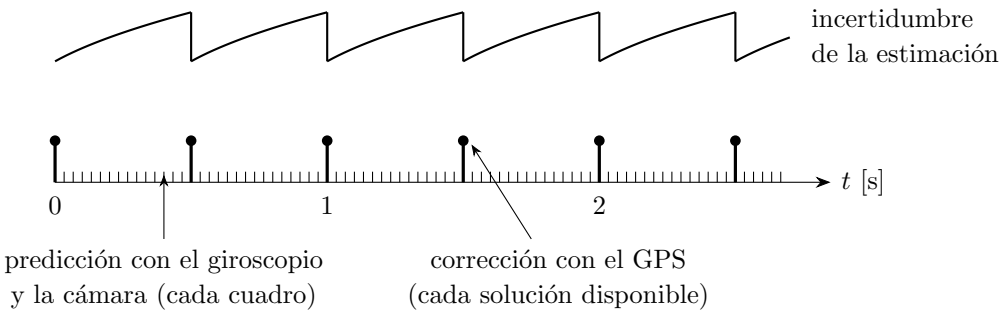


Fig. 5: Operación del filtro de Kalman extendido con fuentes de frecuencia distinta. La incertidumbre crece con cada predicción y se reduce con cada corrección. Representación cualitativa. Fuente: elaboración propia.

2.7.4 Papel de las covarianzas de ruido

Las matrices $\mathbf{Q}_k$ y $\mathbf{R}_k$ establecen cuánta confianza obtiene cada fuente. El caso escalar lo deja en evidencia. Con $\mathbf{H}_k = 1$, la ganancia y la corrección de la Ecuación (2.19) se simplifican a

$$K_k = \frac{P_k^-}{P_k^- + R_k}, \qquad \hat{x}_k = (1 - K_k)\,\hat{x}_k^- + K_k\, z_k, \tag{2.23}$$

esto es, la estimación corregida constituye una combinación convexa entre la predicción y la medición, con un peso $K_k \in (0, 1)$. Si $R_k \to 0$, entonces $K_k \to 1$ y el filtro sigue la medición; si $R_k \to \infty$, entonces $K_k \to 0$ y el filtro la desestima. A su vez, Q_k incrementa P_k^- conforme a la Ecuación (2.18), lo que eleva K_k y concede más peso a la medición. Por

consiguiente, ajustar $\mathbf{Q}_k$ y $\mathbf{R}_k$ equivale a determinar la ponderación entre la predicción, sustentada en el giroscopio y la cámara, y cada una de las correcciones.

Asimismo, la innovación proporciona un mecanismo para comprobar la idoneidad de dichas covarianzas. Si el filtro opera de manera consistente, $\boldsymbol{\nu}_k$ se adhiere a una distribución $\mathcal{N}(\mathbf{0}, \mathbf{S}_k)$, por lo que la innovación normalizada

$$\bar{\nu}_k^2 = \boldsymbol{\nu}_k^\top \, \mathbf{S}_k^{-1} \, \boldsymbol{\nu}_k \tag{2.24}$$

presenta una distribución chi cuadrado con un número de grados de libertad equivalente a la dimensionalidad del vector de medición [8]. Registros elevados de $\bar{\nu}_k^2$ de forma sostenida sugieren que las covarianzas subestiman el error efectivo o que alguna de las fuentes de datos ha sufrido una degradación. Esta misma prueba resulta útil para auditar cada observación de manera previa a su asimilación: cuando $\bar{\nu}_k^2$ excede el límite crítico de la distribución chi cuadrado correspondiente a un nivel de significancia estricto, la lectura se rechaza por considerarse incompatible con la predicción [8]. Dicho control de validación resguarda al filtro frente a estimaciones satelitales anómalas que contengan errores severos, tales como los provocados por el fenómeno de multitrayecto.

En los métodos tradicionales, las matrices $\mathbf{Q}_k$ y $\mathbf{R}_k$ se establecen durante la etapa de diseño, por ejemplo, utilizando niveles de ruido obtenidos mediante mediciones experimentales, y se mantienen constantes. Esto implica asumir que las propiedades estadísticas del error de cada fuente no varían a lo largo del recorrido. Sin embargo, esta suposición no se ajusta a las condiciones de un entorno vial, en el que la confiabilidad de la cámara y la del GPS pueden variar en cuestión de segundos y de manera independiente. Por ello, un valor fijo tiende a ser demasiado conservador cuando las condiciones son favorables y poco adecuado cuando las condiciones se vuelven desfavorables.

2.7.5 Filtrado adaptativo

La alternativa clásica a los valores fijos es el filtrado adaptativo, que ajusta las covarianzas durante la operación a partir de la propia innovación. En la estimación adaptativa basada en la innovación, la covarianza empírica de la innovación se calcula sobre una ventana de las M correcciones más recientes y se compara con la teórica [14]:

$$\hat{\mathbf{C}}_{\nu,k} = \frac{1}{M} \sum_{j=k-M+1}^{k} \boldsymbol{\nu}_j \, \boldsymbol{\nu}_j^\top, \qquad \hat{\mathbf{R}}_k = \hat{\mathbf{C}}_{\nu,k} - \mathbf{H}_k \, \mathbf{P}_k^- \, \mathbf{H}_k^\top. \tag{2.25}$$

Si la innovación observada es mayor que la que predice el filtro, la Ecuación (2.25) aumenta la covarianza de la medición y reduce su influencia; la covarianza del proceso puede ajustarse de forma análoga a partir de la misma secuencia [14].

Este planteamiento presenta dos limitaciones de relevancia para el presente trabajo. La primera radica en que la extensión de la ventana establece un compromiso: una ventana breve reacciona con rapidez pero genera estimaciones ruidosas, que incluso pueden dejar

de estar definidas positivas al tratarse de una diferencia de matrices, mientras que una ventana extensa resulta estable pero lenta. La segunda consiste en que la regla de ajuste continúa siendo especificada por el diseñador y únicamente observa la innovación, sin acceso a otros indicadores, como la calidad del seguimiento visual, que anticipan la degradación de una fuente antes de que esta se refleje en la innovación. Dichas limitaciones motivan el empleo de una política aprendida, la cual se desarrolla en la sección siguiente.

2.8 Aprendizaje por refuerzo

2.8.1 Procesos de decisión de Markov

El aprendizaje por refuerzo analiza los mecanismos mediante los cuales un agente aprende a conducirse dentro de un entorno a través de la experimentación directa, guiado de manera exclusiva por una señal orientada a evaluar sus acciones [22]. A diferencia de los paradigmas de aprendizaje supervisado, el agente no recibe indicaciones sobre la acción correcta a ejecutar, sino únicamente una retroalimentación que cuantifica el desempeño de la decisión adoptada.

La interacción entre el agente y el entorno se describe formalmente mediante un proceso de decisión de Markov, ilustrado en la Fig. 6. En cada instante t, el agente recibe una observación del estado s_t, selecciona una acción a_t y obtiene del entorno una recompensa r_{t+1} junto con un nuevo estado s_{t+1}. Esta transición sigue una dinámica $p(s_{t+1}, r_{t+1} \mid s_t, a_t)$, determinada únicamente por el estado y la acción actuales [22].

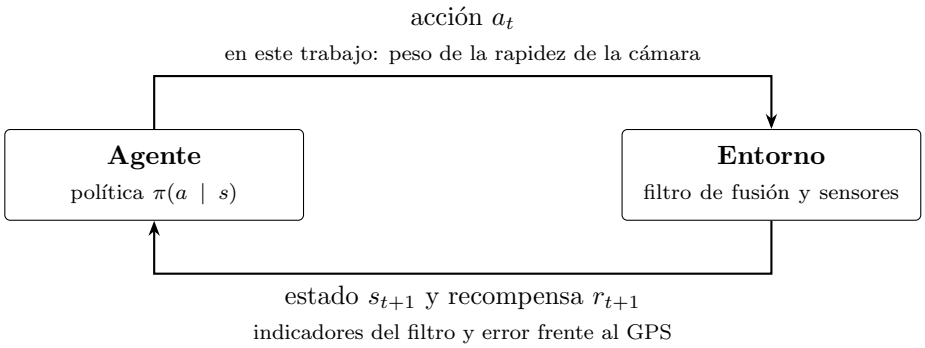


Fig. 6: Ciclo de interacción entre el agente y el entorno. Fuente: elaboración propia con base en [22].

La conducta del agente queda caracterizada por su política $\pi(a \mid s)$, esto es, la probabilidad de seleccionar la acción a en el estado s. La meta consiste en maximizar el retorno, es decir, la suma descontada de las recompensas futuras, y la idoneidad de un estado bajo una política se cuantifica mediante su función de valor [22]:

$$G_t = \sum_{k=0}^{\infty} \gamma^k \, r_{t+k+1}, \qquad v_\pi(s) = \mathbb{E}_\pi[\, G_t \mid s_t = s \,], \tag{2.26}$$

donde $\gamma \in [0, 1]$ es el factor de descuento; el valor $\gamma = 1$ solo es admisible en tareas episódicas, que terminan en un número finito de pasos [22]. Con γ próximo a uno, el agente pondera las consecuencias a largo plazo de sus acciones, lo que le permite admitir una recompensa menor en el presente si con ello logra estados más favorables.

2.8.2 Métodos basados en valor: Q-learning

Las metodologías de aprendizaje por refuerzo se clasifican fundamentalmente en dos grandes ramas. Por un lado, los esquemas de gradiente de política representan la estrategia de control mediante una función parametrizada, usualmente una red neuronal, y ajustan sus parámetros en la dirección que mejora el retorno esperado; resultan naturales cuando la acción es una cantidad continua [23]. Por otro lado, los enfoques basados en valor estiman, para cada estado y acción, el retorno esperado al tomar esa acción y seguir después la política,

$$q_\pi(s, a) = \mathbb{E}_\pi[\, G_t \mid s_t = s,\ a_t = a \,], \tag{2.27}$$

y actúan seleccionando en cada estado la acción de mayor valor [22]. Cuando los conjuntos de estados y de acciones son finitos y pequeños, esa función puede almacenarse como una tabla con una entrada por cada par de estado y acción.

El algoritmo Q-learning estima dicha tabla directamente a partir de la experiencia, sin requerir un modelo de la dinámica del entorno [28]. Tras cada transición, la entrada correspondiente se corrige hacia una estimación del retorno formada por la recompensa recibida y el mejor valor del estado siguiente [22]:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right], \tag{2.28}$$

donde $\alpha \in (0, 1]$ es la tasa de aprendizaje y, en el último paso de un episodio, se omite el término del estado siguiente. La diferencia entre corchetes es un error de diferencia temporal: contrasta el valor que se esperaba con lo que efectivamente ocurrió. Para que la tabla se estime en todos los pares relevantes, durante el entrenamiento la acción se elige con una política ε-codiciosa [22],

$$a_t = \begin{cases} \arg\max_a Q(s_t, a) & \text{con probabilidad } 1 - \varepsilon, \\ \text{una acción elegida al azar} & \text{con probabilidad } \varepsilon, \end{cases} \tag{2.29}$$

que equilibra la explotación de lo aprendido con la exploración de alternativas; es habitual reducir ε a medida que avanza el entrenamiento. Si cada par de estado y acción se visita un número suficiente de veces y la tasa de aprendizaje decrece de forma adecuada, la tabla converge a los valores óptimos [28]. El Algoritmo 2 resume el procedimiento.

Algoritmo 2 Q-learning tabular por episodios. Fuente: elaboración propia con base en [28, 22].

Entrada: conjuntos finitos de estados y acciones, tasa de aprendizaje α, factor de descuento γ, exploración ε

1: $Q(s,a) \leftarrow 0$ para todo par (s,a)
2: **para todo** episodio de entrenamiento **hacer**
3: observar el estado inicial s
4: **mientras** el episodio no ha terminado **hacer**
5: elegir a con la Ecuación (2.29); aplicarla y observar r y s'
6: actualizar $Q(s,a)$ con la Ecuación (2.28); $s \leftarrow s'$
7: **fin mientras**
8: **fin para**

Salida: política $\pi(s) = \arg\max_a Q(s,a)$

Para el problema de este proyecto se adopta Q-learning tabular por tres razones. La primera es que la acción consiste en elegir entre unos pocos niveles de confianza para una medición, por lo que el conjunto de acciones es discreto y reducido (Sección 2.8.3). La segunda es la cantidad limitada de datos de entrenamiento: una tabla sobre un estado discretizado tiene pocos parámetros y es menos propensa que un modelo con muchas variables a memorizar las particularidades de cada recorrido. La tercera es que la política resultante se puede leer directamente en la tabla, lo que hace explícitos el estado y la decisión, y su consulta se reduce a un acceso a memoria, de costo despreciable frente al presupuesto de tiempo de cada cuadro.

2.8.3 Ajuste adaptativo de la fusión mediante aprendizaje por refuerzo

La literatura reporta dos formas de emplear el aprendizaje por refuerzo para ajustar la fusión de sensores.

Ponderación directa de estimaciones. La manera más sencilla consiste en combinar las estimaciones de dos fuentes utilizando un peso generado por la política:

$$\hat{\mathbf{x}} = w\,\hat{\mathbf{x}}_A + (1-w)\,\hat{\mathbf{x}}_B, \qquad w = \pi_{\boldsymbol{\theta}}(s) \in [0,1]. \tag{2.30}$$

Wong et al. utilizan un agente entrenado mediante *Proximal Policy Optimization* para determinar los pesos entre un algoritmo de localización basado en LiDAR y otro basado en SLAM visual [29]. En una formulación de mínimos cuadrados como la Ecuación (2.4), modificar el peso de un sensor equivale a escalar las matrices de información de sus restricciones; Jia et al. adoptan este enfoque mediante un agente actor-crítico que ajusta dinámicamente el peso de cada sensor durante la optimización [11].

Adaptación de las covarianzas del filtro. La segunda forma preserva la estructura del filtro de Kalman y permite que la política modifique sus covarianzas. Gao et al. plantean

un filtro de Kalman adaptativo en el que un agente entrenado con un método actor-crítico para acciones continuas ajusta el ruido de proceso de una integración de GNSS con sensores inerciales; la acción se aplica por medio de una función exponencial para conservar el carácter definido positivo de la covarianza, y la recompensa se define como el opuesto del error de posición [5]. En este trabajo se aplica el mismo principio con acciones discretas y sobre una sola medición: la rapidez que aporta la cámara (Sección 2.4.7), cuya confiabilidad cambia con la escena y con la velocidad. Durante las interrupciones del GPS, la política escala la varianza de esa medición y se evalúa por el error frente a las soluciones GPS ocultas:

$$R_n^{\mathrm{cam}} = \lambda_n \, R_{\mathrm{b}}^{\mathrm{cam}}, \qquad r_n = \sum_{j \in \mathcal{J}_n} \Big(\big\| \hat{\mathbf{p}}_j^{\mathrm{c}} - \mathbf{z}_j \big\| - \big\| \hat{\mathbf{p}}_j - \mathbf{z}_j \big\| \Big) - c_\lambda \mathbb{1}[\lambda_n \neq \lambda_{n-1}] \,, \tag{2.31}$$

donde n indexa las decisiones, λ_n es la acción, tomada de un conjunto finito de multiplicadores, y $R_{\mathrm{b}}^{\mathrm{cam}}$ la varianza fija del filtro convencional. En la recompensa, $\mathcal{J}_n$ reúne las soluciones GPS $\mathbf{z}_j$ comprendidas entre la decisión n y la siguiente, ya sean las ocultas o la primera que se recibe al terminar la interrupción, $\hat{\mathbf{p}}_j$ y $\hat{\mathbf{p}}_j^{\mathrm{c}}$ son las posiciones estimadas por el filtro con la política y por el filtro convencional en la misma interrupción, y c_λ es una penalización pequeña por cambiar de acción, que evita oscilaciones. Con $\lambda_n = 1$ se recupera el filtro convencional, y con $\lambda_n = \infty$ la medición se descarta y el filtro continúa con su propia rapidez y el giroscopio. Las soluciones ocultas solo están disponibles cuando las interrupciones se simulan sobre recorridos grabados, de modo que la recompensa se calcula durante el entrenamiento y la evaluación, nunca en operación.

Ambas modalidades guardan una estrecha vinculación. De acuerdo con la Ecuación (2.23), la actualización efectuada por el filtro constituye por sí misma una combinación convexa entre la predicción y la observación, cuyos pesos relativos dependen de $\mathbf{Q}_k$ y $\mathbf{R}_k$; en consecuencia, modular las covarianzas representa un método de ponderación que preserva la propagación de la incertidumbre propia del filtro, una ventaja de la que carece la Ecuación (2.30). Este segundo enfoque es precisamente el que se adopta en la arquitectura de la plataforma desarrollada en el presente estudio.

Respecto al estado, este debe resumir lo que el filtro observa sobre la confiabilidad de la cámara en el momento de decidir. Se construye con cinco señales disponibles en el propio filtro,

$$\mathbf{s}_n = \big[\, \Delta t_n^{\mathrm{GPS}}, \; \hat{v}_n, \; \sigma_n^{\mathrm{D/c}}, \; \bar{\nu}_{\mathrm{c},n}^2, \; f_n^{\mathrm{det}} \, \big]^\top , \tag{2.32}$$

donde $\Delta t_n^{\mathrm{GPS}}$ es el tiempo transcurrido desde la última solución GPS, $\hat{v}_n$ la rapidez estimada por el filtro, $\sigma_n^{\mathrm{D/c}}$ la dispersión reciente del cociente entre la rapidez Doppler y la de la cámara, $\bar{\nu}_{\mathrm{c},n}^2$ la innovación normalizada media de las últimas mediciones de rapidez de la cámara (Ecuación (2.24)) y f_n^{det} la fracción reciente de cuadros en que la cámara indica que el vehículo está detenido. Cada señal se discretiza en unos pocos niveles, de modo que el estado pertenece a un conjunto finito y la función de valor se representa como una tabla.

El Algoritmo 3 integra los elementos previos en el filtro de la Sección 2.7: la política decide el peso de la rapidez de la cámara una vez por segundo, solo mientras el GPS

no entrega soluciones, ya que con el GPS presente esa medición no aporta información adicional. La concreción de este esquema para la plataforma, incluidos los niveles de cada señal, los multiplicadores y el protocolo de entrenamiento, se expone en el Capítulo 4.

Algoritmo 3 Filtro de Kalman extendido con el peso de la rapidez de la cámara ajustado por una política. Fuente: elaboración propia con base en [5, 8].

Entrada: tabla Q entrenada, varianza base $R_{\mathrm{b}}^{\mathrm{cam}}$, estado inicial $\hat{\mathbf{x}}_0, \mathbf{P}_0$

$\lambda \leftarrow 1$
para cada cuadro $k = 1, 2, \ldots$ **hacer**
  obtener $\Delta\psi_k$ del giroscopio con la Ecuación (2.16), o de la cámara si no hay muestras
  predicción: $\hat{\mathbf{x}}_k^-$ con la Ecuación (2.22); $\mathbf{P}_k^- \leftarrow \mathbf{F}_k \mathbf{P}_{k-1} \mathbf{F}_k^\top + \mathbf{Q}_k$; $\hat{\mathbf{x}}_k \leftarrow \hat{\mathbf{x}}_k^-$; $\mathbf{P}_k \leftarrow \mathbf{P}_k^-$
  si hay soluciones GPS recientes **entonces**
    $\lambda \leftarrow 1$
  si no
    una vez por segundo: construir $\mathbf{s}_n$ según la Ecuación (2.32); $\lambda \leftarrow \arg\max_{\lambda'} Q(\mathbf{s}_n, \lambda')$
  fin si
  para todo medición $\mathbf{z}$ disponible en el cuadro k (GPS o rapidez de la cámara) **hacer**
    calcular $\bar{\nu}^2$ con la Ecuación (2.24), con $R^{\mathrm{cam}} = \lambda R_{\mathrm{b}}^{\mathrm{cam}}$ para la rapidez de la cámara
    si $\bar{\nu}^2$ no supera el umbral de validación y la medición no se descarta ($\lambda < \infty$) **entonces**
      corregir $\hat{\mathbf{x}}_k$ y $\mathbf{P}_k$ con la Ecuación (2.19)
    fin si
  fin para
fin para

2.9 Operación en tiempo real

Se define como un sistema de tiempo real aquel cuya validez operativa no solo descansa en la exactitud del resultado obtenido, sino también en el momento preciso en que este es emitido [1]. En función de las repercusiones asociadas a la transgresión de un límite temporal, se identifican diversos niveles de exigencia: mientras que en un esquema de tiempo real estricto cualquier retraso constituye una falla crítica, en uno de carácter flexible el incumplimiento deteriora la calidad del servicio sin llegar a invalidarlo por completo [1]. La arquitectura implementada en este proyecto se adscribe a esta segunda categoría: si un cuadro no logra procesarse dentro del plazo estipulado, la estimación experimenta una pérdida transitoria de continuidad y precisión, si bien el mecanismo conserva la capacidad de recuperarse en las iteraciones subsiguientes.

De acuerdo con la terminología de [1], cada cuadro puede considerarse una tarea que se

genera en el instante de captura t_k^{cap}, necesita un tiempo de cómputo C_k y finaliza en el instante t_k^{fin}. Cuando la cámara funciona a una frecuencia f_c, se recibe un nuevo cuadro cada $\Delta t_c = 1/f_c$, por lo que se definen

$$C_k = \sum_j C_{k,j}, \qquad L_k = t_k^{\text{fin}} - t_k^{\text{cap}}, \tag{2.33}$$

donde $C_{k,j}$ representa el tiempo requerido por cada etapa del procesamiento y L_k corresponde a la latencia del cuadro, que también contempla el tiempo transcurrido desde la captura hasta el comienzo del procesamiento. Para evitar que el procesamiento acumule retraso con respecto a la captura, el tiempo de cómputo debe satisfacer $C_k \leq \Delta t_c$, lo que para una cámara de 30 Hz representa aproximadamente 33,3 ms por cuadro.

Cuando un cuadro sobrepasa ese presupuesto, el sistema ha de decidir qué hacer con los que arriban mientras tanto. Si se guardan en una cola para procesarlos todos, no se pierde ninguno, pero cada cuadro aguarda más que el anterior y la latencia se incrementa sin límite. La alternativa, apropiada para un sistema de tiempo real flexible, consiste en omitir algunas instancias de la tarea a fin de preservar la oportunidad de las demás [1]. Una manera de llevarla a cabo es una cola de una sola posición, en la cual cada cuadro nuevo sustituye al que estuviera en espera, de modo que el procesamiento prosigue siempre con la imagen más reciente, como se muestra en la Fig. 7.

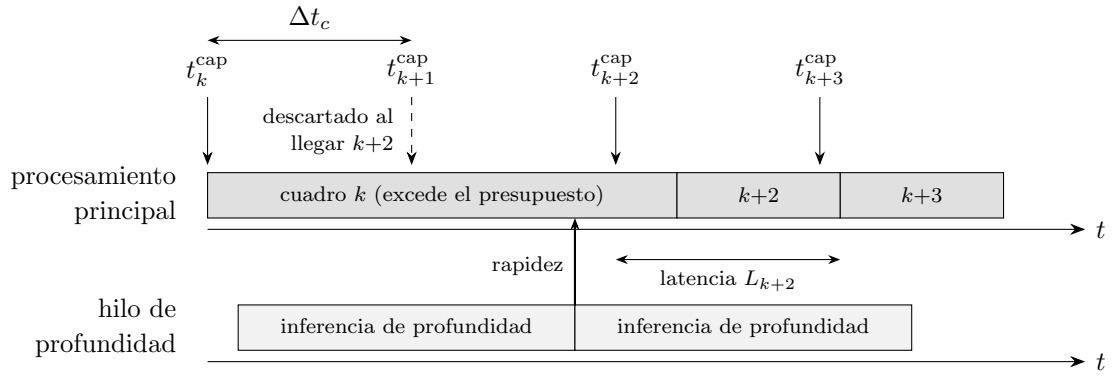


Fig. 7: Descarte de cuadros con una cola de una sola posición y procesamiento asíncrono de la profundidad. Mientras se procesa el cuadro k, el cuadro k+1 queda en espera y es reemplazado por k+2. Las duraciones son ilustrativas. Fuente: elaboración propia con base en la terminología de [1].

Bajo esta estrategia de control, el comportamiento temporal del sistema queda caracterizado por la latencia L_k junto con dos parámetros complementarios: la fracción de cuadros descartados y la tasa de procesamiento efectiva:

$$q_{\text{desc}} = \frac{N_{\text{desc}}}{N_{\text{proc}} + N_{\text{desc}}}, \qquad f_{\text{ef}} = \frac{N_{\text{proc}}}{T_{\text{ses}}}, \tag{2.34}$$

en donde N_{proc} y N_{desc} denotan el número de cuadros procesados y descartados a lo largo de una sesión con una duración T_{ses}. Dado que un valor promedio satisfactorio puede

enmascarar cuadros aislados que sobrepasan considerablemente el presupuesto asignado, tanto el tiempo de cálculo como la latencia se analizan también a través de percentiles elevados de su distribución estadística, y no exclusivamente mediante su media aritmética.

Las etapas con un costo considerablemente mayor que el de las demás pueden ejecutarse de manera asíncrona, mediante un hilo independiente que proporciona resultados con menor frecuencia. Este es el caso de la estimación de escala descrita en la Sección 2.4.7: la inferencia de la red de profundidad constituye la etapa de mayor costo, pero la rapidez que genera cambia lentamente y puede conservarse entre actualizaciones sin interrumpir el procesamiento principal.

La consecuencia práctica radica en que toda decisión que eleve la precisión debe valorarse asimismo por su costo temporal. Extraer más características disminuye el error de cada factor de la Ecuación (2.12), pero eleva el costo de la detección y del emparejamiento; incrementar las iteraciones de RANSAC conforme a la Ecuación (2.11) aumenta el de la estimación de la pose; en cambio, consultar una política tabular apenas suma costo. La manera en que se resolvieron dichos compromisos se documenta en el Capítulo 4.

2.10 Métricas de evaluación de trayectorias

La evaluación de un sistema de localización demanda contrastar la trayectoria estimada, integrada por las poses $\hat{\mathbf{T}}_1, \ldots, \hat{\mathbf{T}}_n$, frente a una secuencia de referencia $\mathbf{T}_1^{\mathrm{ref}}, \ldots, \mathbf{T}_n^{\mathrm{ref}}$ dotada de mayor exactitud. Dado que ambas trayectorias se representan en marcos de coordenadas diferentes y, bajo la modalidad monocular, con escalas desemejantes, el análisis comparativo inicia con su alineación. Dicho proceso de alineación persigue hallar la transformación de semejanza, constituida por un factor de escala s, una rotación $\mathbf{R}$ y una traslación $\mathbf{t}$, que logre superponer de manera óptima las ubicaciones estimadas $\hat{\mathbf{p}}_i$ sobre las posiciones de referencia $\mathbf{p}_i^{\mathrm{ref}}$ [27]:

$$(s^*, \mathbf{R}^*, \mathbf{t}^*) = \arg\min_{s,\mathbf{R},\mathbf{t}} \frac{1}{n} \sum_{i=1}^{n} \left\| \mathbf{p}_i^{\mathrm{ref}} - (s\,\mathbf{R}\,\hat{\mathbf{p}}_i + \mathbf{t}) \right\|^2, \tag{2.35}$$

cuyo cálculo posee una solución analítica cerrada basada en la descomposición en valores singulares. A la transformación resultante se le asigna la notación $\mathbf{T}_{\mathrm{al}}$. En aquellas situaciones donde la trayectoria estimada ya dispone de una escala métrica —como sucede al fusionarla con el sistema GPS—, el procedimiento de alineación se restringe a una transformación de carácter rígido con $s = 1$ [21], de modo que cualquier sesgo de escala se vea reflejado en la métrica de evaluación en lugar de ser compensado de manera artificial.

A partir de las trayectorias alineadas, se calculan dos métricas complementarias de uso extendido en la literatura del área [21]. Utilizando una notación adaptada de dicha referencia y definiendo trans$(\cdot)$ como la componente de traslación de una transformación:

Error absoluto de trayectoria (ATE). Compara cada pose estimada y alineada con

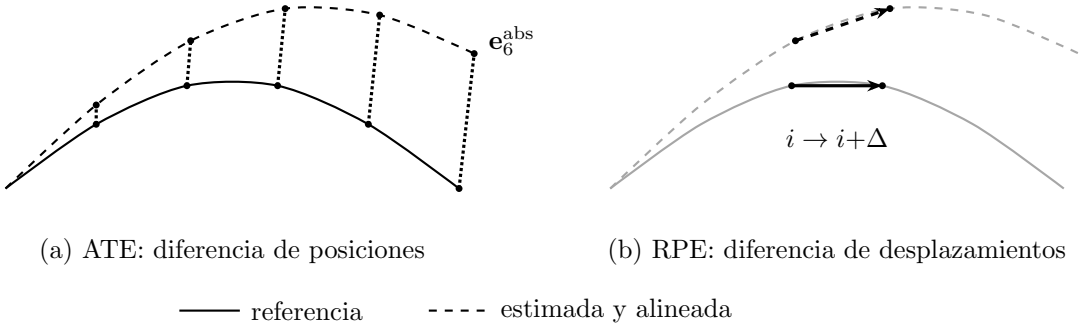
la pose de referencia del mismo instante:

$$\mathbf{e}_i^{\text{abs}} = \operatorname{trans}\Big(\big(\mathbf{T}_i^{\text{ref}}\big)^{-1}\,\mathbf{T}_{\text{al}}\,\hat{\mathbf{T}}_i\Big), \qquad \text{ATE} = \left(\frac{1}{n}\sum_{i=1}^{n}\big\|\mathbf{e}_i^{\text{abs}}\big\|^2\right)^{1/2}. \tag{2.36}$$

Error relativo de pose (RPE). Compara el movimiento ocurrido en un intervalo fijo Δ, en lugar de las posiciones:

$$\begin{aligned}\mathbf{e}_i^{\text{rel}} &= \operatorname{trans}\left(\left(\big(\mathbf{T}_i^{\text{ref}}\big)^{-1}\,\mathbf{T}_{i+\Delta}^{\text{ref}}\right)^{-1}\left(\hat{\mathbf{T}}_i^{-1}\,\hat{\mathbf{T}}_{i+\Delta}\right)\right),\\ \text{RPE}(\Delta) &= \left(\frac{1}{m}\sum_{i=1}^{m}\big\|\mathbf{e}_i^{\text{rel}}\big\|^2\right)^{1/2},\end{aligned} \tag{2.37}$$

con $m = n - \Delta$.



(a) ATE: diferencia de posiciones (b) RPE: diferencia de desplazamientos

Fig. 8: Diferencia entre ATE y RPE. La trayectoria estimada acumula deriva, por lo que su ATE es alto; sin embargo, sus desplazamientos locales se parecen a los de referencia, por lo que su RPE es bajo. Fuente: elaboración propia con base en [21].

La Fig. 8 evidencia por qué ambas métricas se presentan de forma conjunta. El ATE cuantifica la consistencia global y está dominado por la deriva acumulada, dado que un desvío progresivo genera errores crecientes. El RPE cuantifica la calidad local y resulta en buena medida insensible a dicha deriva, pues un error introducido al inicio no afecta los desplazamientos medidos con posterioridad. Un sistema con RPE bajo y ATE alto estima correctamente el movimiento instante a instante pero acumula error; la situación opuesta señala una estimación localmente ruidosa cuyos errores se compensan a lo largo del recorrido.

Deriva durante interrupciones del GPS. Con el propósito de auditar el desempeño del sistema ante la ausencia de señal satelital, resulta de gran interés analizar la distancia espacial entre la posición estimada y la de referencia a lo largo del tiempo,

$$d(t) = \big\|\hat{\mathbf{p}}(t) - \mathbf{p}^{\text{ref}}(t)\big\|, \qquad d_{\%} = 100\,\frac{d_{\text{f}}}{\ell}, \tag{2.38}$$

en donde d_{f} corresponde a la separación existente al concluir el periodo de interrupción y ℓ representa la longitud del trayecto recorrido durante dicho lapso. Expresar la deriva

en función del porcentaje de la distancia recorrida facilita la comparación entre segmentos de longitud variable, siguiendo un criterio homólogo al empleado en la evaluación de odometría del conjunto de datos KITTI, el cual cuantifica el error traslacional como una proporción de la distancia cubierta en los tramos analizados [6]. Una estrategia metodológica para simular estas interrupciones de forma controlada consiste en deshabilitar las correcciones del GPS durante un intervalo específico dentro de una ruta previamente registrada, contrastando posteriormente la estimación obtenida frente a las mediciones de referencia que fueron omitidas.

Para aplicar estas métricas, se requiere una trayectoria de referencia con mayor precisión que la del sistema bajo evaluación. Los conjuntos de datos públicos diseñados para este propósito obtienen dicha trayectoria mediante equipos de posicionamiento de alta precisión instalados en el vehículo de captura; entre ellos, el conjunto KITTI proporciona secuencias registradas en condiciones viales reales junto con sus trayectorias de referencia [6]. En las pruebas efectuadas con equipo propio no se cuenta con una referencia de precisión equivalente, por lo que únicamente se dispone del GPS del teléfono, cuyo error de varios metros, descrito en la Sección 2.5.2, restringe el nivel de detalle de la comparación; en estas condiciones, la evaluación se basa principalmente en la deriva durante interrupciones simuladas y en comparaciones relativas entre distintas configuraciones del sistema, tema que se retoma en el Capítulo 3. Por último, debido a que la plataforma funciona bajo una restricción temporal, su evaluación también considera las cantidades definidas en las Ecuaciones (2.33) y (2.34), con el fin de evitar que una mejora en la precisión obtenida a costa de incumplir el presupuesto de tiempo se considere una mejora del sistema.

Capítulo 3

Marco metodológico

3.1 Introducción

Este capítulo describe la estrategia seguida para desarrollar la plataforma propuesta. Se presentan el tipo de trabajo y la justificación de la estrategia elegida, la secuencia del proceso y sus fases, las técnicas y herramientas empleadas, las estrategias de verificación y validación, y los actores que participan en el proceso. El propósito es que el lector comprenda cómo se abordó la solución del problema planteado en el Capítulo 1; los resultados de aplicar esta metodología se presentan en el capítulo siguiente.

Al momento de redactar este capítulo, la integración del mecanismo de aprendizaje por refuerzo en la plataforma y la evaluación final se encuentran en curso. Para ellas se describe el método seguido, sin anticipar sus resultados.

La Sección 3.2 justifica el tipo de trabajo y la estrategia incremental. La Sección 3.3 presenta la secuencia del proceso y describe cada una de sus fases. La Sección 3.4 reúne las herramientas y los recursos empleados, y la Sección 3.5 describe a los actores participantes. Por último, la Sección 3.6 resume, para cada objetivo específico, las actividades, los entregables, las herramientas y las estrategias de verificación y validación.

3.2 Tipo de trabajo y estrategia elegida

El trabajo corresponde a la modalidad de proyecto de graduación definida en los lineamientos de la carrera [10]. Se clasifica como un proyecto de investigación aplicada con un componente significativo de desarrollo tecnológico. La investigación aplicada se manifiesta en el estudio y la evaluación de técnicas de localización basadas en visión computacional, posicionamiento satelital, sensores inerciales y aprendizaje por refuerzo, orientadas a un problema concreto de precisión y robustez en la localización vehicular. El desarrollo tecnológico se manifiesta en la construcción de una plataforma funcional que integra esas fuentes de información y opera bajo las restricciones de un sistema de tiempo real.

Para el desarrollo se adoptó una estrategia incremental organizada en cuatro fases: análisis y definición de requerimientos; diseño e implementación de la plataforma; validación experimental y evaluación del desempeño; y análisis de resultados y documentación. En el desarrollo incremental el sistema se construye como una serie de versiones, cada una de las cuales agrega funcionalidad a la anterior y puede evaluarse antes de continuar [20]. Tres características del proyecto justifican esta elección.

Dependencias entre componentes. Cada componente de la plataforma requiere que los anteriores funcionen. La fusión necesita la odometría visual, la escala métrica y las fuentes de datos; el mecanismo de aprendizaje por refuerzo necesita un filtro de fusión operativo, que además le sirve de referencia, ya que la acción neutra reproduce el filtro convencional (Sección 2.8.3). Construir por incrementos permite que cada versión se compare directamente con la anterior.

Incertidumbre técnica. Algunas decisiones, como la fuente de la escala métrica, no podían tomarse de antemano porque dependían del desempeño de cada alternativa con los datos disponibles. En esos casos se realizaron sondeos mínimos sobre datos grabados antes de integrar cualquier alternativa en la plataforma, de modo que la decisión se basara en mediciones y no en supuestos.

Costo de las pruebas con el equipo real. Las pruebas con el teléfono y el vehículo son costosas en tiempo y difíciles de repetir en condiciones idénticas. Por ello la plataforma se diseñó para procesar indistintamente datos en vivo o grabaciones, de modo que la mayor parte del desarrollo y de la verificación se realiza sobre grabaciones, y la prueba de campo se ejecuta con el sistema ya integrado.

Dos principios atraviesan todas las fases. El primero es la reproducibilidad: las cifras que se reportan se obtienen en un modo de ejecución determinista, que produce el mismo resultado cada vez que se procesa la misma grabación. El segundo es la separación entre el método y la referencia: cuando se dispone de una trayectoria de referencia, esta se utiliza únicamente para evaluar, nunca como entrada del sistema, de manera que lo medido corresponda a lo que la plataforma obtendría en operación real.

3.3 Secuencia del proceso

La Fig. 9 muestra la secuencia de las cuatro fases y los incrementos de la fase de diseño e implementación. Las flechas discontinuas representan la retroalimentación entre fases: las mediciones obtenidas al implementar refinan los requerimientos, y los resultados de la validación pueden motivar ajustes en la plataforma. Las secciones siguientes describen cada fase.

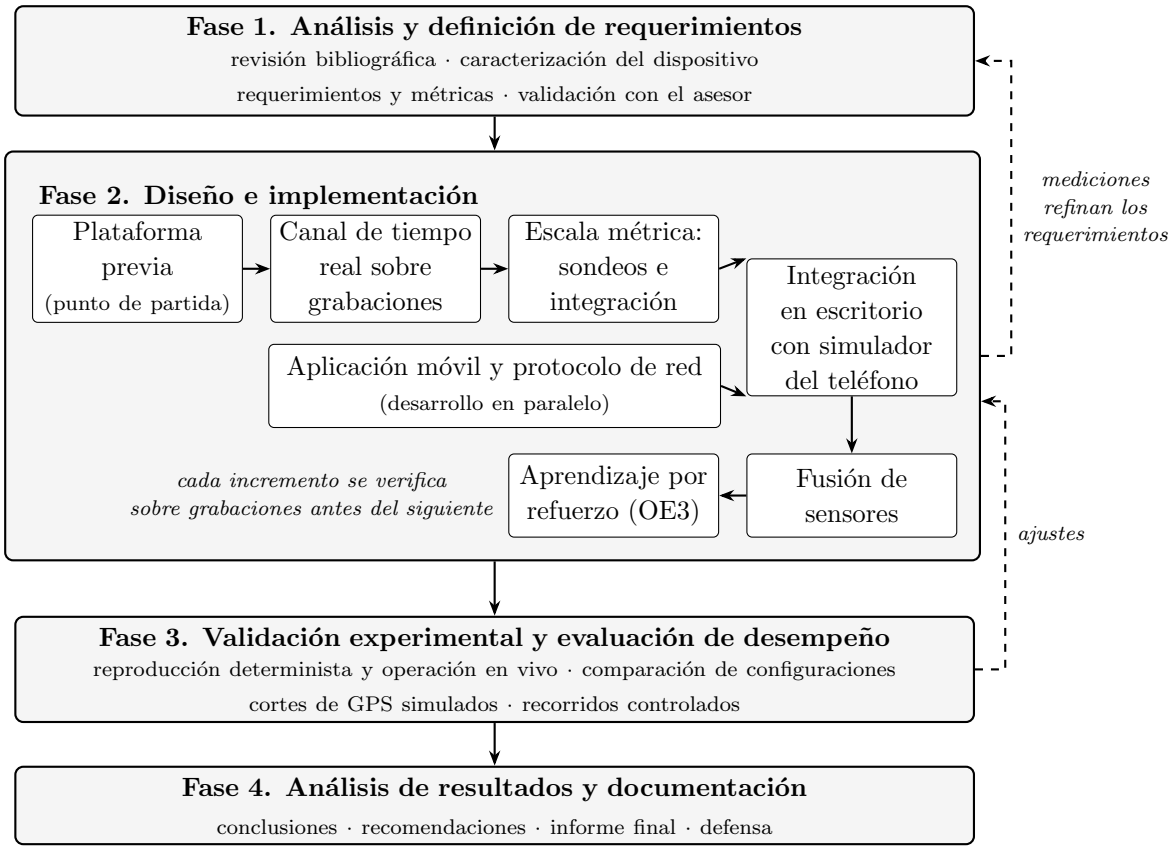


Fig. 9: Secuencia del proceso seguido. La Fase 2 se compone de incrementos; la aplicación móvil se desarrolla en paralelo con el canal de procesamiento y ambos se unen solo a través del protocolo de red. Fuente: elaboración propia.

3.3.1 Fase 1: análisis y definición de requerimientos

Esta fase corresponde al primer objetivo específico. Su punto de partida es la revisión bibliográfica sobre SLAM visual monocular, posicionamiento satelital, sensores inerciales, fusión de sensores, aprendizaje por refuerzo, operación en tiempo real y métricas de evaluación, cuyo resultado es el marco teórico del Capítulo 2. De esa revisión se obtienen las técnicas candidatas y las métricas con que se evaluará la plataforma, descritas en las Secciones 2.9 y 2.10.

La revisión se complementa con la documentación técnica del dispositivo móvil y con mediciones realizadas sobre él, ya que varios requerimientos dependen de sus características reales y no de valores nominales. Entre esas mediciones se encuentran la frecuencia efectiva de las soluciones GPS, el retraso entre la captura de una imagen y su llegada a la computadora, la frecuencia de muestreo de los sensores inerciales y los parámetros intrínsecos de la cámara. Como varias de estas mediciones solo pueden obtenerse una vez construidos los módulos de adquisición, los requerimientos se refinan durante la Fase 2, lo que corresponde a la retroalimentación indicada en la Fig. 9.

Los requerimientos se agrupan en funcionales, computacionales y temporales, y se consoli-

dan en el documento de requerimientos. El profesor asesor evalúa y valida ese documento, lo que constituye el criterio de experto previsto en el primer objetivo específico. Los criterios cuantitativos y los valores específicos con que se verificará el cumplimiento de cada requerimiento se definen en conjunto con el asesor como parte de esta validación.

3.3.2 Fase 2: diseño e implementación de la plataforma

Esta fase corresponde al segundo y al tercer objetivo específico. Se desarrolla mediante incrementos, cada uno de los cuales produce una versión de la plataforma capaz de procesar grabaciones y que se verifica antes de pasar al siguiente. La arquitectura resultante y las decisiones de diseño de cada incremento se documentan en el capítulo siguiente; aquí se describe el método seguido en cada uno.

Punto de partida. El punto de partida es la plataforma previa descrita en el Capítulo 1, que procesa secuencias grabadas sin restricción de tiempo. La odometría visual de la plataforma en tiempo real conserva los mismos parámetros que la previa: número de características ORB, criterio de emparejamiento, umbral de la prueba de razón y número mínimo de correspondencias. Una prueba automática verifica que esos parámetros coincidan en ambos sistemas, de modo que los diagnósticos realizados sobre la plataforma previa sigan siendo válidos para la nueva.

Canal de procesamiento en tiempo real. Se construye primero el canal de procesamiento, con hilos independientes para la captura de cuadros, la recepción de las posiciones GPS y el procesamiento, con la política de descarte del cuadro más antiguo descrita en la Sección 2.9 y con la medición de los tiempos por etapa, la latencia y la tasa de descarte. Las fuentes de datos son intercambiables: el canal recibe los datos con el mismo formato tanto de una grabación como del teléfono en vivo, de modo que el sistema que se evalúa sobre grabaciones es el mismo que opera en campo. Sobre grabaciones, el canal admite dos modos de ejecución. En el modo estricto respeta el tiempo real entre cuadros y descarta cuadros como lo haría en operación, por lo que reproduce el comportamiento real pero no es determinista. En el modo determinista procesa todos los cuadros sin esperar y calcula después los descartes a partir de los tiempos medidos; al ser reproducible, es el modo que se emplea durante el desarrollo y para las cifras que se reportan.

Escala métrica. Dado que la odometría visual monocular no determina la escala, según se explicó en la Sección 2.4.6, antes de integrar una fuente de escala en la plataforma se evaluaron tres alternativas: la recuperación por plano de tierra, la escala derivada de las posiciones GPS y la profundidad estimada por un modelo monocular [30]. Cada alternativa se evaluó primero mediante un sondeo mínimo sobre secuencias del conjunto KITTI [6], cuya trayectoria de referencia de alta precisión se utiliza únicamente para evaluar. Para imitar las condiciones del teléfono, el GPS de KITTI se degrada a una solución por segundo con ruido añadido. Dado que un menor error de escala no garantiza una mejor trayectoria, las alternativas se compararon también por la trayectoria que producen, con una alineación rígida que no compensa los errores de escala. La alternativa

seleccionada se integró después en la plataforma, en un hilo propio que no detiene el procesamiento principal.

Aplicación móvil y protocolo de red. En paralelo con el canal de procesamiento se desarrolló, en Java y con el entorno Android Studio, una aplicación para Android que adquiere el video, las posiciones GPS y las mediciones inerciales del teléfono. Su desarrollo siguió fases propias: compilación y ejecución en el teléfono, medición de la frecuencia del GPS, registro del GPS en archivo, transmisión del GPS, transmisión del video y control remoto de la grabación. La aplicación y el canal de procesamiento residen en repositorios separados y se comunican únicamente a través de un protocolo de red definido para el proyecto: el video se transmite por TCP junto con los parámetros intrínsecos de la cámara y la marca de tiempo de cada cuadro, mientras que las posiciones GPS, el estado y las órdenes de control viajan por UDP. Definir esa interfaz como único punto de unión permite desarrollar y verificar cada lado por separado. El lado del teléfono se verificó con clientes de referencia independientes del canal de procesamiento, y se comprobó que los cuadros transmitidos coinciden con los que se graban en el teléfono. La aplicación ofrece además un modo que transmite y graba a la vez, de modo que cada sesión en vivo deja una grabación completa que puede volver a procesarse en el modo determinista. Más adelante se incorporaron la transmisión en vivo de las mediciones inerciales, necesaria para que la fusión utilice el giroscopio en campo, y una consulta de hora que permite medir la latencia desde la captura pese a la diferencia entre los relojes del teléfono y de la computadora.

Integración en escritorio. Antes de cualquier prueba de campo, el canal de procesamiento y la aplicación se integraron en un entorno de escritorio. Para ello se desarrolló un simulador del teléfono que sirve una grabación con el mismo protocolo de la aplicación, con la cámara en tiempo real, el descarte de cuadros cuando la computadora se retrasa y la entrega de cada posición en el instante en que el video alcanza su marca de tiempo. El simulador permite verificar el cliente en vivo y la interfaz gráfica sin depender del teléfono, de la red ni del vehículo.

Fusión de sensores. Sobre la plataforma integrada se implementó el filtro de Kalman extendido descrito en la Sección 2.7, con niveles de ruido medidos sobre grabaciones realizadas en vehículo. Las variantes del filtro se comparan entre sí sobre las mismas grabaciones, con cortes de GPS simulados y con el GPS degradado de forma sintética, y se conserva un modo que utiliza únicamente la información visual como referencia de comparación.

Mecanismo de aprendizaje por refuerzo. El último incremento corresponde al tercer objetivo específico y se construye sobre el filtro del incremento anterior, que actúa como referencia de comparación. Su formulación es la de la Sección 2.8.3; la configuración del entrenamiento y los resultados se documentan en el capítulo siguiente. Antes de construir el mecanismo se midió el margen de mejora disponible, comparando el filtro convencional con un oráculo que elige, en cada corte del GPS, el mejor ajuste constante. Esa medición ubicó el margen en la confianza que el filtro asigna a la rapidez de la cámara durante las pérdidas del GPS, y no en el peso del GPS, por lo que la acción se limitó a ese ajuste.

Los datos de entrenamiento son las grabaciones propias en vehículo, procesadas una vez en el modo determinista y guardadas, de modo que el entrenamiento recorre las mediciones sin volver a procesar el video. Como su única referencia de posición es el propio GPS del teléfono, la recompensa se construye con cortes de GPS simulados: el filtro no recibe las soluciones de un intervalo, y esas soluciones ocultas se emplean solo para calcular la recompensa y para evaluar, nunca como entrada de la política. Las secuencias de KITTI no se emplearon en este incremento, porque sus sensores difieren de los del teléfono y su GPS tendría que degradarse de forma artificial.

El algoritmo elegido es Q-learning tabular (Sección 2.8), porque la acción se elige entre pocos valores, los datos de entrenamiento son limitados y la consulta de una tabla cabe con holgura en el presupuesto de tiempo de cada cuadro (Sección 2.9).

El protocolo de entrenamiento y de evaluación, incluido el criterio de éxito, se fijó por escrito antes de la primera ejecución, y lo que se reporta es la primera corrida completa. La evaluación deja por turno una grabación fuera del entrenamiento, con varias semillas, y reserva para validar una grabación realizada con otra aplicación y otra orientación de la cámara. La política se compara con el filtro convencional, con una regla de un solo umbral sobre la rapidez, ajustada con los mismos datos, y con el oráculo. Como controles contra artefactos se repite la corrida para verificar su reproducibilidad y se entrena con los estados barajados. Una segunda iteración, con su protocolo también fijado de antemano, agrega como línea base un peso fijo de la cámara durante los cortes.

3.3.3 Fase 3: validación experimental

Esta fase, de validación experimental y evaluación de desempeño, corresponde al cuarto objetivo específico. Su primera actividad es el diseño del protocolo experimental, que define los recorridos, su cantidad y las condiciones en que se realizan. En línea con las acciones de mitigación de riesgos del anteproyecto, se procura que los recorridos cubran condiciones distintas de iluminación, textura de la escena y visibilidad del cielo, que son las que degradan a cada fuente según la Tabla 3.

Modos de evaluación. Las cifras de precisión se obtienen procesando las grabaciones en el modo determinista, lo que garantiza que cualquier configuración pueda volver a evaluarse sobre exactamente los mismos datos. El comportamiento temporal se mide además en el modo estricto y en operación en vivo, que son los que reflejan la latencia y el descarte de cuadros reales.

Configuraciones comparadas. Sobre las mismas grabaciones se comparan tres configuraciones: la plataforma con información exclusivamente visual, la fusión con el filtro convencional y la fusión con el peso de la rapidez de la cámara ajustado por la política. La plataforma previa no se emplea como referencia de comparación: la comparación del cuarto objetivo se realiza dentro del mismo canal de procesamiento, que puede ejecutar una grabación con fusión o en modo exclusivamente visual.

Referencias de evaluación. Las secuencias de KITTI, que cuentan con una trayectoria de referencia de alta precisión, se emplearon en los estudios de la Fase 2, como la selección de la fuente de escala y la verificación de la odometría visual. En las grabaciones propias no se dispone de una referencia de ese tipo, por lo que cada magnitud se contrasta con la medición independiente más confiable del propio teléfono: la forma y la distancia de la trayectoria con el GPS, la rotación con el giroscopio y la rapidez con la velocidad Doppler. El efecto de la fusión durante la pérdida de la señal satelital se evalúa con cortes de GPS simulados de distinta duración, comparando la estimación con las soluciones GPS que el filtro no utilizó. La robustez ante un GPS de mala calidad se evalúa degradando de forma sintética el GPS de las grabaciones, con ruido, saltos y pérdidas, y comparando la estimación con el GPS original.

Métricas y formas de análisis. Las métricas son las de las Secciones 2.9 y 2.10: el error absoluto de trayectoria tras una alineación rígida, la deriva durante los cortes de GPS, la latencia, la tasa de descarte, la frecuencia efectiva y el tiempo de cómputo por etapa, este último descrito mediante percentiles además del promedio. El error relativo de pose y la utilización de recursos computacionales, comprometidos en el anteproyecto, se incorporan a la herramienta de evaluación en esta fase. Los resultados se analizan por grabación y de forma agregada, comparando cada configuración con la anterior sobre los mismos datos.

Pruebas de campo. Las pruebas de campo se ejecutan con el sistema integrado, con el teléfono montado en horizontal en el tablero del vehículo y conectado a una computadora portátil por cable USB, mediante anclaje de red. Se emplea el modo que transmite y graba a la vez, de modo que cada recorrido deja una grabación de respaldo que se procesa después en el modo determinista. En cada prueba se verifican los cuadros recibidos y procesados, la llegada completa del GPS y de las mediciones inerciales en comparación con lo grabado por el teléfono, y la integridad de la grabación de respaldo.

3.3.4 Fase 4: análisis de resultados y documentación

En la última fase se consolidan los resultados de las fases anteriores y se contrastan con los objetivos y los entregables definidos. Se identifican las fortalezas y limitaciones de la solución, se formulan las conclusiones y las recomendaciones para trabajos futuros, y se elabora el informe final, incluido el apéndice de implicaciones ambientales y de desarrollo sostenible que exigen los lineamientos [10]. La fase concluye con la preparación del material para la defensa ante el tribunal evaluador.

3.4 Herramientas y recursos

La Tabla 4 resume las herramientas y los recursos empleados en el proyecto.

Tabla 4: Herramientas y recursos del proyecto

Tipo	**Herramienta o recurso y uso en el proyecto**
Dispositivo móvil	Samsung Galaxy S23: cámara principal de 1280×720 píxeles a 30 cuadros por segundo, receptor GPS, giroscopio y acelerómetro.
Computadoras	Computadora de escritorio con procesador AMD Ryzen 5 5600X y tarjeta gráfica NVIDIA RTX 3070, para el desarrollo y las cifras de referencia; computadora portátil con procesador Intel Core i5-8300H y tarjeta gráfica NVIDIA GTX 1050 Ti, para las pruebas de campo; con Linux Mint 22.1 y 22, respectivamente. Ejecutan el canal de procesamiento, la fusión y la evaluación.
Lenguaje y entorno	Python 3.12 sobre Linux, con un entorno virtual que se configura mediante un guion de instalación incluido en el repositorio.
Visión computacional	OpenCV: detección y descripción ORB, emparejamiento, estimación de la matriz esencial con RANSAC, recuperación de la pose y triangulación.
Profundidad monocular	PyTorch y Transformers, para ejecutar el modelo Depth Anything V2 [30].
Cálculo y análisis	NumPy, SciPy, pandas y scikit-learn para el cálculo numérico y el análisis de datos; matplotlib para los gráficos; pyproj para la conversión a coordenadas UTM.
Interfaz	Tkinter, para la ventana que inicia, supervisa y detiene las sesiones.
Aplicación móvil	Aplicación propia para Android, desarrollada en Java con Android Studio, en un repositorio separado.
Datos	Secuencias del conjunto KITTI [6], con trayectoria de referencia de alta precisión; grabaciones propias en vehículo, la mayoría realizadas con la aplicación, que incluyen video, posiciones GPS con velocidad Doppler y mediciones inerciales con un reloj común.
Control de versiones	Git y GitHub, para el código de la plataforma y el de la aplicación.
Apoyo con inteligencia artificial	Claude y Claude Code, de Anthropic, como apoyo en tareas de programación, análisis y organización del proyecto.

Respecto del último recurso de la tabla, los asistentes de inteligencia artificial se emplearon como apoyo en tareas de programación, de análisis y de organización del proyecto. Las decisiones de diseño, la selección entre alternativas, la validación de los resultados y su interpretación corresponden al autor. El código desarrollado con ese apoyo se somete a las mismas estrategias de verificación que el resto de la plataforma, y los resultados que se reportan provienen de ejecuciones de la plataforma sobre los datos descritos en este capítulo.

3.5 Actores participantes

Estudiante. Es responsable del análisis, el diseño, la implementación, la ejecución de los experimentos, el análisis de los resultados y la documentación del proyecto, así como de las decisiones técnicas que se toman en cada fase.

Profesor asesor. El MSc. Luis Alberto Chavarría Zamora brinda la asesoría técnica y académica del proyecto. Evalúa y valida los requerimientos del sistema, revisa los informes quincenales de avance y los productos intermedios, y realiza las evaluaciones intermedias que establecen los lineamientos [10].

Organización. El proyecto se desarrolla en la Escuela de Ingeniería en Computadores del Tecnológico de Costa Rica, descrita en el Capítulo 1.

Tribunal evaluador. Los profesores lectores y el tribunal evalúan el informe final y la defensa oral, según los criterios de los lineamientos [10].

El seguimiento del proyecto se realiza mediante los informes quincenales de avance dirigidos al profesor asesor, que incluyen las tareas realizadas, las tareas planificadas para el siguiente periodo y un análisis de la situación del proyecto [10].

3.6 Desglose del marco metodológico

La Tabla 5 resume, para cada objetivo específico, las principales actividades, los entregables asociados, las técnicas o herramientas empleadas y las estrategias de verificación y validación. Los entregables coinciden con los definidos en la Tabla 2.

Tabla 5: Desglose del marco metodológico por objetivo específico

Objetivo	**Principales actividades**	**Entregables**	**Técnicas o herramientas**	**Verificación y validación**
OE1. Sintetizar los requerimientos funcionales, computacionales y temporales	Revisión bibliográfica y de documentación técnica. Medición de las características del dispositivo. Definición de requerimientos y de métricas de evaluación.	Documento de requerimientos. Definición de las métricas de evaluación.	Literatura científica, documentación técnica, mediciones sobre el teléfono.	Revisión de consistencia entre requerimientos, literatura y mediciones. Validación del asesor, con criterios cuantitativos definidos en conjunto.
OE2. Diseñar la plataforma SLAM híbrida	Canal de procesamiento en tiempo real. Selección e integración de la escala métrica. Aplicación móvil y protocolo de red. Integración en escritorio. Filtro de fusión.	Documento de arquitectura. Plataforma SLAM híbrida funcional.	Python, OpenCV, PyTorch, aplicación Android, KITTI, grabaciones propias.	Prueba automática de parámetros de la odometría visual. Sondeos con referencia solo para evaluar. Reproducción determinista. Simulador del teléfono. Clientes de referencia del protocolo.
OE3. Desarrollar el mecanismo de aprendizaje por refuerzo	Medición del margen de mejora. Definición del estado, la acción y la recompensa. Protocolo fijado antes de entrenar. Entrenamiento e integración en la plataforma.	Módulo de aprendizaje por refuerzo integrado. Configuración de entrenamiento.	Q-learning tabular; grabaciones propias procesadas de antemano; cortes de GPS simulados.	Evaluación dejando una grabación fuera, con varias semillas. Comparación con el filtro convencional, una regla de umbral y un oráculo. Controles contra artefactos.
OE4. Valorar experimentalmente el desempeño	Diseño del protocolo experimental. Recorridos controlados. Evaluación de las configuraciones. Análisis comparativo.	Resultados experimentales. Informe de evaluación.	Herramienta de evaluación de la plataforma, métricas de las Secciones 2.9 y 2.10.	Comparación sobre las mismas grabaciones. Cortes de GPS simulados. GPS degradado de forma sintética. Contraste con GPS, giroscopio y Doppler. Medición temporal en modo estricto y en vivo.

Capítulo 4

Descripción del trabajo realizado

Este capítulo describe el trabajo realizado para alcanzar los objetivos del proyecto, siguiendo el marco metodológico del Capítulo 3. La Sección 4.1 detalla el proceso de solución: los requerimientos de la plataforma, su arquitectura, las decisiones de diseño tomadas en cada incremento y el mecanismo de aprendizaje por refuerzo. La Sección 4.2 analiza los resultados obtenidos frente a cada objetivo específico, en cuanto al comportamiento en tiempo real, la precisión de la localización y el aporte del aprendizaje por refuerzo, y cierra con las limitaciones de la solución. Como no se dispone de una trayectoria de referencia de alta precisión para las grabaciones propias, cada magnitud se contrasta con la medición independiente más confiable del teléfono: la posición con el GPS, la rotación con el giroscopio y la rapidez con la velocidad Doppler (Sección 3.3.3).

4.1 Descripción del proceso de solución

Esta sección sigue los incrementos de la Fig. 9. Primero se presentan los requerimientos obtenidos en la Fase 1 y la arquitectura resultante de la Fase 2. Después se describen las decisiones de diseño de cada incremento, cada una con el problema que la motivó, las alternativas consideradas y la medición que permitió elegir entre ellas.

4.1.1 Requerimientos de la plataforma

Los requerimientos se derivaron de los objetivos del proyecto y de las características medidas del dispositivo, ya que varias de ellas difieren de los valores nominales. La cámara del Samsung Galaxy S23 entrega 1280×720 píxeles a 30 cuadros por segundo, con los parámetros intrínsecos de su calibración de fábrica, que el teléfono envía al conectarse, y una distorsión no corregida de hasta 17 px en las esquinas. Cada cuadro tarda de 60 a 75 ms en llegar a la aplicación y, por cable, de 66 a 70 ms en llegar a la computadora en la mediana y de 73 a 76 ms en el percentil 95, de modo que una parte importante de la latencia ocurre antes del procesamiento. El GPS, que la aplicación obtiene del proveedor

de ubicación fusionado de Android, entrega una solución por segundo en el vehículo, con su velocidad Doppler y una antigüedad mediana de 0,4 a 0,5 s, y el giroscopio y el acelerómetro entregan unas 53 muestras por segundo. Todas las fuentes comparten el reloj de arranque del teléfono, que es el que se usa para alinearlas, mientras que su hora Unix difiere de la de la computadora en una cantidad que cambia de un día a otro.

La Tabla 6 presenta los requerimientos resultantes, agrupados en funcionales, computacionales y temporales, junto con la forma de verificar cada uno. Los valores de RT-1 y RT-2 son los que se emplearon como referencia durante el desarrollo; su validación por parte del profesor asesor, junto con los criterios cuantitativos de los demás requerimientos, se encuentra pendiente.

Las métricas de las Secciones 2.9 y 2.10 se implementaron en dos lugares. El canal de procesamiento registra por cuadro el tiempo de cada etapa, la latencia, el descarte y la frecuencia efectiva. Una herramienta de evaluación calcula sobre cada sesión el error de trayectoria con alineación rígida, la deriva desde un inicio común y durante cortes simulados del GPS, la escala frente a la Doppler y la rotación frente al giroscopio. El error relativo de pose y la utilización de recursos computacionales todavía no forman parte de esa herramienta.

Tabla 6: Requerimientos propuestos para la plataforma

Id.	Requerimiento	Verificación
RF-1	Recibir en vivo del teléfono el video, las posiciones GPS con su velocidad Doppler y las mediciones inerciales, con marcas de tiempo de un reloj común.	Comparación de lo recibido con lo grabado por el teléfono.
RF-2	Procesar grabaciones con el mismo canal y el mismo formato que en vivo, con un modo de ejecución determinista.	Repetición de corridas sobre una misma grabación.
RF-3	Estimar en cada cuadro la posición y el rumbo en un plano métrico, combinando la cámara, el giroscopio y el GPS.	Predicción frente a cada solución GPS nueva.
RF-4	Mantener la estimación durante las pérdidas del GPS y rechazar las soluciones incompatibles con la predicción.	Cortes simulados y GPS degradado de forma sintética.
RF-5	Ejecutar una misma grabación en modo exclusivamente visual.	Comparación del cuarto objetivo.
RF-6	Ajustar el peso de una fuente mediante una política con estado y recompensa explícitos.	Protocolo de evaluación del tercer objetivo.
RF-7	Mostrar durante la operación el video, el estado del sistema y la trayectoria, y registrar cada sesión.	Sesiones en vivo y sobre grabaciones.
RC-1	Ejecutarse en una computadora con tarjeta gráfica NVIDIA y Linux, incluida una portátil a bordo del vehículo, sin depender de una conexión a internet.	Prueba con la red desconectada y prueba de campo.
RC-2	Mantener el costo de la fusión y de la política despreciable frente al presupuesto de cada cuadro.	Tiempo por etapa.
RT-1	Latencia de la captura al resultado con percentil 95 menor que 150 ms.	Latencia medida con el reloj del teléfono.
RT-2	Frecuencia efectiva de al menos 10 Hz.	Ecuación (2.34).
RT-3	Latencia acotada ante sobrecarga, mediante el descarte de cuadros.	Cola de una posición (Fig. 7).

4.1.2 Arquitectura de la plataforma

La Fig. 10 muestra la arquitectura de la plataforma. Se compone de dos programas independientes, la aplicación del teléfono y el canal de procesamiento de la computadora, unidos únicamente por el protocolo de red.

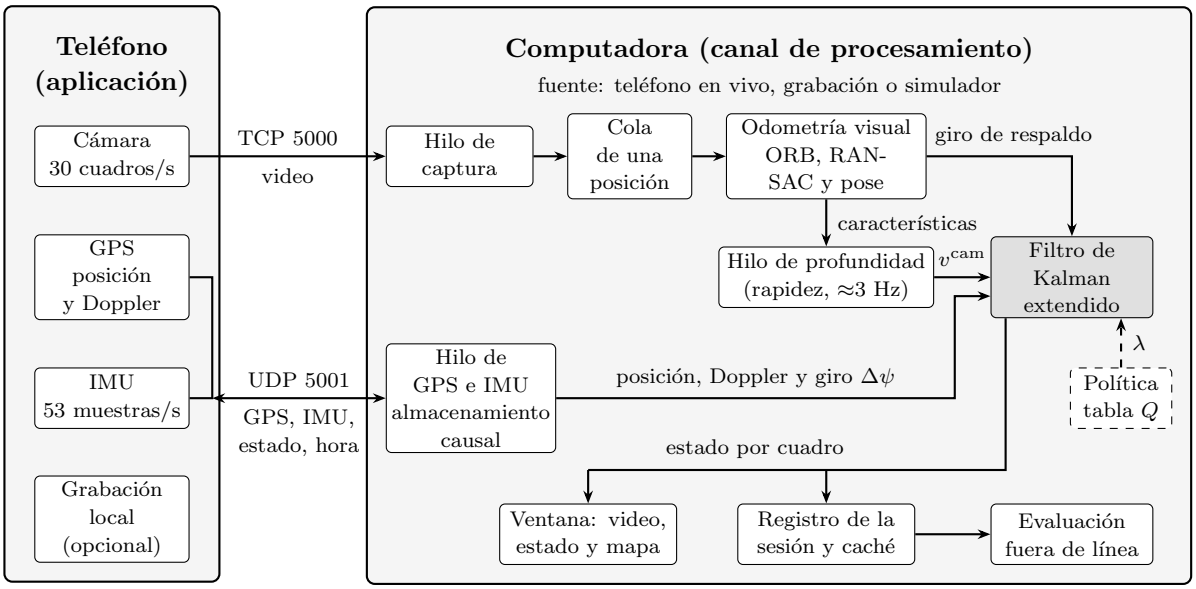


Fig. 10: Arquitectura de la plataforma. La aplicación y el canal de procesamiento solo comparten el protocolo de red. La política, en línea discontinua, aún no está integrada en el canal. Fuente: elaboración propia.

Aplicación y protocolo. La aplicación actúa como servidor. Al conectarse, la computadora recibe por TCP los parámetros de la cámara y después cada cuadro en formato JPEG con su instante de captura, y por UDP cada posición GPS y cada muestra de la IMU, con el mismo formato con que el teléfono las guarda en sus archivos. Por el mismo canal UDP, la computadora inicia o detiene la grabación en el teléfono y consulta su hora. El teléfono no encola cuadros: si la red está ocupada los descarta, de modo que el retraso no crece.

Canal de procesamiento. El canal separa en hilos distintos la captura, la recepción de los sensores y el procesamiento. Los cuadros llegan a una cola de una sola posición que descarta el más antiguo (Sección 2.9), y las posiciones y muestras inerciales se almacenan de forma causal, de modo que cada cuadro solo accede a lo recibido hasta su marca de tiempo. El hilo de procesamiento ejecuta la odometría visual y una etapa del filtro por cuadro, mientras que la rapidez del modelo de profundidad se calcula en un hilo aparte que reutiliza las características de la odometría visual. Cada sesión se guarda en disco, con el estado del filtro por cuadro, las posiciones, las muestras inerciales y las métricas temporales, y se muestra durante la operación en una ventana con el video y el mapa de la trayectoria fusionada. Como la diferencia entre el reloj del teléfono y el de la computadora varió de un día a otro entre -56 y $+132$ ms, la latencia desde la captura se mide consultando la hora del teléfono cada 0,5 s y tomando la consulta de ida y vuelta más rápida del último minuto; por cable, el error de esta sincronización fue de a lo sumo 0,5 ms.

Modos de ejecución. Las fuentes son intercambiables: el teléfono en vivo, una grabación o un simulador del teléfono, que sirve una grabación con el protocolo de la aplicación y permitió integrar el canal y la interfaz antes de usar el teléfono. Sobre grabaciones,

el modo determinista produjo resultados idénticos bit a bit en corridas repetidas y, en la computadora de escritorio, predijo el descarte y la latencia del modo estricto con diferencias cercanas a 1 ms. Sus resultados se guardan en una caché indexada por el contenido de la grabación, las opciones de la corrida y el código que la produce, de modo que un cambio en la grabación, en las opciones o en los módulos del canal obliga a reprocesar. El modo exclusivamente visual ejecuta la misma grabación sin usar el GPS después del arranque y es la línea base del cuarto objetivo. El detalle de los módulos y del protocolo corresponde al documento de arquitectura, entregable del segundo objetivo.

4.1.3 Estimación de la escala métrica

El análisis del punto de partida mostró que la plataforma previa no disponía de una escala propia para la cámara. La recuperación de la pose entrega una traslación de norma unitaria (Sección 2.4.6), y la plataforma previa le asignaba en cada paso la longitud medida por el GPS y orientaba la trayectoria hacia la dirección del GPS, de modo que no existían dos fuentes independientes que fusionar. Una medición con el GPS degradado de forma sintética lo confirmó: el error de la odometría visual aumentó de 41 a 250 m cuando la desviación estándar del ruido añadido pasó de 3 a 10 m, algo que no ocurriría con una estimación visual independiente.

Se evaluaron tres fuentes de escala: la derivada de las posiciones GPS, la recuperación por plano de tierra y la profundidad estimada por un modelo monocular. En KITTI, con la trayectoria de referencia empleada solo para evaluar, el error mediano de escala fue cercano a 45 % con el GPS a 1 Hz y a 50 % con una implementación simple del plano de tierra, por lo que se eligió el modelo Depth Anything V2 en su variante métrica para exteriores [30], que además no consume el GPS.

El primer intento de integrarlo falló por la base de triangulación y no por el modelo. A 30 cuadros por segundo el vehículo avanza unos 0,14 m entre cuadros consecutivos, lo que no basta para triangular puntos a 10–50 m: con esa separación, la razón entre la escala estimada y la real fue de 2,64, mientras que entre cuadros separados 0,33 s, con una base de 2,38 m, fue de 1,08. Por ello la Ecuación (2.13) se evalúa entre cuadros separados 0,33 s, solo con puntos de entre 3 y 60 m de profundidad, y su resultado se suaviza con la mediana de las últimas siete estimaciones. Sobre las siete secuencias utilizables de KITTI, el error mediano de escala osciló entre 10 y 37 % en las seis urbanas y alcanzó 63 % en la de autopista; es mínimo entre 6 y 12 m/s y crece por debajo de 6 m/s, hasta 57 % bajo 2 m/s por falta de base, y por encima de 12 m/s, cuando la escena se aleja del rango útil del modelo.

En las grabaciones en vehículo apareció una dependencia adicional. El modelo reescala cada imagen a un lado corto fijo sin conocer la distancia focal, de modo que recortar la franja inferior de la imagen, donde aparece el capó, cambiaba la escala de píxeles y reducía la profundidad estimada en cerca de 30 %. Por esa razón, en lugar de recortar la imagen se aplica una máscara que impide detectar características en esa franja, y el

modelo recibe la imagen completa. Aun así, con la máscara la distancia medida por la cámara superó a la del GPS en 10 % en una grabación y en 59 % en otra, lo que llevó a tratar la rapidez de la cámara como una medición cuyo factor de escala κ estima el filtro con la Doppler (Ecuación (2.21)), y no como una escala absoluta. La estimación corre en su propio hilo, a unos 3 Hz; en la computadora de escritorio sumó 2,3 ms a la mediana de la latencia, sin reducir la frecuencia de 30 Hz, aunque cada inferencia del modelo tarda unos 88 ms.

Detección del vehículo detenido. Con el vehículo detenido no hay base de triangulación, y la cámara reportaba una rapidez mediana de 0,44 a 0,64 m/s. La razón entre inliers y correspondencias y el flujo de las características no separaron al vehículo detenido del que avanza lentamente: el capó oculta los puntos cercanos, el avance entre cuadros consecutivos es menor que un píxel y el teléfono gira en los altos por el cabeceo del vehículo. Sí los separó el residuo que queda después de ajustar la rotación pura que mejor explica el movimiento de los puntos entre cuadros separados 0,33 s, ya que un giro sin avance no produce paralaje: su mediana fue de 1,1 a 1,3 px con el vehículo detenido, de 3,0 px a 1–1,5 m/s y de 7,6 a 8 px por encima de 5 m/s. La regla adoptada declara la detención cuando el residuo es menor que 2 px en dos estimaciones seguidas y la rapidez estimada es menor que 3 m/s, y la retira cuando supera 3 px; el límite de rapidez evita falsas detenciones en autopista, donde la escena lejana también deja poco paralaje. En las dos grabaciones completas del 30 de septiembre, la regla detectó el 85 y el 97 % de los cuadros con el vehículo detenido según el GPS, marcó como detenidos solo el 1,1 y el 0,6 % de los cuadros a más de 1 m/s, y eliminó 92 y 38 m de avance falso.

4.1.4 Corrección de la odometría visual

La odometría visual conserva la configuración de la plataforma previa: 2000 características ORB, emparejamiento por fuerza bruta con distancia de Hamming, prueba de razón con umbral 0,75 y más de 15 correspondencias por par de cuadros; la matriz esencial se estima con RANSAC, con probabilidad 0,999 y umbral de 1 px. Se reimplementó en el canal de tiempo real en lugar de importar el código previo, que se conservó sin cambios como referencia histórica, para no arrastrar los errores detectados en él, entre ellos el uso por defecto de los parámetros intrínsecos de KITTI.

Validación con el giroscopio. Para medir la rotación sin una trayectoria de referencia se empleó el giroscopio como instrumento: la rotación que resulta de integrar su velocidad angular entre dos cuadros con la Ecuación (2.16) se compara con la estimada por la cámara. Con este método se comprobó que el procesamiento de una grabación y la operación en vivo producen el mismo error de rotación, de 0,32° y 0,33° por cuadro sobre los mismos 2114 pares de cuadros, lo que respalda el uso de grabaciones en la evaluación.

Composición de poses. Las comparaciones en el plano horizontal revelaron un error heredado de la plataforma previa en la composición de la Ecuación (2.12). La recuperación de la pose entrega la transformación que lleva los puntos del cuadro anterior al actual,

mientras que la cámara se mueve con la transformación inversa; el código previo componía la primera, lo que espeja cada giro. Un experimento sintético con una cámara que avanza 1 m y gira 10° lo confirmó: con la composición previa la cámara terminaba en $z = -0{,}985$ m y con la inversa, en $z = +1$ m. El error había pasado inadvertido porque la alineación tridimensional de las gráficas compensa un recorrido plano espejado girándolo 180°.

Saltos de rumbo. La primera línea base exclusivamente visual en vehículo, sobre dos fragmentos de unos 4 min de las grabaciones del 30 de septiembre, mostró errores de rumbo de hasta 810° y 294° frente al giroscopio. El error no crecía de forma gradual: el 0,4 % de los pasos, con giros de más de 5°, explicaba entre el 56 y el 71 % del error de rotación. Al examinar esos pasos uno por uno se encontró la causa en la función de recuperación de la pose de OpenCV: antes de elegir entre las cuatro soluciones de la matriz esencial, descarta los puntos situados a más de 50 veces el desplazamiento entre cuadros, y con el vehículo detenido, lento o frente a una escena lejana no queda ninguno, de modo que las cuatro soluciones empatan y se devuelve la primera. En 52 de los 57 pasos de más de 5°, esa solución era la correcta girada 180°. La corrección consiste en que voten todos los puntos, sin costo adicional. Se añadió además un límite físico de 10° de giro por paso: un paso que lo excede se trata como un paso sin pose, lo que deja pasar el bache más fuerte registrado, de 9,7° según la cámara y 9,5° según el giroscopio, y rechaza los fallos observados, de entre 11° y 180°. Con la máscara y el voto de todos los puntos, el error máximo de rumbo de los dos fragmentos bajó de 810° a 91° y de 294° a 24°, y en las siete secuencias de KITTI, con la composición corregida y el voto, la separación final respecto de la trayectoria de referencia, aislando la forma, pasó de entre 5 y 140 % de lo recorrido con el código original a entre 2 y 14 %.

Rumbo a partir del giroscopio. Aun corregida, la cámara sola acumula una deriva de rumbo de 19° a 55° por minuto frente al giroscopio, que no se redujo de forma apreciable al corregir la distorsión del lente, reubicar el centro óptico, probar otras distancias focales o ampliar la franja enmascarada. Al integrar en el plano distintas combinaciones de giro y rapidez se comprobó que el error dominante era el rumbo y no la escala: con el giro de la cámara la separación final fue de 58 y 85 % de lo recorrido, y con el giro del giroscopio, de 11 y 10 %, aun con la rapidez de la cámara. El rumbo del giroscopio, en cambio, derivó entre 1,2° y 1,7° por minuto frente al rumbo del GPS. Con esta evidencia, y con la aprobación del profesor asesor, se decidió que el rumbo del filtro provenga del giroscopio y que la cámara aporte la rapidez y, solo cuando faltan muestras de la IMU, el giro. Esta decisión dejó sin efecto la limitación del anteproyecto que excluía los sensores inerciales, sin modificar los objetivos específicos.

4.1.5 Filtro de fusión

El filtro implementado es el de la Sección 2.7, con el estado de la Ecuación (2.21) y la predicción de la Ecuación (2.22). La vertical se estima con la Ecuación (2.15), con una

constante de tiempo de 20 s, y el filtro arranca cuando el GPS registra un avance de 20 m seguidos a 3 m/s o más, con el rumbo de esa cuerda como rumbo inicial. Los niveles de ruido de la Tabla 7 se midieron sobre las grabaciones antes de ejecutar el filtro, contra el giroscopio y la Doppler, en lugar de ajustarse según su efecto en los resultados.

Tabla 7: Mediciones y niveles de ruido del filtro

Elemento	**Valor**	**Origen**
Posición y Doppler del GPS	$\sigma = 4$ m y 0,3 m/s	Exactitud del GPS del teléfono; con σ de posición entre 3 y 6 m los resultados casi no cambian.
Rumbo entre soluciones	$\sigma = 0{,}5$ m en la cuerda, solo si su longitud difiere menos de 1,5 m de la que predice la Doppler	Los pasos del GPS coinciden con la Doppler con una desviación absoluta mediana de 0,3 m.
Rapidez de la cámara (v/κ)	20 % más 0,5 m/s, una vez por segundo	Cociente entre la Doppler y la cámara, con ruido de 12 a 19 %; piso por el error a baja rapidez.
Detenido ($v = 0$)	$\sigma = 0{,}5$ m/s	Doppler con el vehículo detenido según la cámara.
Rumbo del giroscopio	$0{,}5°/\sqrt{\text{s}}$	Residuo frente al rumbo del GPS.
Rapidez v	Paseo aleatorio de 1 m/s por $\sqrt{\text{s}}$	Función de estructura de la Doppler entre 1 y 10 s.
Factor de escala κ	Deriva de 10 % por $\sqrt{\text{s}}$, acotado entre 0,2 y 5	Cociente entre la Doppler y la cámara.

Validación de las mediciones. Cada medición se valida con la innovación normalizada de la Ecuación (2.24) al 99,9 % de la distribución chi cuadrado. Si una solución GPS se rechaza dos veces seguidas, la siguiente se acepta inflando la covarianza, para que el filtro no quede ciego cuando el error es de la predicción; esa aceptación forzada solo procede si el vehículo pudo llegar a esa posición a 40 m/s desde la última solución que coincidió con la predicción, y no mientras las soluciones rechazadas permanezcan desplazadas por un mismo vector, lo que caracteriza una ráfaga de errores del GPS. La rapidez de la cámara nunca se fuerza, y tampoco el rumbo entre soluciones cuando el giroscopio está disponible; la primera, además, no se usa si implica un factor de escala fuera del intervalo de 0,2 a 5. Para verificar estas reglas se insertaron soluciones a 1 km de la trayectoria en 20 puntos de cada grabación: una, dos, tres, cinco y diez seguidas fueron rechazadas en todos los casos, y la trayectoria se desplazó como máximo 8 m.

Pérdidas del GPS. Durante una pérdida del GPS el factor κ se congela dos segundos después de la última solución, ya que sin una rapidez de referencia el filtro repartía cada cambio de la rapidez de la cámara entre v y κ. Además, la incertidumbre de la posición a lo largo del camino crece con la distancia recorrida según el desajuste típico entre la

escala congelada y la necesaria, de 18 %. Sin ese término el filtro era demasiado confiado al terminar una pérdida y rechazaba la primera solución buena en el 10 a 72 % de los casos; con él, en el 0 a 10 %, sin cambiar la trayectoria estimada.

Evolución del filtro. La Tabla 8 compara las variantes del filtro en las dos grabaciones del 30 de septiembre, con un corte simulado cada 10 s; la primera versión tomaba el rumbo y la rapidez de la cámara como entradas de la predicción.

Tabla 8: Error al volver el GPS según la variante del filtro, en metros (mediana / percentil 90), con un corte simulado cada 10 s

	Grabación 14:05			**Grabación 14:18**		
Variante	10 s	30 s	120 s	10 s	30 s	120 s
Rumbo y rapidez de la cámara	7,5 / 45	31,6 / 143	148 / 426	18,3 / 89	44,4 / 336	395 / 2194
Cámara, con la rapidez como estado	7,4 / 31	33,9 / 129	155 / 430	14,5 / 60	52,2 / 302	421 / 2121
Giroscopio, sin la rapidez como estado	6,7 / 34	19,0 / 95	69 / 373	16,0 / 89	41,6 / 250	171 / 1526
Giroscopio y rapidez como estado	**4,9 / 23**	**15,7 / 79**	**61 / 318**	**10,6 / 43**	**27,3 / 178**	**178 / 1348**
Ídem, con el sesgo del giroscopio	4,9 / 23	16,4 / 79	60 / 318	11,3 / 43	27,5 / 178	198 / 1348
GPS extrapolado a velocidad constante	13,2 / 40	53,8 / 192	357 / 1012	21,1 / 45	79,1 / 254	693 / 1268

El giroscopio es lo que más reduce el error en los cortes largos, porque elimina el error de rumbo, y tratar la rapidez como estado reduce los peores casos, ya que la rapidez de la cámara que falla en autopista se rechaza en lugar de entrar en la predicción. La estimación del sesgo del giroscopio no mejoró ninguna duración y quedó desactivada. La configuración elegida supera a la primera versión en todas las duraciones de ambas grabaciones, y al GPS extrapolado a velocidad constante en el 72 a 96 % de los cortes de la grabación de las 14:05 y en el 65 a 80 % de los de las 14:18; la excepción es el percentil 90 de los cortes de 120 s de esta última, dominados por un tramo de autopista.

Ajustes por el GPS degradado. Un banco de pruebas con el GPS de dos sesiones de campo degradado de forma sintética mostró dos debilidades. Con ruido blanco de 5 m la fusión quedaba peor que el propio GPS, con un percentil 95 de 35 m frente a 12 m, porque los rumbos entre soluciones ruidosas que pasaban la validación torcían el rumbo; además, tras dos rechazos el filtro forzaba y seguía las ráfagas de errores. Se adoptaron dos cambios: usar el rumbo entre soluciones solo si la longitud de la cuerda concuerda con la Doppler, sin forzarlo cuando el giroscopio está disponible, y no forzar soluciones desplazadas por un mismo vector durante hasta 10 s. Con el GPS de las grabaciones, los cambios prácticamente no alteraron las correcciones aceptadas, ya que solo se descartó un rumbo entre soluciones de 355 en una sesión; su efecto con el GPS degradado se analiza

en la Sección 4.2.3. La alternativa de adaptar la varianza del GPS se reservó para el mecanismo de aprendizaje por refuerzo (Sección 4.1.6).

Integración en el canal. Sobre una grabación, la fusión dentro del canal reproduce la ejecución fuera de línea con diferencias de posición menores que 0,5 mm, y su costo es de 0,13 a 0,14 ms por cuadro en la computadora de escritorio. En el modo exclusivamente visual, el GPS solo fija la posición y el rumbo iniciales; después el filtro continúa con la rapidez de la cámara, con su propia escala ($\kappa = 1$), y con el giro de la cámara o, si se habilita, del giroscopio.

4.1.6 Mecanismo de aprendizaje por refuerzo

Medición del margen. Antes de construir el mecanismo se midió, con el filtro terminado, dónde existía margen para una política. Para la confianza en la rapidez de la cámara durante las pérdidas del GPS se compararon, en 324 cortes de 10 a 30 s de las cuatro sesiones de campo, el filtro convencional, el mismo filtro sin la rapidez de la cámara durante el corte y un oráculo que elige el mejor de ambos en cada corte. El margen resultó grande: en los cortes de 30 s, el oráculo redujo el percentil 90 del error al volver el GPS de 195 a 111 m, un 43 %. Sin embargo, ninguna regla basada en una sola señal lo capturó: la mejor, un umbral sobre la rapidez evaluado dejando una sesión fuera, recuperó el 21 % de esa reducción y nada de la mediana. Para el peso del GPS, en cambio, el margen fue escaso: con el GPS de las grabaciones, un oráculo que elegía cada 10 s entre tres pesos observando el GPS limpio mantuvo el peso del filtro convencional entre el 96 y el 100 % del tiempo, y con ruido sintético de 10 o 20 m el margen lo capturaba un peso fijo según el nivel de ruido, lo que corresponde a un problema de estimación más que de decisiones secuenciales. Por ello el mecanismo se limitó a la confianza en la rapidez de la cámara durante las pérdidas del GPS.

Una medición adicional con las dos grabaciones del 30 de septiembre mostró que una regla de umbral ajustada en una sesión puede empeorar otra: ajustada en la primera, capturó entre el 46 y el 86 % del margen de la segunda, y ajustada en la segunda, empeoró al filtro convencional en la primera. Este resultado motivó una política que considere varias señales a la vez y obligó a evaluar tanto la política como la regla dejando fuera la sesión de prueba.

Datos y entorno. El entrenamiento y la evaluación emplean seis sesiones en vehículo grabadas con la aplicación, las cuatro de la prueba de campo y las dos del 30 de septiembre, con 44 min de manejo con el filtro activo y 750 cortes de 10 a 30 s en la grilla de evaluación. Una séptima grabación, realizada con otra aplicación, con el teléfono en vertical y otra cámara, se reservó para validar en otro dominio. Cada sesión se procesó una vez en el modo determinista y se guardó en la caché, de modo que la fusión se vuelve a ejecutar sin el video y con la misma estimación que sobre la grabación completa. El entorno es una variante del filtro convencional que solo multiplica la varianza de la rapidez de la cámara por la acción λ de la Ecuación (2.31); con $\lambda = 1$ reproduce el filtro convencional

sin diferencia en toda la sesión, lo que se comprueba de forma automática. La política decide una vez por segundo y solo después de 1,5 s sin una solución GPS, ya que con el GPS presente ignorar la rapidez de la cámara durante toda la sesión no empeoró la predicción frente a cada solución; así, el comportamiento con el GPS disponible no cambia por construcción. Cada episodio parte de una copia del filtro convencional en un segundo de la sesión y simula una pérdida de 10 a 60 s, que termina con la solución con que vuelve el GPS.

Estado, acciones y recompensa. El estado es el de la Ecuación (2.32), con cada señal discretizada en tres niveles según la Tabla 9, lo que da 243 estados. Los umbrales de la dispersión y de la innovación normalizada son los terciles de esas señales en las decisiones de la grilla de las seis sesiones, calculados antes de entrenar y sin usar el error; como incluyen la sesión de prueba, constituyen una fuga de información leve, declarada en el protocolo. La recompensa es la de la Ecuación (2.31), con $c_\lambda = 0{,}1$ m; al medirse contra el filtro convencional en el mismo corte, elimina la dificultad propia de cada tramo sin cambiar la política óptima, porque el término que se resta no depende de las acciones.

Tabla 9: Señales del estado de la política y sus niveles

Señal	Descripción	Niveles
$\Delta t_n^{\mathrm{GPS}}$	Tiempo desde la última solución GPS.	≤ 5; ≤ 15; > 15 s
$\hat{v}_n$	Rapidez estimada por el filtro.	≤ 6; ≤ 12; > 12 m/s
$\sigma_n^{\mathrm{D/c}}$	Coeficiente de variación del cociente entre la Doppler y la rapidez de la cámara en las últimas 10 soluciones.	$\leq 0{,}17$; $\leq 0{,}29$; $> 0{,}29$
$\bar{\nu}^2_{\mathrm{c},n}$	Innovación normalizada media de las últimas 5 rapideces de la cámara, calculada con el peso del filtro convencional para que siga disponible cuando la medición se descarta.	$\leq 0{,}28$; $\leq 1{,}03$; $> 1{,}03$
f_n^{det}	Fracción de cuadros marcados como detenidos en los últimos 5 s.	0; $\leq 0{,}5$; $> 0{,}5$

Entrenamiento. La tabla Q se inicializa en cero y, ante un empate, se elige $\lambda = 1$, de modo que un estado no visitado se comporta como el filtro convencional. Se usa la actualización de la Ecuación (2.28) sin descuento ($\gamma = 1$), ya que el episodio termina al volver el GPS, con $\alpha = \max(1/N(s,a),\, 0{,}02)$, donde $N(s,a)$ es el número de visitas al par, y exploración ε-codiciosa (Ecuación (2.29)) con ε decreciente de forma lineal de 0,5 a 0,05. Cada política se entrena con 20 000 episodios, en unos 12 min; en cada episodio se sortean una sesión de entrenamiento, con probabilidad proporcional a su duración, un instante de inicio y una duración entera del corte entre 10 y 60 s, y las actualizaciones se aplican al terminar el episodio, en orden inverso.

Protocolo de evaluación. El protocolo se fijó por escrito antes de la primera ejecución, y lo que se reporta es la primera corrida completa; una prueba de funcionamiento previa, con dos sesiones, no se usó para ajustarlo. Para cada una de las seis sesiones se entrenan

políticas con las otras cinco y se prueban en ella, con tres semillas por prueba; la grabación de validación se prueba con políticas entrenadas en las seis. Se mide el error al volver el GPS en una grilla de cortes de 10, 20, 30 y 60 s, uno cada 10 s. Las líneas base son el filtro convencional, una regla de un solo umbral sobre la rapidez del filtro, elegido entre 0 y 20 m/s con las cinco sesiones de entrenamiento de cada prueba, y un oráculo que elige en cada corte la mejor acción constante. El criterio de éxito exige capturar al menos el 25 % del margen entre el filtro convencional y el oráculo en el percentil 90 de los cortes de 20 y de 30 s, con las seis sesiones de prueba juntas, sin que con el GPS presente el percentil 95 del error de predicción cambie más de 0,2 m.

Iteraciones. La primera iteración usa las acciones $\lambda \in \{1, 4, \infty\}$, donde $\lambda = \infty$ descarta la rapidez de la cámara. Su análisis (Sección 4.2.4) mostró que el filtro convencional confía de más en la cámara durante los cortes: con la escala congelada, el error de la rapidez de la cámara en los cortes típicos tiene una mediana de 29 %, frente al 20 % que supone el filtro, de modo que un peso fijo menor para la cámara durante los cortes es una línea base más exigente. Por ello se definió una segunda iteración, con su propio protocolo fijado antes de ejecutarla, que usa las acciones $\lambda \in \{1, 16, 256, \infty\}$, agrega ese peso fijo como línea base, elegido con las sesiones de entrenamiento de cada prueba, y exige superarlo en el percentil 90 de los cortes de 20 y 30 s sin empeorar la mediana del filtro convencional en más de 1 m. Como esta iteración se definió después de observar las sesiones de prueba, se declara así al reportarla. La política entrenada con las seis sesiones se guarda como una tabla de 14 kB junto con los niveles del estado y las acciones, y su integración en el canal de procesamiento y en la interfaz está pendiente.

4.2 Análisis de los resultados obtenidos

Esta sección analiza los resultados frente a los objetivos específicos, con las siete grabaciones en vehículo de la Tabla 10. Las cifras provienen de las sesiones en vivo de la prueba de campo, de corridas deterministas sobre las grabaciones y de bancos de prueba construidos sobre ellas, con el código vigente entre el 7 y el 12 de octubre, y son preliminares hasta la corrida final con el código congelado.

Tabla 10: Grabaciones empleadas

Grabación	Fecha	Duración	Recorrido	Rapidez máx.	Observaciones
14:05	30/9/2026	12,0 min	3,3 km	18,5 m/s	14 altos
14:18	30/9/2026	12,8 min	6,6 km	21,7 m/s	Camino mojado
14:52	11/10/2026	136 s	983 m	11,2 m/s	Prueba de campo
14:55	11/10/2026	353 s	1865 m	12,8 m/s	Prueba de campo
15:05	11/10/2026	254 s	2342 m	16,7 m/s	Prueba de campo
15:16	11/10/2026	506 s	3349 m	17,9 m/s	Prueba de campo, con lluvia
Validación	11/3/2025	289 s	1090 m	13,8 m/s	Otra aplicación, teléfono vertical

4.2.1 Comportamiento en tiempo real

La Tabla 11 compara el comportamiento temporal en vivo en las dos computadoras, con el teléfono conectado por cable y la escala por profundidad activa.

Tabla 11: Comportamiento temporal en vivo, con el teléfono conectado por cable

	Escritorio	Portátil conectada	Portátil con batería
Tiempo por cuadro, mediana	23–27 ms	48–54 ms	75–84 ms
ORB / emparejamiento / pose	9 / 6 / 7 ms	19–23 / 14–16 / 14 ms	32 / 22 / 20 ms
Frecuencia efectiva	30 Hz	≈19 Hz	11–13 Hz
Cuadros descartados	0,1–1 %	37 %	56–62 %
Captura a resultado, mediana / p95	97 / 107 ms	132–138 / 167–189 ms	164–169 / 201–219 ms
Inferencia de profundidad	88–97 ms	291 ms	442 ms
Filtro por cuadro, mediana	0,14 ms	0,15–0,23 ms	0,36–0,40 ms

En la computadora de escritorio la plataforma cumple los dos valores de referencia: procesa los 30 cuadros por segundo, descarta a lo sumo el 1 % y su latencia tiene un percentil 95 de 107 ms. En la portátil empleada en campo la frecuencia efectiva supera los 10 Hz, pero el percentil 95 de la latencia excede los 150 ms, tanto conectada a la corriente como con batería. El exceso proviene del cómputo y no del enlace: la captura hasta la llegada tomó 70/76 ms en la de escritorio y 66–67/73 ms en la portátil, mientras que el tiempo por cuadro de la portátil supera el periodo de 33,3 ms (Ecuación (2.33)), de modo que siempre hay un cuadro en espera. El cuello de botella es la odometría visual y no la fusión, que cuesta menos de 0,5 ms por cuadro. Reducir las características ORB a 1000 bajaría la latencia estimada en vivo de la portátil a unos 165 ms, todavía por encima de la referencia, y alteraría la odometría visual verificada, por lo que la prueba de campo

se realizó con la configuración vigente. El enlace sí determina la latencia por WiFi: el mismo día, con el mismo teléfono y la misma computadora, por WiFi el teléfono no envió el 22,8 % de los cuadros y la latencia fue de 112/224 ms, frente a ningún cuadro perdido y 97/107 ms por cable; por eso el campo se realizó con anclaje de red por USB.

4.2.2 Prueba de campo

La prueba de campo se realizó el 11 de octubre en cuatro sesiones en ciudad, de día y con lluvia intermitente, con la portátil a batería dentro del vehículo, el teléfono montado en el tablero y conectado por cable, y la opción de transmitir y grabar a la vez. La Tabla 12 resume el desempeño en vivo; una prueba previa a 5–8 km/h no arrancó el filtro, como corresponde a su condición de arranque.

Tabla 12: Desempeño en vivo durante la prueba de campo, con la portátil a batería

Sesión	**Cuadros procesados (descarte)**	**Frecuencia efectiva**	**Latencia, mediana / p95**	**Arranque del filtro**	**Predicción, mediana / p95**
14:52	1531 (62,5 %)	11,2 Hz	169 / 219 ms	13,7 s	1,3 / 3,2 m
14:55	4073 (61,5 %)	11,5 Hz	167 / 205 ms	2,6 s	1,4 / 3,4 m
15:05	3030 (60,1 %)	11,9 Hz	165 / 206 ms	14,0 s	2,0 / 4,3 m
15:16	6116 (59,7 %)	12,1 Hz	164 / 201 ms	25,4 s	2,0 / 5,3 m

Al comparar lo recibido con lo grabado por el teléfono coincidieron todas las posiciones GPS y todas las muestras de la IMU, con los mismos valores; el teléfono dejó de enviar entre 0 y 17 cuadros por sesión, y entre el 99,93 y el 99,98 % de los cuadros procesados coincidió con un cuadro grabado a menos de 1 μs. El filtro arrancó en las cuatro sesiones, giró con el giroscopio entre el 99,9 y el 100 % de los cuadros y no rechazó ninguna corrección de posición; su predicción a un segundo quedó a una mediana de 1,3 a 2,0 m de cada solución nueva. La innovación normalizada media de la posición, de 0,17 a 0,49 frente al valor esperado de 2, indica que la desviación de 4 m asignada al GPS es conservadora para este receptor. Aunque la portátil descartó cerca del 60 % de los cuadros, el reprocesamiento determinista de las mismas grabaciones, sin descarte, dio la misma precisión de la fusión, con medianas de 1,2 a 1,8 m, porque el giroscopio integra las muestras inerciales y no depende de los cuadros procesados. En la sesión de las 15:16, las gotas de lluvia en el parabrisas hicieron que la cámara no viera los giros y se creyera detenida en el 13,4 % de la marcha; el rumbo de la fusión, tomado del giroscopio, no se afectó, y la validación rechazó 38 detenciones falsas.

4.2.3 Precisión de la localización

Sin GPS después del arranque. La Tabla 13 muestra la separación final respecto del GPS en el modo exclusivamente visual, desde el arranque del filtro, con el giro de la cámara y con el del giroscopio. Con el GPS disponible, en cambio, la fusión predice cada solución nueva con un error mediano de 1,3 a 2,0 m (Sección 4.2.2).

Tabla 13: Separación final respecto del GPS en el modo exclusivamente visual, como porcentaje de lo recorrido

Giro	14:05	14:18	14:52	14:55	15:05	15:16
Cámara	55 %	86 %	73 %	69 %	97 %	33 %
Giroscopio	5 %	18 %	39 %	31 %	21 %	34 %

Con el giro de la cámara, la trayectoria se separa entre un tercio y casi la totalidad de lo recorrido, lo que confirma que la odometría visual monocular sola no sostiene la localización en recorridos de varios minutos. Con el giroscopio, la forma de los giros es correcta y la separación queda entre 5 y 39 %, aunque en la sesión con lluvia no mejora; lo que queda es el largo de los tramos, que depende de la escala de la cámara, cuya razón con la Doppler varió en campo entre 0,16 y 1,8 según la sesión y la rapidez, y se desploma por encima de 12 m/s.

Pérdidas simuladas del GPS. Para la configuración elegida, la Tabla 8 muestra el error al volver el GPS en las grabaciones del 30 de septiembre. En las sesiones de campo, la mediana de ese error fue de 10 a 22 m en los cortes de 10 s, de 34 a 161 m en los de 30 s y de 156 a 434 m en los de 120 s, y la fusión superó al GPS extrapolado a velocidad constante en el 55 al 100 % de los cortes, según la sesión y la duración. Los cortes de más de 20 s dependen sobre todo de la escala de la cámara, lo que también explica la dispersión entre sesiones.

GPS degradado. La Tabla 14 muestra el efecto de degradar de forma sintética el GPS de dos sesiones de campo, con la referencia en el GPS original.

Tabla 14: Percentil 95 del error con el GPS degradado de forma sintética, en metros, media de cinco semillas. “GPS solo” es la solución degradada o, si se perdió, la última extrapolada con su Doppler

	Sesión 15:05		**Sesión 14:55**	
Degradación del GPS	Fusión	GPS solo	Fusión	GPS solo
Ninguna	4,1	–	3,1	–
Ruido blanco de 5 m	6,5	11,8	5,3	12,0
Ruido blanco de 10 m	15,8	23,7	11,6	24,0
Multitrayecto de 10 m, correlado durante 10 s	21,0	23,0	20,4	23,1
Saltos de 30 a 100 m en el 15 % de las soluciones	4,7	76,9	6,4	74,9
Ráfagas de 5 s a 30–100 m	4,4	66,4	3,7	65,4
Pérdida del 80 % de las soluciones	100,9	77,0	25,6	42,6
Una solución cada 5 s	50,4	16,2	12,1	12,1
Ruido, saltos y pérdidas combinados	27,8	52,4	19,2	55,6

La fusión rechaza los saltos sueltos y las ráfagas, con un percentil 95 de 4 a 6 m frente a 65 a 77 m del GPS solo, y con ruido blanco de 5 y 10 m su error queda entre el 44 y el 67 % del que tiene el GPS solo. El error correlado de tipo multitrayecto, en cambio, no se distingue de un movimiento real y pasa casi intacto. Con soluciones escasas el resultado depende otra vez de la escala de la cámara: en la sesión de las 14:55 la fusión queda cerca del GPS solo o lo mejora, mientras que en la de las 15:05, más rápida, queda peor.

4.2.4 Aporte del aprendizaje por refuerzo

La Tabla 15 resume la primera iteración en las seis sesiones de prueba juntas, con 256, 250, 244 y 226 cortes de 10, 20, 30 y 60 s, cada sesión evaluada con políticas entrenadas sin ella; entre paréntesis se indica la fracción del margen entre el filtro convencional y el oráculo que captura cada método en el percentil 90.

Tabla 15: Error al volver el GPS con la política de la primera iteración, en metros (mediana / percentil 90), en las seis sesiones de prueba juntas; la política es la media de tres semillas

Corte	**Convencional**	**Regla de rapidez**	**Peso fijo**	**Política**	**Oráculo**
10 s	9,6 / 34,1	8,5 / 32,7 (11 %)	–	8,6 / 32,6 (12 %)	5,5 / 21,1
20 s	19,9 / 97,1	20,6 / 85,3 (23 %)	26,2 / 80,8 (32 %)	20,6 / 80,3 (33 %)	14,3 / 46,5
30 s	32,3 / 169,6	37,7 / 138,3 (36 %)	39,7 / 133,7 (42 %)	34,1 / 135,0 (40 %)	21,2 / 83,2
60 s	76,6 / 361,5	112,8 / 339,4 (13 %)	–	70,3 / 324,0 (21 %)	48,0 / 185,8

La política cumple el criterio declarado: captura el 33 % del margen a 20 s y el 40 % a 30 s, y cada una de las tres semillas supera por sí sola el 25 %, con capturas de 28 a 38 %

y de 36 a 47 %. Con el GPS presente la predicción no cambió, porque en las seis sesiones no hubo ninguna pérdida natural de 1,5 s y la política nunca actuó. La regla de rapidez, cuyo umbral resultó de 10 m/s en cinco de las seis pruebas, queda cerca: la política la supera por 10 puntos a 20 s, por 4 a 30 s y por 8 a 60 s, y empatan a 10 s. La mejora se concentra en la cola: la política empeora la mediana del filtro convencional en 0,7 m a 20 s y en 1,8 m a 30 s, y la mejora a 60 s.

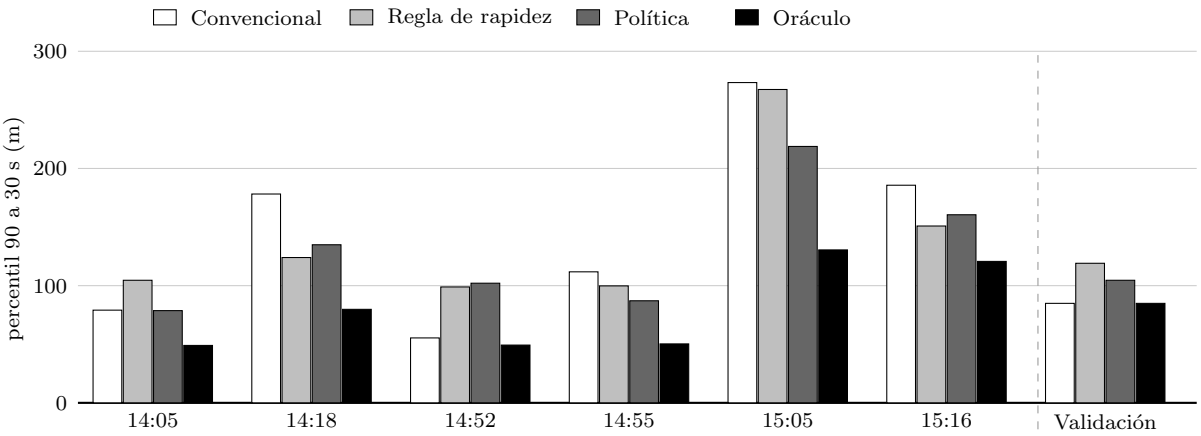


Fig. 11: Percentil 90 del error al volver el GPS en los cortes de 30 s, por sesión de prueba, con la política de la primera iteración (media de tres semillas). La grabación de validación, a la derecha de la línea discontinua, pertenece a otro dominio. Fuente: elaboración propia.

Por sesión (Fig. 11), la política mejora el percentil 90 en cuatro de las seis sesiones, lo iguala en la de las 14:05 y lo empeora en la de las 14:52, la más corta, con 9 cortes de 30 s; la regla empeora dos. Los controles descartan un artefacto: una segunda corrida idéntica reprodujo los mismos números y la misma tabla final; con las mismas tablas pero con los estados barajados la captura cayó a 4 y 3 %, y con acciones al azar en la misma proporción, a 8 y 7 %; y un remuestreo por sesión dio intervalos del percentil 5 al 95 de 16 a 49 % a 20 s y de 22 a 52 % a 30 s. En los cortes de 30 s que empiezan a menos de 3 m/s la política casi no cambia el resultado, mientras que por encima de 10 m/s descarta con frecuencia la rapidez de la cámara: rescata los cortes en que la escala se dispara, con un percentil 90 de mejora de 157 m, a cambio de empeorar otros, con un percentil 10 de −61 m.

La comparación más exigente es con un peso fijo menor para la cámara durante los cortes, elegido con las sesiones de entrenamiento: empata con la política en el percentil 90, pero empeora la mediana en 6 a 7 m, frente a 0,7 a 1,8 m de la política, porque baja el peso siempre, mientras que la política decide cuándo bajarlo. El análisis de los cortes en que la política pierde más de 20 m mostró que su estado no distingue una cámara con la escala equivocada de un vehículo que acelera o frena, y que descartar la cámara equivale a suponer rapidez constante; esto motivó la segunda iteración, con pesos finitos intermedios. En la grabación de validación no hubo margen a 30 s, ya que el oráculo coincide con el filtro convencional, y tanto la política como la regla empeoraron el percentil 90, aunque

la mediana de la política quedó igual o mejor: la política no se traslada a un dominio con otra aplicación y otra cámara. Durante los cortes, la política eligió $\lambda = 1$ en el 30 a 55 % de las decisiones, $\lambda = 4$ en el 16 a 26 % y el descarte en el 20 a 54 %, y la tabla final visitó 187 de los 243 estados.

4.2.5 Limitaciones de la solución

- **Referencia.** Las grabaciones propias carecen de una trayectoria de referencia de alta precisión. El GPS del teléfono, con un error de varios metros, limita las comparaciones finas, aunque es pequeño frente a los errores de decenas de metros que se miden en los cortes.

- **Latencia en la portátil.** La latencia en la computadora portátil empleada en campo es mucho mayor que en la computadora de escritorio: su percentil 95 fue de 167 a 189 ms conectada a la corriente y de 201 a 219 ms con batería, frente a 107 ms, porque su tiempo de procesamiento por cuadro es de dos a tres veces mayor.

- **Escala de la cámara.** Varía con la escena y la rapidez, y se desploma por encima de 12 m/s; domina el error en los cortes de más de 20 s y con soluciones GPS escasas.

- **Aprendizaje por refuerzo.** El aporte de la política es moderado y pierde confiabilidad fuera del dominio en que se entrenó. Su limitación principal es que, durante una pérdida del GPS, el estado no distingue si la rapidez de la cámara es errónea o si el vehículo realmente aceleró o frenó. En el segundo caso la política baja la confianza en la cámara cuando no debería, lo que equivale a suponer una rapidez constante y empeora ligeramente la estimación: la mediana del error al volver el GPS es de 0,7 a 1,8 m mayor que la del filtro convencional. La política evaluada mejora los resultados frente al filtro convencional en los peores casos, pero esta limitación persiste.

Capítulo 5

Conclusiones

Recordar que las conclusiones no son un resumen de lo que se desarrolló

5.1 Recomendaciones

Bibliografía

[1] Giorgio C. Buttazzo. *Hard Real-Time Computing Systems: Predictable Scheduling Algorithms and Applications*. Springer, 3rd edition, 2011. https://doi.org/10.1007/978-1-4614-0676-1.

[2] Cesar Cadena, Luca Carlone, Henry Carrillo, Yasir Latif, Davide Scaramuzza, José Neira, Ian Reid, and John J. Leonard. Past, present, and future of simultaneous localization and mapping: Toward the robust-perception age. *IEEE Transactions on Robotics*, 32(6):1309–1332, 2016. https://doi.org/10.1109/TRO.2016.2624754.

[3] Kai-Wei Chiang, Dinh Thuan Le, Thanh Trung Duong, and Rui Sun. The performance analysis of INS/GNSS/V-SLAM integration scheme using smartphone sensors for land vehicle navigation applications in GNSS-challenging environments. *Remote Sensing*, 12(11):1732, 2020. https://doi.org/10.3390/rs12111732.

[4] Martin A. Fischler and Robert C. Bolles. Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography. *Communications of the ACM*, 24(6):381–395, 1981. https://doi.org/10.1145/358669.358692.

[5] X. Gao, H. Luo, B. Ning, F. Zhao, L. Bao, Y. Gong, Y. Xiao, and J. Jiang. RL-AKF: An adaptive Kalman filter navigation algorithm based on reinforcement learning for ground vehicles. *Remote Sensing*, 12(11):1704, 2020. https://doi.org/10.3390/rs12111704.

[6] Andreas Geiger, Philip Lenz, and Raquel Urtasun. Are we ready for autonomous driving? the KITTI vision benchmark suite. In *2012 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3354–3361, 2012. https://doi.org/10.1109/CVPR.2012.6248074.

[7] Giorgio Grisetti, Rainer Kümmerle, Cyrill Stachniss, and Wolfram Burgard. A tutorial on graph-based SLAM. *IEEE Intelligent Transportation Systems Magazine*, 2(4):31–43, 2010. https://doi.org/10.1109/MITS.2010.939925.

[8] Paul D. Groves. *Principles of GNSS, Inertial, and Multisensor Integrated Navigation Systems*. Artech House, 2nd edition, 2013. ISBN 978-1-60807-005-3.

[9] Richard Hartley and Andrew Zisserman. *Multiple View Geometry in Computer Vision*. Cambridge University Press, 2nd edition, 2004. ISBN 978-0-521-54051-3.

[10] Instituto Tecnológico de Costa Rica, Escuela de Ingeniería en Computadores. Lineamientos para los trabajos finales de graduación, licenciatura en ingeniería en computadores, curso ce-5601. Versión 4.1, 2024.

[11] Yupeng Jia, Haiyong Luo, Fang Zhao, Guanlin Jiang, Yuhang Li, Jiaquan Yan, and Zhuqing Jiang. Lvio-Fusion: A self-adaptive multi-sensor fusion SLAM framework using actor-critic method. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2021. https://doi.org/10.1109/IROS51168.2021.9635905.

[12] Rudolph E. Kalman. A new approach to linear filtering and prediction problems. *Transactions of the ASME — Journal of Basic Engineering*, 82(1):35–45, 1960. https://doi.org/10.1115/1.3662552.

[13] David G. Lowe. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110, 2004. https://doi.org/10.1023/B:VISI.0000029664.99615.94.

[14] A. H. Mohamed and K. P. Schwarz. Adaptive Kalman filtering for INS/GPS. *Journal of Geodesy*, 73(4):193–203, 1999. https://doi.org/10.1007/s001900050236.

[15] Raúl Mur-Artal, J. M. M. Montiel, and Juan D. Tardós. ORB-SLAM: A versatile and accurate monocular SLAM system. *IEEE Transactions on Robotics*, 31(5):1147–1163, 2015. https://doi.org/10.1109/TRO.2015.2463671.

[16] Edward Rosten and Tom Drummond. Machine learning for high-speed corner detection. In *Computer Vision – ECCV 2006*, pages 430–443, 2006. https://doi.org/10.1007/11744023_34.

[17] Ethan Rublee, Vincent Rabaud, Kurt Konolige, and Gary Bradski. ORB: An efficient alternative to SIFT or SURF. In *2011 International Conference on Computer Vision (ICCV)*, pages 2564–2571, 2011. https://doi.org/10.1109/ICCV.2011.6126544.

[18] Davide Scaramuzza and Friedrich Fraundorfer. Visual odometry Part I: The first 30 years and fundamentals. *IEEE Robotics & Automation Magazine*, 18(4):80–92, 2011. https://rpg.ifi.uzh.ch/docs/VO_Part_I_Scaramuzza.pdf.

[19] John P. Snyder. Map projections: A working manual. Professional Paper 1395, U.S. Geological Survey, 1987. https://pubs.usgs.gov/publication/pp1395.

[20] Ian Sommerville. *Software Engineering*. Pearson, Boston, MA, USA, 10th edition, 2016.

[21] Jürgen Sturm, Nikolas Engelhard, Felix Endres, Wolfram Burgard, and Daniel Cremers. A benchmark for the evaluation of RGB-D SLAM systems. In *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 573–580, 2012. https://cvg.cit.tum.de/_media/spezial/bib/sturm12iros.pdf.

[22] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition, 2018. http://incompleteideas.net/book/the-book-2nd.html.

[23] Richard S. Sutton, David McAllester, Satinder Singh, and Yishay Mansour. Policy gradient methods for reinforcement learning with function approximation. In *Advances in Neural Information Processing Systems 12 (NIPS 1999)*, pages 1057–1063, 1999. https://proceedings.neurips.cc/paper_files/paper/1999/file/464d828b85b0bed98e80ade0a5c43b0f-Paper.pdf.

[24] TEC: Tecnológico de Costa Rica. Ingeniería en computadores, 2026. [En línea]. Disponible en: https://www.tec.ac.cr/ingenieria-computadores.

[25] TEC: Tecnológico de Costa Rica. Qué es el tec, 2026. [En línea]. Disponible en: https://www.tec.ac.cr/que-es-tec.

[26] Sebastian Thrun, Wolfram Burgard, and Dieter Fox. *Probabilistic Robotics*. MIT Press, 2005. ISBN 978-0-262-20162-9.

[27] Shinji Umeyama. Least-squares estimation of transformation parameters between two point patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 13(4):376–380, 1991. https://doi.org/10.1109/34.88573.

[28] Christopher J. C. H. Watkins and Peter Dayan. Technical note: Q-learning. *Machine Learning*, 8(3–4):279–292, 1992. https://doi.org/10.1007/BF00992698.

[29] Ching-Chang Wong, Hsuan-Ming Feng, and Kun-Lung Kuo. Multi-sensor fusion simultaneous localization mapping based on deep reinforcement learning and multi-model adaptive estimation. *Sensors*, 24(1):48, 2024. https://doi.org/10.3390/s24010048.

[30] Lihe Yang, Bingyi Kang, Zilong Huang, Zhen Zhao, Xiaogang Xu, Jiashi Feng, and Hengshuang Zhao. Depth anything V2. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. https://doi.org/10.52202/079017-0688.

[31] Farzaneh Zangenehnejad and Yang Gao. GNSS smartphones positioning: Advances, challenges, opportunities, and future perspectives. *Satellite Navigation*, 2(24), 2021. https://doi.org/10.1186/s43020-021-00054-y.

Apéndice A

APENDICE A

Apéndice B

APENDICE B

Apéndice C

APENDICE C